

UNIVERSIDAD NACIONAL DE ASUNCIÓN

FACULTAD POLITÉCNICA

INGENIERÍA EN INFORMÁTICA



Tesis de Grado

**Algoritmos de Optimización Multi-Objetivos Basados en
Colonias de Hormigas Aplicado al Problema de Compensación
de Potencia Reactiva**

Autores:

Hugo R. Benítez Vega
Rodolfo Páez Quintana

Tutores:

D.Sc. Ing. Benjamín Barán
D.Sc. Ing. Diego Pinto
Ing. Pedro Gardel

SAN LORENZO - PARAGUAY
NOVIEMBRE - 2012

Mi gratitud, principalmente esta dirigida al Dios todopoderoso por haberme dado la existencia y permitido llegar al final de la carrera. A mis queridos padres quienes con mucho cariño, amor y ejemplo han hecho de mí una persona con valores para poder desenvolverme como profesional. A mis hermanos, por que siempre he contado con ellos para todo, gracias a la confianza que siempre nos hemos tenido; por el apoyo y la amistad.

Hugo R Benítez Vega

A Dios, Por haberme permitido llegar hasta este punto y haberme dado salud para lograr mis objetivos, por estar conmigo en cada paso que doy, por fortalecer mi corazón e iluminar mi mente, por haber puesto en mi camino a aquellas personas que han sido mi soporte y compañía durante todo el periodo de estudio, además de su infinita bondad y amor. A mi familia, por ser el puntal principal de mi vida, por enseñarme a soñar y a alcanzar metas, por haberme apoyado en todo momento, por sus consejos, sus valores, por la motivación constante que me ha permitido ser una persona de bien, pero más que nada, por su amor. A esa persona muy especial, quien me ha dado su apoyo incondicional durante el tiempo que duró la realización de esta tesis, gracias por estar conmigo siempre. “Te haré entender, y te enseñaré el camino en que debes andar, sobre ti fijaré mis ojos” (Sal 32:8)

Rodolfo Páez Quintana

Agradecimientos

A todos los directivos de la Universidad Nacional de Asunción, por su apoyo y colaboración para la realización de esta investigación. A la Facultad Politécnica, por el soporte institucional dado para la realización de este trabajo.

A los profesores: Pedro Gardel, Diego Pinto y Benjamín Barán por sus asesorías y apoyos en el trabajo de investigación. Quisieramos agradecer especialmente al los Profesores Pedro Gardel y Diego Pinto por todos los conocimientos que compartieron con nosotros a lo largo del proceso de elaboración de este trabajo de tesis.

A nuestras familias, por habernos comprendido y apoyado en todo este tiempo de mucho trabajo. Sin su apoyos no hubiera sido posible realizar esta tesis. Y a todas aquellas personas que de una u otra forma, colaboraron o participaron en la realización de esta investigación, hacemos extensiva nuestro más sinceros agradecimientos.

Abstract

A fundamental aspect of the design and operation of the EPS (*Electric Power Systems*) is the problem of RPC (*Reactive Power Compensation*). The objective of an RPC is to determine the configuration of the electrical system that optimizes the resources available for investment in compensation devices and the physical layout of inductors or capacitor banks needed to achieve a stable system, while increasing the efficiency of the EPS and system reliability.

The energy efficiency of an electric system depends largely on the reactive power compensation is performed, it is often necessary to use reactive power compensators at industrial systems due to the variety of existing loads.

The theory of meta-heuristic ACO (*Ant Colony Optimization*) was proposed as a theory that models the natural behavior of real ants in their search for food. While moving between the nest and the food source, some species of ants deposite a chemical substance called pheromone to find the shortest path from their nest to a food source. Currently, this theory is successfully applied to some multi-objective optimization problems.

The present work proposes the resolution of the RPC optimization based on MOACO (*Multi-Objective Ant Colony Optimization*). It is proposed to simultaneously optimize the investment in banks of reactive power compensation, the average voltage deviation and the maximum deviation of tesion. Also, this work presents results of experimental tests based on conventional metrics and statistical analysis through hypothesis testing.

Resumen

Un aspecto fundamental de diseño y operación de todo Sistema Eléctrico de Potencia (*Electric Power Systems, EPS*) es el problema de Compensación de Potencia Reactiva (*Reactive Power Compensation, RPC*). El objetivo del RPC es determinar la configuración del sistema eléctrico, que optimice los recursos disponibles para la inversión en dispositivos de compensación y la distribución física de los bancos de capacitores o inductores necesarios para alcanzar un sistema estable, aumentando al mismo tiempo la confiabilidad del EPS.

La eficiencia energética de un sistema eléctrico depende en gran medida de la Compensación de Potencia Reactiva que se realice, se hace frecuente la necesidad de utilizar compensadores de potencia reactiva en sistemas industriales debido a la diversidad de cargas existentes. Por tal motivo, el RPC es un problema complejo en la que el desarrollo de técnicas de optimización es un desafío permanente.

La teoría de la meta-heurística de Optimización basada en Colonias de Hormigas (*Ant Colony Optimization, ACO*) fue propuesta como una teoría que modela el comportamiento natural de las hormigas reales en su búsqueda de alimentos, que por medio de una sustancia química que segregan, trabajando como colonia, son capaces de encontrar el camino más corto desde su nido a una fuente de alimento, y es utilizada con éxito en la resolución de problemas de optimización multi-objetivo (*Multi-Objective Ant Colony Optimization, MOACO*).

Este trabajo propone la resolución del problema RPC basado en MOACO. Se propone optimizar simultáneamente la inversión en bancos de compensación de potencia reactiva, la desviación del promedio de tensión y la máxima desviación de tensión. Son nueve los algoritmos MOACO aplicados para la resolución del problema y se verifica un buen comportamiento empírico de los mismos. Además presentamos resultados de las pruebas experimentales basados en métricas convencionales y análisis estadísticos a través de pruebas de hipótesis obtenidas por las meta-heurísticas MOACO del estado del arte.

Contenido

Contenido	v
Lista de Figuras	ix
Lista de Símbolos	xi
Lista de Acrónimos	xiv
Lista de Tablas	xvi
Lista de Algoritmos	xvii
1 Introducción	1
1.1 El trabajo está organizado como sigue:	2
2 Conceptos Básicos e Introducción al Flujo de Potencia Óptimo	4
2.1 Estudio de Sistemas Eléctricos de Potencia	4
2.2 Estructura funcional de los Sistemas Eléctricos de Potencia	4
2.2.1 Sistema de Generación	5
2.2.2 Sistema de Transmisión	5
2.2.3 Sistema de Distribución	6
2.3 Planificación y operación de los Sistemas Eléctricos de Potencia	6
2.3.1 Planificación de la Expansión	6
2.3.2 Planificación de la Operación	6
2.3.2.1 Planificación de la operación energética	6
2.3.2.2 Planificación de la operación eléctrica	6
2.3.3 Operación en tiempo-real	7
2.4 Estudios y herramientas computacionales	7
2.5 Flujo de Potencia	7
2.5.1 Formulación de la red	8
2.5.2 Definición analítica del problema del Flujo de Potencia	11
2.5.3 Métodos de solución	11
2.5.4 Flujo de Potencia Óptimo	12
2.5.4.1 Aplicaciones	12

2.5.4.2	Formulación matemática	13
3	Optimización Multi-Objetivo	16
3.1	Conceptos y Terminología	16
3.2	Búsqueda y Toma de Decisiones	19
3.3	Métodos tradicionales de optimización	20
3.3.1	El método de suma con pesos	20
3.3.2	Ordenamiento Lexicográfico	22
4	Formulación del problema considerado	23
4.1	Formulación Matemática del Problema de Compensación de Potencia Reactiva	23
4.1.1	Minimización de la inversión en dispositivos de compensación de potencia reactiva	25
4.1.2	Minimización de la desviación promedio de voltaje	25
4.1.3	Minimización de la máxima desviación de voltaje	26
4.2	Formulación como problema Multi-Objetivo	26
4.3	Métodos de Optimización aplicados a los Sistemas Eléctricos de Potencia	28
4.3.1	Métodos Analíticos	28
4.3.2	Métodos de Programación Numérica	28
4.3.3	Métodos Metaheurísticos	29
4.4	Métodos basados en Inteligencia Artificial	29
4.4.1	Sistemas Expertos	29
4.4.2	Redes Neuronales	29
4.4.3	Teoría de Conjuntos Difusos	29
4.4.4	Templado Simulado	30
4.4.5	Búsqueda Tabú	30
4.4.6	Optimización por Colonia de Hormigas (ACO)	30
4.4.7	Optimización por enjambres de partículas	30
4.4.8	Algoritmos Genéticos	31
4.5	Técnicas híbridas de Inteligencia Artificial	31
5	Optimización basada en colonia de hormigas	32
5.1	Colonia de Hormigas	33
5.2	Modelo computacional simple de las hormigas reales	35
5.3	Meta-heurística ACO	37
5.4	Alternativas de diseño multi-objetivo	39
5.4.1	Número de Colonias	40
5.4.2	Información de feromonas y visibilidad	40
6	Algoritmos ACO y MOACO	43
6.1	Algoritmos ACO mono-objetivos	44
6.1.1	Ant System (AS)	44
6.1.2	Rank-based Ant System (ASrank)	44

6.1.3	Max-Min Ant System (MMAS)	45
6.1.4	Ant-Q Algorithm	47
6.1.5	Ant Colony System (ACS)	48
6.1.6	Omicron ACO (OA)	49
6.2	Algoritmos MOACO	49
6.2.1	Multiple Objective Ant Q Algorithm (MOAQ)	50
6.2.2	Bicriterion Ant (BIANT)	50
6.2.3	Bicriterion Multi Colony (BicriterionMC o BIMC)	51
6.2.4	Pareto Ant Colony Optimization (PACO)	52
6.2.5	Multi-Objective Ant Colony System (MOACS)	52
6.2.6	MultiObjective Max-Min Ant System (M-MMAS o M3AS)	53
6.2.7	COMPETants (COMP)	54
6.2.8	Multiobjective Omicron ACO (MOA)	55
6.2.9	MultiObjective Ant System (MAS)	55
7	MOACOs Aplicados al problema RPC	57
7.1	Pseudocódigo genérico MOACO del problema RPC	57
7.2	Feromonas τ	59
7.3	Visibilidad η	61
7.3.1	A continuación se presenta los pseudocódigos de visibilidad η_1 , η_2 y η_3 propuestos.	66
8	Estudios Experimentales, Testing y Análisis de Resultados	71
8.1	Definir los objetivos experimentales.	71
8.1.1	Problema de referencia.	73
8.2	Entorno computacional	73
8.3	Métricas de desempeño	74
8.3.1	Distancia al frente Pareto óptimo M_1	74
8.3.2	Distribución del frente Pareto M_2	75
8.3.3	Extensión del frente Pareto M_3	75
8.3.4	Error al frente Pareto óptimo M_4	75
8.3.5	Soluciones aportadas al frente Pareto óptimo	75
8.3.6	Espaciamento (<i>Spacing</i>) M_6	76
8.3.7	Hiper-Volumen M_7	76
8.4	Diseño Experimental	77
8.5	Estudio Global de las métricas de desempeño para los algoritmos MOACO-RPC	77
8.5.1	Análisis de Resultados de la Métrica M_1	78
8.5.2	Análisis de Resultados de la Métrica M_2	79
8.5.3	Análisis de Resultados de la Métrica M_3	79
8.5.4	Análisis de resultado de la métrica Error M_4	79
8.5.5	Análisis de resultado de la métrica ONVGR M_5	79
8.5.6	Análisis de resultado de la métrica de Spacing M_6	81
8.6	Análisis Estadísticos	81

8.6.1	Diseño del experimento utilizando prueba de hipótesis	81
8.6.2	Procedimiento general para la prueba de Hipótesis	83
8.6.3	Selección de métricas para aplicar la prueba de hipótesis	83
8.6.4	Análisis Estadísticos de los Datos	84
8.6.4.1	Test de Normalidad (Test de Shapiro-Wilk)	84
8.6.4.2	Prueba de Homogeneidad de Varianza (Test de Levene)	85
8.6.4.3	Prueba de T-test respecto a las medias cuando se mues- tran distribuciones normales.	87
8.6.4.4	Análisis de prueba de hipótesis.	88
9	Conclusiones y Trabajos Futuros	90
	Apéndice A	92
	Apéndice B	96
	Referencias	102

Lista de Figuras

2.1	Estructura funcional de los EPS	5
2.2	Red sencilla mostrando variables nodales	8
4.1	Ejemplo de distribución de bancos Shunt en un EPS	27
5.1	Comportamiento de las hormigas en la búsqueda de su alimento entre el nido y su fuente de alimentación. (a) Inicialmente todas las hormigas van por un camino más corto, (b) eligen aleatoriamente los caminos alternativos en ausencia de feromonas entre los distintos caminos alternativos, y (c) los altos niveles de concentración de feromonas atraen a las hormigas por el camino más corto. Imagen tomada de [GBF ⁺ 06]. . .	34
7.1	Visualización gráfica de la asignación de deseabilidad η_1	63
7.2	Visualización gráfica de la asignación de deseabilidad de la función η_2 .	64
7.3	Visualización gráfica de la asignación de deseabilidad de la función compuesta η para tres iteraciones distintas: a) la primera de la generación, b) una intermedia y c) la última iteración de la generación.	66
8.1	Sistema eléctrico de potencia estandarizado IEEE de 118 barras.	72
8.2	Estudio de la métrica de Distancia al frente M_1	78
8.3	Estudio de la métrica Distribución del frente Pareto M_2	79
8.4	Estudio de la métrica Extensión del frente Pareto M_3	80
8.5	Estudio de la métrica Error al frente Pareto Ptrue M_4	80
8.6	Estudio de la métrica ONVGR M_5	81
8.7	Estudio de la métrica Spacing M_6	82
8.8	Modo de proceder a la hora de seleccionar el test estadístico adecuado a la naturaleza de las muestras.	84
1	Test de Normalidad “Test de Shapiro-Wilk”(1)	96
2	Test de Normalidad “Test de Shapiro-Wilk”(2)	97
3	Test de Normalidad “Test de Shapiro-Wilk”(3)	98
4	Test de Normalidad “Test de Shapiro-Wilk”(4)	99
5	Test de Normalidad “Test de Shapiro-Wilk”(5)	100

LISTA DE FIGURAS

6	Prueba de T-Test con respecto a las medias cuando se muestran distribuciones normales	101
---	---	-----

Lista de Símbolos

B_i	Compensación instalada en la barra i .
b_{iI}^m	Máximo valor de compensación inductiva admisible en la barra i .
CP_{true}	Conjunto Pareto Óptimo.
P_{true}	Frente Pareto ptimo.
E_k	Tensión en el nodo k .
FP	Frente Pareto calculado por un algoritmo.
f_1^m	Máxima potencial reactiva total nominal que se puede instalar en el EPS.
f_3	Desviación máxima de voltaje.
$f : \mathbb{R}^n \rightarrow \mathbb{R}$	Función objetivo.
G_{km}	Conductancia de línea entre los nodos k y m .
k	Nodo de la red eléctrica.
$\mathbf{k}$	Número de funciones objetivos de un MOP.
l_i	Número de líneas asociadas a la barra i .
$e(x)$	Conjunto de restricciones de un MOP.
m	Nodo de una red eléctrica.
$\mathbf{m}$	Número de restricciones de un MOP.
n	Número de barras del sistema eléctrico de potencia.
$\mathbf{n}$	Número de variables de decisión.
O	micron, parámetro utilizado en el micron ACO.
P_k	Potencia activa neta en la barra k .
Q_k	Potencia reactiva neta en la barra k .
S_k	Potencia aparente neta en la barra k .
V_i^*	Voltaje deseado en la barra i .
v_i^*	Valor del hipercubo utilizado por la métrica Hiper-Volumen.
ΔV	Desviación de tensión.
w_j	Peso de ponderación.
$\mathbf{X}$	Espacio de decisión.
$\mathbf{x} \in R^n$	Variable de control o independiente.

Y_{kk}	Admitancia propia del nudo k .
y_{km}	Admitancia de línea entre los nudos k y m .
$\mathbf{y}$	Vector objetivo.
Y_{kk}	Admitancia propia del nudo k .
$\ \cdot\ $	Norma.
$\triangleright$	Domina o es no comparable con.
$\sim$	Son no comparables.
β	Parámetro que determina la influencia de la visibilidad en un ACO.
η_1, η_2, η_3	Funciones de visibilidad especialmente diseñadas para los algoritmos MOA-COs.
O	micron.
τ	Matriz de feromona utilizada por ACO.
θ_k	Fase de la tensión E_k .
x^*	Solución global óptima.
u, v, x	Vectores de decisión.
J_i	Conjunto de vecinos ubicados a un salto del nodo.
$\Delta\tau$	Cantidad de feromonas a depositar.
η	Visibilidad.
α	Importancia relativa de las feromonas.
Z	Factor de normalización.
f_s	Factor de suavizamiento.
τ_{min}	Valor mínimo impuesto a la cantidad de feromonas.
q_o	Probabilidad de utilizar la regla pseudo aleatoria.
q	Tamaño de muestras para el test de Shapiro-Wilk.
gb	Mejor solución global.
b	Cantidad de colonias.
l	Número de hormigas.
P	Conjunto de soluciones no nominadas.
η	Función de visibilidad global
η_1	Función de visibilidad que otorga mayor deseabilidad a las soluciones con poca compensación.
w_1	Valor de ponderación para η_1 .
w_2	Valor de ponderación para η_2 .
w_3	Valor de ponderación para η_3 .
f_b	Factor de proporcionalidad para el cálculo de w_2 .
M_2	Métrica de Distribución del frente pareto.

M_4	Métrica de Error al frente pareto óptimo.
SP	Valor correspondiente a la métrica Spacing.
HV	Valor de la métrica Hiper-Volumen.
H_0	Hipótesis nula de una prueba de hipótesis.
H_1	Hipótesis alternativa de una prueba de hipótesis.
$\alpha - error$	Probabilidad de cometer error de Tipo I.
$\beta - error$	Probabilidad de cometer error de Tipo II.
n_i	Tamaño de la i-ésima muestra.
$\bar{x}$	Media muestral para los test estadísticos.
$x(i)$	i-ésimo valor de una muestra.
σ	Desviación estándar o Desviación típica.
σ^2	Varianza de una población.
μ	Valor que se desea alcanzar en el T-test.
R	Punto de referencia utilizado por la métrica Hiper-Volumen.
t_c	Valor t critico del T-test.
T	Conjunto de datos para el test de Shapiro-Wilk.
d	Numero de muestras del test de Levene.
W	Estadístico del test Shapiro-Wilk.
$y_{(q)}$	Muestra ordenada para el test de Shapiro-Wilk.

Lista de Acrónimos

<i>ACO</i>	Optimizacin por Colonia de Hormigas. (Ant Colony Optimization)
<i>ANDE</i>	Administracin Nacional de Electricidad.
<i>ANN</i>	Redes Neuronales. (Artificial Neural Networks)
<i>CA</i>	Corriente Alterna.
<i>CC</i>	Corriente Continua.
<i>DP</i>	Programacin dinmica. (Dynamic Programming)
<i>EA</i>	Algoritmo Evolutivo. (Evolutionary Algorithm)
<i>ECT</i>	Encuentro Cientfico Tecnolgico.
<i>EPSs</i>	Sistemas Elctricos de Potencia. (Electric Power Systems)
<i>ES</i>	Sistemas Expertos. (Expert Systems)
<i>FST</i>	Teora de Conjuntos Difusos. (Fuzzy Set Theory)
<i>GA</i>	Algoritmos Genticos (Genetic Algorithms.)
<i>i.e.</i>	it est. (latn) esto es
<i>IEE</i>	Instituto de Ingenieros Elctricos (Institution of Electrical Engineers)
<i>IEEE</i>	Instituto de Ingenieros Elctricos y Electronicos (Institute of Electrical and Electronics Engineers.)
<i>MOP</i>	Problema de Optimizacin Multiobjetivo. (Multiobjective Optimization Problem)
<i>NLP</i>	Programacin no lineal (Non-Linear Programming.)
<i>OE</i>	micron Elctrico.
<i>OPF</i>	Flujo de Potencia ptimo. (Optimal Power Flow)
<i>PSO</i>	Optimizacin por enjambre de partculas. (Particle Swarm Optimization)
<i>pu</i>	por unidad
<i>QAP</i>	Problema de Asignacin Cuadrtica. (Quadratic Assignment Problem)
<i>QP</i>	Programacin cuadrtica. (Quadratic Programming)
<i>RPC</i>	Compensacin de Potencia Reactiva. (Reactive Power Compensation)
<i>SA</i>	Templado Simulado. (Simulated Annealing)
<i>SCADA</i>	Sistema de adquisicin remota de datos. (Supervisory Control and Data Acquisition)

LISTA DE ACRONIMOS

- SOP* Problema de Optimizacin Monoobjetivo. (Single-objective Optimization Problem)
- TS* Bsqueda Tab. (Tab Search)
- ACS* Ant Colony System. (Sistema basado en colonias de hormigas).
- AS* Ant System. (Sistema basado en hormigas).
- ASrank* Ranked Ant System. (Sistema de hormiga basado en ranking).
- BIANT* Bicriterion Ant. (Hormigas bi-criterio).
- COMP* CompetANTs.
- MAS* Multiobjective AS. Ant System multi-objetivo.
- MMAS* Max-Min Ant System. Sistema Max-Min basado en hormigas.
- M3AS* Multiobjective MMAS(Max-Min Ant System multi-objetivo).
- MOA* Multiobjective OA. Omicron ACO multi-objetivo.
- MOACO* Multiobjective Ant Colony Optimization. Optimizacin multi-objetivo basada en colonias de hormigas.
- MOACS* Multiobjective ACS. Ant Colony System multi-objetivo.
- MOAQ* Multiobjective Ant Q. Ant Q multiobjetivo.
- OA* Omicron ACO.
- ONVGR* Overall Non-dominated Vector Generation Ratio. Razn de la Generacin Total de Vectores Nodominados.
- PACO* Pareto ACO.
- TSP* Traveling Salesman Problem. Problema del cajero viajante.
- VRPTW* Vehicle Routing Problem with Time Windows. Problema de ruteo de vehculos con ventanas de tiempo.

Lista de Tablas

7.1	Matriz de feromonas del ejemplo 7.1	61
7.2	Asignación de deseabilidad otorgados por la función η_1 para el ejemplo 7.2	63
7.3	Asignación de deseabilidad hecha por la función η_2 para el ejemplo 7.2 .	64
7.4	Asignación de deseabilidad otorgados por la función η_3 para el ejemplo 7.2	65
7.5	Ejemplo de asignación de deseabilidad de la función compuesta η para la primera iteración de una generación	65
7.6	Ejemplo de asignación de deseabilidad de la función compuesta η para la segunda iteración de una generación	66
7.7	Ejemplo de asignación de deseabilidad de la función compuesta η para la tercera iteración de una generación.	66
7.8	Asignación de probabilidades Pr_{ij} , para la iteración inicial del ejemplo 7.3	69
7.9	Asignación de probabilidades Pr_{ij} , para la iteración final del ejemplo 7.3	70
8.1	Parámetros de configuración de los algoritmos.	73
8.2	Tabla de Errores de Tipo I y Tipo II.	83
8.3	Shapiro-Wilk para la métrica HV	86
8.4	T-test para la métrica HV de los algoritmos MOACO.	89
8.5	T-test para la métrica M_1 de los algoritmos MOACO.	89
1	Datos de la métrica M_1	92
2	Datos de la métrica M_2	93
3	Datos de la métrica M_3	93
4	Datos de la métrica Error M_4	94
5	Datos de la métrica ONVGR M_5	94
6	Datos de la métrica Spacing M_6	95

Lista de Algoritmos

1	Pseudocódigo de un algoritmo ACO Simple.	36
2	Pseudocódigo Construir Solución ACO Simple.	36
3	Pseudocódigo de un algoritmo ACO genérico [DM99].	39
4	Pseudocódigo Construir Solución de un algoritmo ACO genérico.	39
5	Pseudocódigo de un algoritmo ACO multi-objetivo.	41
6	Pseudocódigo Construir Solución de un algoritmo ACO multi-objetivo. .	41
7	Pseudocódigo genérico del MOACO-RPC	58
8	Pseudocódigo construcción de solución por cada hormiga	58
9	Pseudocódigo de actualización de la matriz de feromonas	59
10	Pseudocódigo de visibilidad η_1	67
11	Pseudocódigo de visibilidad η_2	67
12	Pseudocódigo de visibilidad η_3	68

Capítulo 1

Introducción

De todas las formas de energías conocidas en la actualidad, la que más se emplea para la economía de cualquier nación, es la energía eléctrica. La posibilidad de explotar distintos tipos de fuentes de energía como corrientes de ríos, combustóleo, gas, uranio, carbón, la fuerza de los mares y vientos, etc. de sitios alejados de los centros de consumo, hace posible que la energía eléctrica se transmita a grandes distancias. Esto implica que debe haber mecanismos de transmisión y posterior distribución de la energía eléctrica, ya que es necesaria en la gran mayoría de procesos de producción de la sociedad actual.

Las bases de la energía eléctrica fueron cimentadas a mediados del siglo XIX, cuando el científico inglés, Michael Faraday, en el año de 1831, descubrió el fenómeno de la inducción electromagnética [Rob60]. Las posteriores investigaciones de la interacción de los conductores de corriente eléctrica con el campo electromagnético posibilitaron la creación de generadores eléctricos, que transforman la energía mecánica del movimiento giratorio en energía eléctrica, lo que formó la base de un Sistema Eléctrico de Potencia “Electric Power Systems” (EPS) [Rob60].

La operación eficiente de un EPS, como así también varias otras aplicaciones reales de ingeniería y otras áreas, generalmente involucran la optimización simultanea de varios objetivos, y la toma de decisiones puede estar relacionada a la alternativa que optimice al mismo tiempo varios criterios generalmente contradictorios [Coe99], [Deb99a].

Muchos de los problemas de esta naturaleza son clasificados como NP-Complejos [Sah76] que no pueden ser tratados de manera eficaz con métodos de búsqueda exhaustiva que exploren completamente el espacio de soluciones del problema. De esta manera al existir una variedad de objetivos, generalmente en conflicto, aparece el concepto de un “conjunto de soluciones óptimas” antes que una única mejor solución.

Este concepto es introducido en la teoría de Pareto y estas soluciones óptimas son conocidas como soluciones Pareto óptimas. Su nombre les fue dado en honor al ingeniero y economista Vilfredo Pareto, quien fue el primero en definir un nuevo criterio de optimalidad para los problemas con múltiples objetivos a cumplir [Coe99]. Esta teoría de Pareto es presentada en detalle en [Van97] y menciona conceptos y definiciones matemáticas precisas de manera a poder tratar problemas desde el punto de vista multi-objetivo “puro” sin utilizar métodos tradicionales de optimización mono-

objetivo.

En la actualidad, la optimización multi-objetivo es tratada por diversos paradigmas de programación, entre los cuales se pueden citar los métodos estocásticos, como los algoritmos evolutivos [Coe99], [CR] y los algoritmos basados en el comportamiento de las hormigas reales [DAGP90], [GADP89], cuya técnica es denominada optimización basada en colonia de hormigas, (*Ant Colony Optimization*, ACO) [DM99]. A la fecha fueron ya propuestos diferentes algoritmos ACO multi-objetivos denominados (*Multi-Objective ACO*, MOACO), [fHIC03], [DK02], [DHR03], [GBF⁺06], [IS01], [MM99], [Pin05], y se debe esto al creciente interés científico ante la necesidad de optimizar estos algoritmos de manera a poder resolver problemas de alta complejidad, como ejemplo de este tipo de problemas podemos citar diversos problemas de ingeniería [GBF⁺06], [Pin05], logística [fHIC03], [DHR03] y otras áreas.

Optimización por Colonia de Hormigas o Ant Colony Optimization es una metaheurística propuesta por Dorigo et al. [DM99], la cual ha sido inspirada en el comportamiento de búsqueda de alimentos de las colonias de hormigas. En los últimos años, ACO ha mostrado empíricamente su efectividad en la resolución de diferentes problemas de optimización combinatoria NP-Complejos, como el problema del cajero viajante o (*Travelling Salesman Problem*, TSP), el problema de asignación cuadrática o (*Quadratic Assignment Problem*, QAP), el problema del enrutamiento de vehículos con ventanas de tiempo o (*Vehicle Routing Problem with Time Windows*, VRPTW), y varios más [DS03], [Gam99], [fHIC03].

Existe un gran número de algoritmos ACO multi-objetivos [fHIC03], [DK02], [DHR03], [GBF⁺06], [IS01], [MM99], [Pin05], los cuales difieren fundamentalmente en el criterio de como utilizan las informaciones obtenidas durante la construcción de una solución, como se actualizan estas informaciones, la cantidad de colonias empleadas y, como son tratadas éstas informaciones para obtener las soluciones óptimas desde el punto de vista multi-objetivos.

El presente trabajo tiene como principal objetivo abordar desde una nueva perspectiva el Problema de Compensación de Potencia Reactiva (Reactive Power Compensation, RPC), tratados en la sección 2.1, lo cual es un problema tradicional en el estudio de los Sistemas Eléctricos de Potencia [Kun93]. Para la resolución de este problema se ha desarrollado distintas técnicas metaheurísticas MOACO con el objeto de minimizar las funciones objetivos del problema en cuestión, la cual se refiere básicamente en optimizar la inversión de potencia reactiva suministrada al sistema eléctrico, así como también minimizar las desviaciones de voltajes en las barras del sistema eléctrico de referencia.

1.1 El trabajo está organizado como sigue:

En el capítulo 2 se da una introducción general acerca de los sistemas eléctricos de potencia, el problema del flujo de potencia, los estudios relacionados con los mismos, el modelo matemático de la red, métodos de solución y una introducción general del flujo óptimo de potencia y sus aplicaciones hasta llegar al problema del RPC de un EPS.

En el capítulo 3 se define formalmente la optimización multi-objetivo, su formulación matemática, además se presentan las métricas que definen el desempeño de los algoritmos multi-objetivos.

En el capítulo 4 se presenta la formulación del Problema de la Compensación de Potencia Reactiva, así como las consideraciones hechas en el presente trabajo para su resolución.

En el capítulo 5 se describe la teoría de la metaheurística ACO, y se muestra como el modelo de comportamiento de las hormigas reales es utilizada en la computación.

En el capítulo 6 se describen los Algoritmos ACO y MOACO.

En el capítulo 7 se describe los algoritmos MOACO utilizados por este trabajo, así como las adaptaciones necesarias para resolver el problema RPC.

En el capítulo 8 se presentan los Estudios Experimentales, Testing y Análisis de Resultado.

Finalmente, en el capítulo 9 se presenta las conclusiones del trabajo realizado, así como las sugerencias para los posibles trabajos futuros relacionados con el tema.

Capítulo 2

Conceptos Básicos e Introducción al Flujo de Potencia Óptimo

2.1 Estudio de Sistemas Eléctricos de Potencia

Un EPS es un conjunto de elementos que constituyen la red eléctrica de potencia, siendo su función: generar, transmitir, y distribuir la energía eléctrica hasta los usuarios, bajo ciertas condiciones y requerimientos; desempeñando un papel importante en la búsqueda de medios eficientes de utilización de los recursos energéticos [Val02],[GBF⁺06].

Un aspecto fundamental del diseño y operación de los EPS es el problema de la Compensación de Potencia Reactiva [GBF⁺06], que consiste básicamente en la determinación de una configuración del sistema que optimice los recursos disponibles para la inversión en dispositivos de compensación, aumentando al mismo tiempo la eficiencia del EPS y la confiabilidad del sistema.

Para el presente problema de compensación, se debe tener en cuenta que los objetivos son una combinación de varios factores, entre los cuales se encuentran la inversión en costos de dispositivos de compensación debido a las pérdidas en la transmisiones. Considerando este enfoque, el problema de la compensación de potencia reactiva puede considerarse como un Problema de Optimización Multi-Objetivo, en la cual, se debe optimizar la inversión por cada Mega Volt-Amperio Reactivo (MVAR) suministrado al sistema, y esto a la vez optimizar los valores deseables de tensiones en las barras.

2.2 Estructura funcional de los Sistemas Eléctricos de Potencia

El Sistema de Potencia está construido por varios elementos, cada uno de ellos cumplen con funciones específicas, de manera que en operación conjunta garantizan un flujo confiable y económico de electricidad. Los elementos básicos que constituyen un sistema de potencia se pueden agrupar en tres grandes grupos de acuerdo a la función que desempeñan, la figura 2.1 muestra sus principales componentes [Val02],[Fal98].




Figura 2.1: Estructura funcional de los EPS

2.2.1 Sistema de Generación

Parte básica del Sistema Eléctrico de Potencia, se encarga de entregar la energía eléctrica al sistema, esto a partir de la transformación de distintos tipos de energía primaria compuesta por usinas o centrales generadoras. Las centrales generadoras más utilizadas en la actualidad son del tipo hidroeléctrica y térmica, como el carbón, fuel oil, gas natural, etc. El tipo de central de generación y ubicación dependen de las condiciones físicas de la fuente primaria de utilización. Las centrales hidroeléctricas, en general, están localizadas en puntos distantes a los centros de consumo, exigiendo sistemas de transmisión complejos y de tensión elevada. Las centrales térmicas generalmente están ubicada cerca de los centros de consumo, debido a su rápida puesta en marcha y tamaño de las instalaciones menores que en las hidroeléctricas; normalmente son utilizadas para suplir energía de punta. La selección del tipo de central de generación eléctrica se realiza por criterios técnicos y económicos, siendo estos últimos lo de mayor importancia.

2.2.2 Sistema de Transmisión

La ubicación de las grandes centrales de generación eléctrica, obligan a transportar grandes bloques energéticos generados a través de grandes distancias, de manera a que lleguen a los centros de consumo. Compuesta por líneas de transmisión y equipos auxiliares, estas líneas pueden ser de corriente alterna (CA) o corriente continua (CC), siendo estas últimas utilizadas para la transmisión de grandes cantidades de energía a las grandes distancias. Las líneas de transmisión son los elementos más extensos del sistema de potencia, y poseen un gran número de ventajas y desventajas cuyo objetivo es asegurar la confiabilidad del sistema.

2.2.3 Sistema de Distribución

De las tres etapas, la de distribución de energía eléctrica comprende las técnicas y sistemas empleados para la conducción de la energía hasta los usuarios dentro del área de consumo. La energía eléctrica es transmitida frecuentemente en bloques de magnitud considerable y en altas tensiones desde el punto de generación hasta el área donde se pretende distribuirla, de ahí que sea necesario ejecutar uno o más pasos de transformación para llevarla a los niveles de utilización. Compuesta por las subestaciones y alimentadores responsables de la distribución. Incluye los sistemas de baja y media tensión.

Para lograr un adecuado desempeño de un EPS así descritos, surge la necesidad de haber realizado los correspondientes estudios de diseño, expansión y operación de los mismos, conforme se presenta resumidamente en la siguiente sección.

2.3 Planificación y operación de los Sistemas Eléctricos de Potencia

Las actividades de ingeniería de planificación y operación de un EPS pueden ser clasificadas en tres categorías principales, diferenciadas según el horizonte de análisis considerado y la naturaleza de los estudios realizados [Val02]:

2.3.1 Planificación de la Expansión

Tiene como objetivo determinar, dentro de un horizonte de largo plazo (hasta 30 años), los nuevos elementos a ser incluidos en el sistema para atender un aumento previsto en la demanda de energía eléctrica.

2.3.2 Planificación de la Operación

Tiene como objetivo establecer una estrategia de operación, incluyendo planes de emergencia, para un horizonte de mediano plazo (hasta algunos años). Normalmente se subdivide en: Planificación de la operación energética y Planificación de la operación eléctrica.

2.3.2.1 Planificación de la operación energética

Donde se analiza la mejor estrategia para la utilización de recursos energéticos, por ejemplo: agua disponible y prevista en los reservorios de las represas hidroeléctricas versus uso de combustible en usinas térmicas.

2.3.2.2 Planificación de la operación eléctrica

Donde se analiza el impacto de las decisiones energéticas en diversos factores tales como: las actividades del programa de mantenimiento, condiciones climáticas, etc., en el desempeño del EPS para garantizar un nivel adecuado de confiabilidad.

2.3.3 Operación en tiempo-real

Tiene como objetivo atender la demanda de energía instantánea del sistema, procurando minimizar los desvíos con respecto a las directivas de planificación de operación. Esto típicamente se realiza en centros de operación de sistemas que cuentan con sistemas de adquisición remota de datos SCADA (*Supervisory Control and Data Acquisition*) y sistemas computacionales capaces de ofrecer a los operadores condiciones adecuadas para la toma de decisiones y acciones de control.

En cada una de estas instancias es de esencial importancia el contar con herramientas de análisis adecuadas a fin de determinar las condiciones de operación de todos los puntos del EPS conocidos algunos parámetros del mismo, como ser las características topológicas y eléctricas de la red así como la distribución de las cargas y dispositivos de compensación entre otros. La herramienta que resuelve dicho problema es conocida como flujo de potencia LF (*Load flow*).

2.4 Estudios y herramientas computacionales

Para ejecutar los estudios relacionados a la planificación y a las tareas de operación de un EPS. Los ingenieros, necesitan herramientas computacionales para el análisis, simulación y control de los mismos [Val02]. A continuación presentamos los estudios y herramientas más importantes que son utilizados en el análisis del Sistema de Potencia, siendo que la gran mayoría de ellos, por no decir la totalidad, son en la actualidad implementados en distintas plataformas computacionales y entre estas podemos citar algunas herramientas básicas de análisis y simulación que realizan los siguientes cálculos tales como: Cálculo de Flujo de Potencia, Cálculo de corto Circuito, Simulación dinámica electromecánica (Estabilidad Transitoria), análisis modal (Estabilidad con pequeñas perturbaciones), Despacho económico de energía, Flujo de Potencia Óptimo, etc. Cabe destacar que en el estudio de optimización de un EPS, ya sea de planificación, operación, u operación en tiempo real, el análisis llamado Flujo de Potencia Óptimo OPF (*Optimal Power Flow*) engloba los principales problemas con que se enfrentan un EPS en cada una de sus etapas. Una introducción al mismo se da en las siguientes secciones.

2.5 Flujo de Potencia

El estudio de flujos de cargas o flujos de Potencias, como se llama también a menudo, está ligado tanto a la evolución de los sistemas eléctricos, como a la evolución digital, teniendo que realizarse grandes cantidades de cálculo matemático. El objetivo de este estudio es obtener los voltajes nodales. Con estas variables conocidas, determinaremos los flujos en las líneas de transmisión, y en general de los elementos del sistema de transmisión dados los niveles de demanda y generación del sistema [Arr83].

La solución provee información de módulo y fase de las tensiones, flujo de potencia activa y reactiva en las líneas de transmisión, pérdidas y la potencia reactiva generada o absorbida en las barras controladoras de tensión [SC95]. Bajo condiciones normales

de funcionamiento, los sistemas eléctricos de transmisión, operan en estado estable y el cálculo básico que se requiere para determinar las características de este estado es llamado flujo de potencia [GBF⁺06].

Aunque la red se considera lineal, sin embargo es bien conocido que el modelo matemático para el estudio de flujos de potencia es no lineal. Por consiguiente, se recurre a métodos numéricos de naturaleza iterativa para su solución [GBF⁺06].

Por último cabe mencionar que las aplicaciones del estudio de flujos de potencia son muy importantes y fundamentales constituyendo la herramienta esencial para el análisis, la planeación, y el diseño de tanto los sistemas eléctricos, como de la operación y control de los mismos.

2.5.1 Formulación de la red

El enfoque inicial ante cualquier análisis de un sistema de energía eléctrica debe ser la formulación de un modelo adecuado para la red. Tal modelo debe relacionar las tensiones de la red con las corrientes o potencias de la misma [SC95]. Existe, de hecho, abundante bibliografía sobre formulación de redes. Véase en [Ste88] dos formas de representar las mismas: ecuaciones de nudos y ecuaciones de lazos. Se utiliza en esta obra la primera de ellas.

En el método de los nudos [Arr83], las variables son las tensiones complejas (módulo y fase) en los nudos y las corrientes. Deben ser designados valores de referencia para los módulos y fases de las tensiones. Generalmente para los módulos la referencia es la tierra; mientras que para las fases se tomó como referencia la de uno de los nudos o barras, asignándole el valor cero.

En la figura 2.2 se puede observar una red sencilla mostrando las corrientes nodales, tensiones y potencias.




Figura 2.2: Red sencilla mostrando variables nodales

Una corriente nodal es aquella que entra a la red por un determinado nudo, proveniente de una fuente y/o de una carga externa a la red. A partir de esta definición, la

2. Conceptos Básicos e Introducción al Flujo de Potencia Óptimo

corriente que entra a la red (desde una fuente) se considera que es positiva, mientras que la que sale de la red (hacia una carga) tiene signo negativo, y la corriente nodal inyectada neta es la suma algebraica de las dos. Así mismo, se puede hablar de una potencia nodal inyectada.

$$S_k = P_k + \mathbf{j}Q_k \quad (2.1)$$

donde:

S_k es la potencia aparente neta en la barra¹ k .

P_k es la potencia activa neta en la barra k .

Q_k es la potencia reactiva neta en la barra k .

$\mathbf{j}$ es la unidad imaginaria $\sqrt{-1}$.

En el método de los nudos, es conveniente usar admitancias de rama en lugar de impedancias. Designando a las tensiones de los nudos k y m como E_k y E_m respectivamente, y a las admitancias de la rama entre ellos como y_{km} , se tiene que la corriente que fluye en esta rama desde el nudo k hacia el nudo m , está dada por:

$$I_{km} = y_{km}(E_k - E_m) \quad (2.2)$$

Se enumeran $0, 1, \dots, n$ los nudos de la red, donde 0 designa el nudo de referencia para los módulos de tensión (tierra). Según la ley de corrientes de Kirchhoff, la corriente I_k inyectada en el nudo k , debe ser igual a la suma de las corrientes que salen del mismo, por consiguiente:

$$I_k = \sum_{m=0 \neq k}^n I_{km} = \sum_{m=0 \neq k}^n y_{km}(E_k - E_m) \quad (2.3)$$

Habiéndose elegido $E_0 = 0$, y si el sistema es lineal:

$$I_k = \sum_{m=0 \neq k}^n y_{km}E_k - \sum_{m=1 \neq k}^n y_{km}E_m \quad (2.4)$$

Si esta ecuación se escribe para todos los nudos, excepto para el de referencia, es decir, para todas las barras en el caso de un sistema de potencia, entonces el conjunto completo de ecuaciones que definen la red se puede expresar en forma matricial como el tipo de ecuación $Ax = b$:

¹Nudos de distribución de la energía eléctrica.

2. Conceptos Básicos e Introducción al Flujo de Potencia Óptimo

$$\begin{bmatrix} I_1 \\ I_2 \\ \vdots \\ I_k \\ \vdots \\ I_n \end{bmatrix} = \begin{bmatrix} Y_{11} & Y_{12} & \dots & Y_{1k} & \dots & Y_{1n} \\ Y_{21} & Y_{22} & \dots & Y_{2k} & \dots & Y_{2n} \\ \vdots & \vdots & & \vdots & & \vdots \\ Y_{k1} & Y_{k2} & \dots & Y_{kk} & \dots & Y_{kn} \\ \vdots & \vdots & & \vdots & & \vdots \\ Y_{n1} & Y_{n2} & \dots & Y_{nk} & \dots & Y_{nn} \end{bmatrix} \cdot \begin{bmatrix} E_1 \\ E_2 \\ \vdots \\ E_k \\ \vdots \\ E_n \end{bmatrix} \quad (2.5)$$

donde:

$$Y_{kk} = \sum_{m=0 \neq k}^n y_{km} = \text{admitancia propia del nudo } k$$

$$Y_{km} = -y_{km} = \text{admitancia mutua entre los nudos } k \text{ y } m$$

Podemos escribir la ecuación(2.5) en forma vectorial como:

$$I_k = \sum_{m=1}^N Y_{km} E_m \quad \forall k \in \{1, \dots, n\} \quad (2.6)$$

La potencia que entra en una barra está dada por [Ste88]:

$$S_k = P_k + jQ_k = E_k I_k^h = E_k \sum_{m=1}^n Y_{km}^h E_m^h \quad (2.7)$$

donde:

$$I_k^h = \text{Complejo conjugado de } I_k$$

$$Y_k^h = \text{Complejo conjugado de } Y_k$$

$$E_k^h = \text{Complejo conjugado de } E_k$$

Desarrollando la expresión 2.7 en coordenadas polares y separando las partes real e imaginaria tendremos [GBF⁺06]:

$$P_k = \sum_{m=1}^N V_k V_m (G_{km} \cos \theta_{km} + \sigma_{km} \sin \theta_{km}) \quad (2.8)$$

$$Q_k = \sum_{m=1}^N V_k V_m (G_{km} \sin \theta_{km} - \sigma_{km} \cos \theta_{km}) \quad (2.9)$$

donde:

$$V_k = \text{módulo de la tensión } E_k$$

$$\theta_k = \text{módulo de la tensión } E_k$$

$$\theta_{km} = \theta_k - \theta_m, \text{ diferencia de fase entre los nodos } k \text{ y } m$$

$$G_{km} = \text{conductancia entre las barras } k \text{ y } m$$

$$\sigma_{km} = \text{susceptancia entre las barras } k \text{ y } m$$

$$Y_{km} = G_{km} + j\sigma_{km}$$

2. Conceptos Básicos e Introducción al Flujo de Potencia Óptimo

Con estos conceptos básicos en mente se puede dar una definición analítica al problema del flujo de potencia [SC95].

2.5.2 Definición analítica del problema del Flujo de Potencia

La completa definición del flujo de carga o flujo de potencia requiere el conocimiento de cuatro variables en cada barra k del sistema [Arr83]:

$$\begin{aligned} P_k & \text{ potencia activa} \\ Q_k & \text{ potencia reactiva} \\ V_k & \text{ módulo de la tensión } E_k \\ \theta_k & \text{ fase de la tensión } E_k \end{aligned}$$

Solo son conocidas *a priori* dos variables en cada barra, y la finalidad del estudio del flujo de carga es resolver las ecuaciones para las dos variables restantes en cada barra. Se define a continuación una clasificación de las barras en base al tipo de especificación de las mismas, es decir, cuales variables son conocidas de antemano:

- Barra PV o de tensión controlada. La potencia activa total inyectada P_k es especificada, y la magnitud de la tensión es mantenida a un valor determinado mediante la inyección de potencia reactiva. Este tipo de barra generalmente corresponde a un generador, donde P_k es fijada por los reguladores de caudal turbinado, y V_k es fijada por los reguladores automáticos de tensión actuando en la excitación de la máquina; o bien a una barra donde la magnitud de la tensión es fijada por inyección de potencia reactiva mediante capacitores estáticos o compensadores rotativos síncronos, por ejemplo, una sub-estación.
- Barra PQ o de tensión no controlada. La potencia total inyectada, $P_k + jQ_k$, es especificada en esta barra. En un sistema de potencia corresponde a un centro de consumo de carga, como una ciudad o una industria, donde la potencia demandada está determinada por los requerimientos de los consumidores. Tanto P_k como Q_k se suponen invariables con pequeñas alteraciones de la tensión en la barra.
- Barra Slack o barra oscilante. Es necesaria para el estudio del flujo de cargas, a raíz de que las pérdidas en el sistema son desconocidas de antemano. Por consiguiente, la potencia inyectada no puede ser especificada en todas las barras. Es usual elegir una de las barras PV disponibles como slack, y considerar su potencia activa como desconocida. A la fase de la barra slack usualmente se la designa como de referencia del sistema. En la práctica, corresponde a una estación generadora que tiene la responsabilidad de controlar la frecuencia de la red.

2.5.3 Métodos de solución

La complejidad que presenta la obtención de una solución formal del problema de las cargas en una red de energía, radica en las diferencias en el tipo de datos especificados

para las distintas barras del sistema. Aunque no es difícil la formulación del número suficiente de ecuaciones, no es práctico obtener una solución analítica. La resolución de los problemas de carga por métodos numéricos sigue un proceso iterativo, asignando valores estimados en las barras a las tensiones desconocidas, y recalculando las tensiones en cada una de las barras a partir de los valores estimados en las otras y de las potencias real y reactiva [SC95].

De esta manera, se obtiene un nuevo conjunto de tensiones en las barras, que se emplea para calcular otro, y así sucesivamente; cada cálculo de un nuevo conjunto de tensiones se llama iteración. El proceso iterativo se repite hasta que los cambios en cada barra sean menores que un valor mínimo especificado [Ste88].

Existen varios métodos iterativos que pueden ser aplicados a la resolución del flujo de potencia, entre los cuales se puede citar:

- Método Gauss-Seidel
- Método de Newton-Raphson
- Métodos desacoplados derivados del método de Newton-Raphson

2.5.4 Flujo de Potencia Óptimo

El Flujo de Potencia Óptimo OPF (*Optimal Power Flow*) tiene como objetivo la optimización de la condición estática de operación de un EPS. Se usa el término optimización en el sentido de maximizar o minimizar un determinado objetivo, sujeto a algunas restricciones [Ste88].

En comparación con el Flujo de Potencia, el OPF es una herramienta de síntesis mientras que el *LF* se utiliza en el análisis [Fal98]. Como ya se ha explicado el flujo de potencia es la herramienta que da la solución de la red eléctrica para una determinada condición de operación, mientras que con el *OPF* se escoge, entre las infinitas condiciones de operación posibles para atender la demanda, una que optimice el objetivo seleccionado, siendo algunos de ellos: desvío mínimo del punto de operación, minimización de pérdidas de energía y mínimo corte de carga.

2.5.4.1 Aplicaciones

El OPF tiene aplicación en varios problemas de planificación de expansión, operación y operación en tiempo-real, tales como [Ste88]:

- Despacho económico y seguro (operación en tiempo-real, simulación del despacho en estudios de planificación de expansión);
- Redespacho preventivo y correctivo (operación en tiempo-real);
- Minimización de pérdidas;
- Ubicación de fuentes de potencia reactiva (planificación de expansión del soporte de reactivos);

- Evaluación de la confiabilidad de sistemas compuestos de generación transmisión;
- Planificación de la expansión de sistemas de transmisión;
- Tarifación de servicios de transmisión.

2.5.4.2 Formulación matemática

La naturaleza del problema *OPF* se basa en que la demanda es, en general, considerada conocida y constante. La mejor manera de atender esa demanda se obtiene al resolver el problema de *OPF*.

El *OPF* es formulado como un problema de Programación No-Lineal, de acuerdo con el siguiente formato patrón:

$$\text{minimizar } f(x) \tag{2.10}$$

$$\text{sujeto a : } e(x) \leq 0 \tag{2.11}$$

donde:

- $x \in \mathbb{R}^n$ es la variable de control o independiente;
- $f : \mathbb{R}^n \rightarrow \mathbb{R}$ es la función objetivo;
- $e : \mathbb{R}^n \rightarrow \mathbb{R}^m$ son las restricciones de desigualdad;

A continuación se da una definición detallada de las variables dependientes, variables independientes o de control, restricciones y funciones objetivo típicas de un problema *OPF*.

1. *Variables dependientes:* Las variables dependientes o de estado $u(x)$ son un conjunto mínimo de variables capaces de caracterizar completamente al estado de operación de la red. Corresponden a las variables que definen analíticamente al flujo de potencia en un estado dado de la red, véase la sección 2.5.2.
2. *Variables independientes:* Las variables independientes o de control (x) son las variables que llevan al proceso de OPF a una solución óptima. Físicamente, corresponden a dispositivos o procesos de control presentes en la red eléctrica. Las variables normalmente utilizadas son [Val02]:

- Flujo de Potencia Activa:
 - potencia activa generada;
 - ángulo de fase de transformadores desfasadores;
 - potencia transmitida en los alimentadores DC;
 - flujo de intercambio entre áreas (subestaciones).

2. Conceptos Básicos e Introducción al Flujo de Potencia Óptimo

- Flujo de Potencia Reactiva:
 - módulo de la tensión en barras de generación;
 - potencia reactiva generada o ubicada;
 - posición de los taps (derivaciones del bobinado) de transformadores;
 - susceptancia shunt (en derivación) de bancos de reactores (capacitores o inductores).

En el caso de una barra de generación, la variable de control asociada al flujo de potencia reactiva puede ser tanto el módulo de la tensión como la inyección de potencia reactiva. La selección de uno u otro depende del dispositivo de control presente en la barra y del método de solución adoptado.

Algunas variables de control solamente pueden asumir valores discretos, como los *taps* de transformadores, susceptancias *shunt* de bancos de reactores, etc. Cuando la variable de control utilizada en el *OPF* son las susceptancias *shunt* de bancos de reactores, el problema se conoce como *RPC* en *EPSs*.

3. *Restricciones de igualdad*: La solución del *OPF* corresponde a una solución del flujo de potencia. Es decir, debe satisfacer las restricciones que gobiernan el flujo de potencia, ver expresiones (2.7), (2.8) y (2.7).
4. *Restricciones de desigualdad*: Son inecuaciones que representan límites físicos relacionados con la capacidad térmica de transmisión de potencia de los componentes de la red o límites operacionales relacionados con aspectos de seguridad de operación del sistema de potencia. Las variables generalmente asociadas a esos límites, agrupadas de acuerdo a su mayor influencia en el flujo de potencia activa o reactiva, son listadas a continuación:

- Potencia activa generada;
 - ángulo de fase de transformadores desfasadores;
 - potencia transmitida en los alimentadores DC;
 - flujo de intercambio entre áreas (subestaciones).
- Flujo de Potencia Reactiva:
 - módulo de la tensión en barras de generación;
 - potencia reactiva generada o ubicada;
 - posición de los taps de transformadores;
 - susceptancia shunt de reactores.

5. *Funciones objetivos*: Se conocen como funciones objetivo a las características de los EPSs que se desean mejorar. Entre otras, estas características pueden ser [GBF⁺06]:

- Pérdidas Mínimas: esta función puede ser representada como la inyección de potencia activa en la barra slack, o como la sumatoria de las pérdidas activas

2. Conceptos Básicos e Introducción al Flujo de Potencia Óptimo

de todas las ramas de la red. Esta función representa las pérdidas por efecto Joule que tienen las líneas de transmisión y distribución de energía eléctrica.

- **Mínimo coste de ubicación de fuentes de reactivos:** Función objetivo utilizada para la planificación de la instalación de nuevas fuentes de potencia reactiva. El objetivo del problema es determinar la capacidad y lugar de ubicación de nuevas fuentes que cumplan con las restricciones de tensión del sistema con un mínimo costo.
- **Mínimo Corte de Carga:** Esta función objetivo se utiliza para resolver situaciones de emergencia en las cuales el corte de suministro de energía a una parte de la carga es la única solución posible para aliviar sobrecargas y evitar tensiones fuera del límite. Sin embargo el corte de carga debe ser mínimo y ponderado por la importancia de las cargas.
- **Desvío Mínimo del Punto de Operación:** Función que tiene por objetivo obtener una solución lo más próxima posible a un punto de operación previamente establecido por otro estudio como ser el de optimización energética.
- **Desvío Promedio del Punto de Operación:** Función que tiene por objetivo obtener una solución donde cada uno de los parámetros esté lo más próximo posible al punto de operación previamente establecido.

En este capítulo hemos introducidos los conceptos básicos de un Sistema Eléctrico de Potencia (EPS), hemos estudiados que la estructura funcional del mismo esta compuesta por tres elementos fundamentales: Generación, Transmisión y Distribución, siendo estos dos últimos los objetos principales de esta tesis. Para el estudio de estas dos fases se ha introducido el concepto de flujo de potencia, el cual constituye un aspecto fundamental para el problema de Compensación de Potencia Reactiva (RPC). Además, se ha desarrollado la formulación matemática del Flujo de Potencia Óptimo, el cual es aplicado en los diferentes métodos que serán estudiados en los siguientes capítulos.

Capítulo 3

Optimización Multi-Objetivo

En el presente capítulo primeramente se denotan las definiciones formales del problema de optimización multi-objetivo. Además, se mencionan algunas técnicas tradicionales de búsqueda utilizadas en la actualidad para la resolución de problemas con varios objetivos. Los conceptos presentados son tomados de: [PMB06], [LPB08].

3.1 Conceptos y Terminología

La optimización multi-objetivo puede ser definida como el problema de encontrar un vector de variables de decisión que satisfacen restricciones y optimiza un vector de funciones cuyos elementos representan las funciones objetivo. Estas definiciones aparecen en los trabajos de Coello [Coe99] y Deb [Deb99a].

La mayoría de los problemas de ingeniería por naturaleza son multi-objetivos, porque normalmente poseen varios objetivos, posiblemente en conflicto o contrapuestos, equis importantes a tener en cuenta a la hora de resolver el problema global. La noción de óptimo ha sido redefinida en este contexto y es así que en vez de tratar de encontrar una solución única, lo que se busca es una buena serie de soluciones de compromiso a partir de las cuales el encargado de tomar las decisiones puede seleccionar una que se ajuste a sus necesidades de diseño.

En los problemas de optimización con objetivo único, el espacio de búsqueda se encuentra totalmente ordenado por medio de la función objetivo por lo que es posible hablar de un óptimo global, el cual es descrito formalmente en la siguiente definición [Van]. Posteriormente se da la definición formal MOP (*Multi-Objective Optimization Problem*) adoptada en este trabajo [Van] y [ZE99].

Definición 1. Óptimo global (mono-objetivo): Dada una función $f : \mathbb{R}^n \rightarrow \mathbb{R}$, para $x \in \mathbb{R}^n$, el valor $f^* = f(x^*)$ es llamado un óptimo global (máximo o mínimo) si y solo si:

$$\forall x \in \mathbb{R}^n : \text{es mejor que } f(x) \quad (3.1)$$

Así, tenemos que x^* es la solución global óptima, y f es la función objetivo. Entonces, cuando se tiene un único objetivo, el proceso de optimización se reduce a hallar el máximo o el mínimo valor de una función. El problema de determinar la solución óptima global es llamado problema de optimización global.

Definición 2: (Problema de Optimización Multi-objetivo): Un MOP general consiste de un conjunto de n parámetros (variables de decisión), un conjunto de k funciones objetivos, y un conjunto de m restricciones. Las funciones objetivo y las restricciones son funciones de las variables de decisión. Luego, el MOP puede expresarse como:

Optimizar

$$y = f(x) = (f_1(x), f_2(x), \dots, f_k(x)) \quad (3.2)$$

sujeto a:

$$e(x) = (e_1(x), e_2(x), \dots, e_m(x)) \geq 0 \quad (3.3)$$

donde:

$$\begin{aligned} x &= (x_1, x_2, \dots, x_n) \in X \subseteq \mathbb{R}^n \\ y &= (y_1, y_2, \dots, y_k) \in Y \subseteq \mathbb{R}^k \end{aligned}$$

x es un *vector de decisión n -dimensional*, X denota el espacio de decisión, y es un *vector objetivo k -dimensional*, e Y denota el espacio objetivo. Optimizar, dependiendo del problema, puede significar igualmente, minimizar o maximizar. El conjunto de restricciones $e(x) \geq 0$ determina el conjunto de soluciones factibles X_f y su correspondiente conjunto de vectores objetivo factibles Y_f .

Definición 3: (Conjunto de soluciones factibles): El conjunto de soluciones factibles X_f se define como el conjunto de vectores de decisión que satisface $e(x)$. El conjunto de soluciones factibles X_f se define como el conjunto de vectores de decisión x que satisface $e(x) \geq 0$:

$$X_f = \{x \in X | e(x) \geq 0\} \quad (3.4)$$

La imagen de X_f , es decir, la región factible del espacio objetivo, se denota por

$$Y_f = f(X_f) = \{y = f(x) | \forall x \in X_f\} \quad (3.5)$$

De estas definiciones se tiene que cada solución del MOP en cuestión consiste de una n -tupla $x = (x_1, x_2, \dots, x_n)$, que determina, un vector objetivo $y = (f_1(x), f_2(x), \dots, f_k(x))$, donde cada x debe cumplir con el conjunto de restricciones $e(x) \geq 0$.

Como se ha mencionado en la *definición 1*, en optimización con un solo objetivo, el conjunto de variables de decisión factibles está completamente ordenado de acuerdo al valor de la función objetivo. Esto es, dadas dos soluciones u y v en el espacio de soluciones factibles, se cumple solo una de las siguientes proposiciones: $f(u) > f(v)$, $f(u) = f(v)$ o $f(u) < f(v)$.

Sin embargo en un contexto multi-objetivo no existe un único mejor valor, sino un conjunto de “*mejores soluciones*”. Entre éstas, ninguna solución se puede considerar mejor que las demás si se tienen en cuenta todos los objetivos simultáneamente. De este hecho se deriva que pueden existir y generalmente existen conflictos entre los diferentes objetivos que componen al problema, i.e., la optimización de algún objetivo implica la degradación de algún otro objetivo. Por ende, al tratar con MOPs se precisa de un nuevo concepto de “*óptimo*”. La noción más aceptada de óptimo en problemas multi-objetivo es aquella introducida por el Economista Vilfredo Pareto en 1896.

Antes de entrar al concepto de dominancia Pareto se debe comprender las relaciones matemáticas que se definen a continuación. Esto se puede realizar de la siguiente manera:

Definición 4: (Extensión de las relaciones) Dados dos vectores de decisión $u, v \in X$

$$f(u) = f(v) \text{ si y solo si } f_i(u) = f_i(v) \forall i \in 1, 2, \dots, k$$

$$f(u) \leq f(v) \text{ si y solo si } f_i(u) \leq f_i(v) \forall i \in 1, 2, \dots, k$$

$$f(u) < f(v) \text{ si y solo si } f_i(u) \leq f_i(v) \wedge \exists i f_i(u) \neq f_i(v)$$

Definición 5. (Dominancia Pareto): Sean dos vectores de decisiones $u, v \in X_f$. Se dice que u domina v (denotado como $u \succ v$) si es mejor o igual que v en cada uno de los objetivos y estrictamente mejor en al menos un objetivo. Esto es,

$$\forall i \in \{1, 2, \dots, k\} : f_i(u) \text{ es mejor o igual que } f_i(v) \quad (3.6)$$

$$\wedge \exists j \in \{1, 2, \dots, k\} : f_j(u) \text{ es estrictamente menor que } f_j(v)$$

Note que la definición anterior de dominancia Pareto es independiente de que se trate de minimizaciones, maximizaciones o combinaciones de estas.

Definición 6. (Vectores no comparables): Dados dos vectores $u, v \in X_f$ decimos que u y v son no comparables, si y solo si $u \not\prec v \wedge v \not\prec u \wedge u \neq v$.

En este caso, ni u es mejor que v , ni v puede ser considerado mejor que u . Si bien los vectores u y v no son estrictamente iguales, ambas soluciones pueden ser consideradas igualmente buenas debido a que ninguna es superior a la otra cuando consideramos todos los objetivos en forma simultánea. Se dice entonces que el vector u es no comparable al vector v y se lo denota como $u \sim v$. Alternativamente, $u \succ v$ denota que u domina o es no comparable con v .

Definido el concepto de dominancia Pareto, puede ser introducido el criterio de optimalidad Pareto, el cual es descrito a continuación:

Definición 7. (Optimalidad Pareto): Dado un vector de decisión $x \in X_f$, se dice que x es no dominado respecto a un conjunto $Q \subseteq X_f$ si y solo si:

$$\forall v \in Q : (x \succ v) \quad (3.7)$$

En caso que x sea no dominado respecto a todo el conjunto X_f , y solo en ese caso, se dice que x es una solución pareto óptima. Por lo tanto, el conjunto pareto óptimo P^* puede ser definido formalmente como:

Definición 8. (Conjunto pareto óptimo y frente pareto óptimo): Dado el conjunto de vectores de decisión factibles X_f , se denomina conjunto pareto óptimo P^* al conjunto de vectores de decisión no dominados que pertenecen a X_f , es decir:

$$P^* = \{x \in X_f \mid x \text{ es no dominado con respecto a } X_f\} \quad (3.8)$$

El correspondiente conjunto de vectores objetivos $P_{true} = f(P^*)$ constituye el frente pareto óptimo

3.2 Búsqueda y Toma de Decisiones

Se pueden distinguir dos niveles de dificultad al resolver un problema de optimización multiobjetivo: la búsqueda y la toma de decisiones [Hor97]. El primer aspecto se refiere al proceso de optimización, durante el cual se explora el espacio de soluciones factibles buscando las soluciones Pareto óptimas. El segundo aspecto es equivalente a seleccionar un conjunto o una única solución de compromiso del conjunto Pareto óptimo encontrado en el proceso anterior. Este paso generalmente tiene que ver con cuestiones inherentes a las condiciones del problema y los recursos disponibles.

Los métodos de optimización multi-objetivo pueden clasificarse en tres categorías diferentes dependiendo de la manera en que se combinan ambas fases:

- Toma de decisión previa a la búsqueda (decidir, luego buscar): los objetivos del MOP se combinan en un único objetivo que implícitamente incluye información de preferencia obtenida del responsable de la toma de decisiones. Estos son métodos de toma de decisión *a priori*, tales como la suma con pesos, orden lexicográfico, etc. Gran parte de las técnicas tradicionales para resolución de MOP utilizan esta estrategia [Ste86].
- Búsqueda previa a la toma de decisión (buscar, luego decidir): se realiza la optimización sin incluir información de preferencia. El responsable de la toma de decisiones escoge del conjunto de soluciones obtenidas (que idealmente son todas del conjunto Pareto óptimo). A estos se conocen como métodos de toma de decisión *a posteriori*. Ejemplos: la optimización con algoritmos evolutivos y colonia de hormigas.
- Toma de decisión durante la búsqueda (decidir mientras se busca): esto permite que quien toma las decisiones pueda establecer preferencias durante un proceso de optimización interactivo. Luego de llevarse a cabo cada paso del proceso de optimización, se presenta al responsable de decisiones los conflictos existentes y se le permite especificar sus preferencias o compromisos. De esta manera se desarrolla una búsqueda guiada. Estos métodos reciben el nombre de progresivos o interactivos.

Combinar múltiples objetivos en un único objetivo a optimizar, posee la ventaja de que a la función resultante se puede aplicar cualquiera de los métodos de optimización de un único objetivo ya disponibles en la literatura [Steuer1986], sin mayores modificaciones. No obstante, tal combinación requiere conocimiento del dominio del problema que no siempre está disponible. En los problemas de diseño de diversas aéreas de ingeniería, se realiza la búsqueda justamente para tener un mejor conocimiento del espacio de búsqueda del problema y de las soluciones alternativas. Al realizar la búsqueda antes de la toma de decisión no se requiere este conocimiento, pero se impide que quien toma la decisión exprese previamente sus preferencias, lo que probablemente conduce a una reducción de la complejidad del espacio de búsqueda. El presente trabajo está enfocado en técnicas que han demostrado ser capaces de explorar espacios de búsquedas prácticamente ilimitados y altamente complejos y generar aproximaciones al conjunto Pareto óptimo.

3.3 Métodos tradicionales de optimización

3.3.1 El método de suma con pesos

En este método las funciones objetivo del problema de optimización multi-objetivo son combinadas utilizando diferentes coeficientes de peso para formar una función general a ser optimizada. Esto implica que un problema de optimización con objetivos múltiples.

Optimizar

$$y = f(x) = (f_1(x), f_2(x), \dots, f_k(x)) \quad (3.9)$$

sujeto a:

$$e(x) = (e_1(x), e_2(x), \dots, e_k(x)) \geq 0 \quad (3.10)$$

se transforma en un problema de optimización de la forma:

Optimizar

$$y = f(x) = \left(\sum_{i=1}^k w_i \cdot f_i(x) \right) \quad (3.11)$$

sujeto a:

$$e(x) = (e_1(x), e_2(x), \dots, e_k(x)) \geq 0$$

donde $x \in X_f$ y w_i es el peso usado para ponderar la i -ésima función objetivo. Usualmente, y sin pérdida de generalidad, se escogen pesos fraccionarios y diferentes de cero, de manera a cumplir la condición de normalización: $\sum_{i=1}^k w_i = 1$, $w_i \geq 0$ [Don04].

Si bien no se adecuan a la naturaleza del problema, la ventaja principal del método de suma con pesos es que permite la utilización de algoritmos desarrollados para la resolución de problemas de optimización mono-objetivos (Single-objective Optimization Problems - SOPs) bien conocidos y de probada eficacia, aun cuando se trate de problemas reales de gran tamaño. Para problemas de gran escala, muy pocas técnicas de optimización multi-objetivo reales se han presentado [Hor97], a diferencia de técnicas de optimización de un solo objetivo que han existido desde hace bastante tiempo y han sido probadas en diferentes situaciones. Sin embargo, este método cuenta con las siguientes limitaciones [Deb99b]:

- El algoritmo de optimización se debe aplicar varias veces para encontrar las múltiples soluciones Pareto optimas. Como cada corrida es independiente de las demás, generalmente no se obtiene un efecto sinérgico. Por lo tanto, delinear el frente Pareto óptimo resulta computacionalmente muy caro.
- Requiere conocimiento previo del problema a resolver y es sensible a los pesos utilizados.
- Algunos algoritmos son sensibles a la forma del frente Pareto (problemas con curvas cóncavas).
- La variación entre las diferentes soluciones encontradas depende de la eficiencia del optimizador de un solo objetivo. Podría darse el caso de encontrar siempre la misma solución o soluciones muy parecidas, en corridas múltiples.

3.3.2 Ordenamiento Lexicográfico

El método de orden lexicográfico se basa en la asignación de prioridades *a priori* a cada uno de los objetivos a optimizar. El objetivo que posee la mayor prioridad es utilizado para realizar el orden, si ocurre un empate el siguiente objetivo de mayor prioridad es comparado, y así sucesivamente. Todos los objetivos $f_1, \dots, f_k$ son ordenados en orden creciente de prioridad. Esta técnica es recomendable cuando se conoce perfectamente el orden de importancia de los objetivos, porque el desempeño del algoritmo depende en gran medida de dicho ordenamiento [Lan02].

En el presente capítulo se ha dado la definición formal de un problema de optimización multi-objetivo y se han definido términos y conceptos que serán utilizados en los posteriores capítulos

En el presente capítulo, primeramente se ha introducido las definiciones formales del problema de optimización multi-objetivo. Además, se han mencionados algunas técnicas tradicionales de búsquedas utilizadas en la actualidad para la resolución de problemas con varios objetivos. Dados los conceptos básicos de un Sistema Eléctrico de Potencia y Optimización Multi-objetivo, en el siguiente capítulo nos ocuparemos de la formulación matemática del Problema de Compensación de Potencia Reactiva.

Capítulo 4

Formulación del problema considerado

El problema de compensación de potencia reactiva es considerado en este trabajo como un Problema de Optimización Multiobjetivo con las siguientes funciones objetivos a optimizar:

1. Inversión en bancos de compensación de potencia reactiva.
2. Desviación promedio de tensión.
3. Máxima desviación de tensión.

En base a la definición general de un problema multiobjetivo presentada en el capítulo anterior, a continuación se formula matemáticamente el problema de Compensación de Potencia Reactiva (RPC) como un MOP. Posteriormente se describe brevemente varios métodos de optimización aplicados al *EPS*.

4.1 Formulación Matemática del Problema de Compensación de Potencia Reactiva

El estudio del sub-problema de OPF llamado Compensación de Potencia Reactiva, RPC, cumple un papel muy importante en la planificación de la expansión y operación de EPS. Los estudios indican que, en promedio, más del 13% de la energía total producida es consumida por las pérdidas de potencial eléctrico $I^2 \cdot R$ en la zona de distribución [Bun82], [GBF⁺06], siendo que las corrientes reactivas son responsables por parte de esas pérdidas. Por este motivo, bancos de capacitores y/o reactores *Shunt* son comúnmente instalados en las adyacencias de los alimentadores en redes de transmisión y distribución para proveer así potencia reactiva en los puntos en que es necesaria, disminuyendo la necesidad de transportarlas a través de la red eléctrica. Esto resulta en varias ventajas como [ABB05], [Kun93]:

4. Formulación del problema considerado

- Reducción de las pérdidas de transmisión;
- Mejora del factor de potencia;
- Incremento de la capacidad de transmisión;
- Mejor control de voltaje;
- Mejora de la calidad del servicio.

La concreción de estas metas depende de la adecuada ubicación y dimensionamiento de bancos de capacitores y/o reactores *Shunt*. Expuesto de esta forma, el problema de RPC en EPS puede ser formulado como la determinación del tamaño adecuado y la distribución física de los elementos de compensación para asegurar un perfil satisfactorio de tensión mientras minimiza el costo de compensación, buscando además: [Kun93]

Minimización de las pérdidas de transmisión: las pérdidas de potencia activa en la transmisión pueden traducirse directamente en costos monetarios, ya que consiste en la diferencia entre la potencia generada y la potencia servida.

Minimización de cantidad y capacidad de fuentes de reactivos instaladas: aunque la instalación de bancos de capacitores y/o reactores *Shunt* provee la forma más económica de generar potencia reactiva para controlar el voltaje, el exceso de la utilización de estos dispositivos conduce a la reducción de la estabilidad del sistema y a una pobre regulación del perfil de tensiones, además del costos que implican los dispositivos en sí y su instalación;

Buen perfil de tensiones: la calidad de la potencia servida está relacionada directamente por la diferencia entre la tensión efectiva y la tensión nominal de los alimentadores.

Para la formulación matemática del problema se hicieron las siguientes consideraciones:

- Se analizó solamente el valor pico de potencia demandada;
- Se consideró el tamaño de los bancos de reactores como variables discretas debido a que solo se fabrican bancos de potencia normalizados por la industria [ABB05];
- Se consideró el costo de los bancos como unitario e independiente de la ubicación;
- Se limitó el valor de los bancos de reactivos, tanto para el caso capacitivo como inductivo.

4. Formulación del problema considerado

En base a estos puntos se identificaron tres funciones objetivos a ser minimizadas: un objetivo f_1 relacionado al aspecto económico de la inversión en los dispositivos de compensación, el segundo objetivo f_2 relativo a la calidad del servicio que normalmente es tratado como una restricción operativa de los EPS y el tercer objetivo f_3 relativo a la calidad del servicio en cada barra. Así, las funciones objetivo consideradas son:

4.1.1 Minimización de la inversión en dispositivos de compensación de potencia reactiva

Función objetivo utilizada para la planificación de la instalación de nuevas fuentes de potencia reactiva. Su formulación es la siguiente:

$$\min f_1 = \sum_{i=1}^n |b_i| \quad (4.1)$$

sujeto a las siguientes restricciones :

$$\begin{aligned} f_1 &\leq f_1^m \\ |b_i| &\leq |b_i^m| \end{aligned}$$

Donde f_1 es la inversión total requerida; f_1^m es la máxima inversión disponible para todo el sistema; $|b_i|$ es la compensación en la barra i medida en MVA; $|b_i^m|$ es el máximo valor absoluto de compensación reactiva posible para dicha barra del sistema y n es el número de barras en el sistema. Conocido el costo de las fuentes de reactivos por MVA de potencia, esta función objetivo se puede interpretar fácilmente como el costo financiero de inversiones en fuentes de reactivos.

4.1.2 Minimización de la desviación promedio de voltaje

El objetivo de esta función es obtener una solución donde las tensiones de barras estén lo más próximo posible a la tensión de operación ideal previamente establecida. Puede ser definida de la siguiente manera:

$$\min f_2 = \frac{\sum_{i=1}^n |v_i^* - v_i|}{n} \quad (4.2)$$

donde f_2 es el promedio de la desviación de voltaje, v_i el voltaje efectivo obtenido en la barra i y v_i^* el voltaje deseado en dicha barra. Esta segunda función puede ser considerada como un objetivo técnico que mide la calidad de una solución; es decir, que tan conveniente sería ubicar una determinada distribución de reactivos en la red.

4.1.3 Minimización de la máxima desviación de voltaje

El objetivo de esta función es asegurar que el voltaje en todas las barras esté dentro de los límites aceptables de la configuración del sistema. Se puede definir de la siguiente manera:

$$\min f_3 = \max |v_i^* - v_i| \quad (4.3)$$

Donde f_3 es la máxima desviación de voltaje, v_i el voltaje efectivo obtenido en la barra i y v_i^* el voltaje deseado en dicha barra. Esta tercera función se puede considerar como el complemento de la función f_2 y su finalidad es evitar los picos de desviación de voltajes muy altos en cada barra, los cuales pueden darse aún cuando el promedio de desviación de voltaje se encuentra en el rango aceptado.

4.2 Formulación como problema Multi-Objetivo

Se define a la variable de decisión como el vector de ubicación de fuentes de reactivos en cada barra según:

$$B = [b_1, b_2, b_3, \dots, b_n] \quad (4.4)$$

donde cada b_i representa la compensación en MVA ubicada en la barra i . El valor de b_i , está limitado por los valores máximos de compensación tanto inductiva como capacitiva. Esto puede expresarse como:

$$b_{iI}^m \leq b_i \leq b_{iC}^m \quad (4.5)$$

donde b_{iI}^m y b_{iC}^m corresponden a los máximos valores de compensación inductiva y capacitiva respectivamente. Por convención los bancos de características inductivas tienen valores negativos y los de características capacitivas valores positivos. Para el presente trabajo se consideró el mismo valor absoluto para la máxima compensación capacitiva e inductiva para todas las barras; en futuros trabajos podrían fijarse valores diferentes para distintas barras de acuerdo a las características de tensión o carga de las mismas. Por lo tanto, la cantidad de posibles compensaciones consideradas, denotado por c , para cada barra es la misma. Este valor c depende del valor de la máxima compensación admisible y del nivel de discretización usado, es decir, de la cantidad de valores diferentes que se considera para compensar una barra determinada. Como ya se expresó, se consideró el nivel de discretización unitario, o sea, que los bancos pueden tomar todos los valores enteros entre b_{iI}^m y b_{iC}^m .

El problema hasta aquí descrito formalmente se formula como un MOP así:

$$\min F(B) = [f_1, f_2, f_3] \quad (4.6)$$

4. Formulación del problema considerado

Las restricciones corresponden a las propias del flujo de potencia de acuerdo a las expresiones (2.7), (2.8) y (2.9); y a las restricciones impuestas al primer objetivo de minimización de la inversión y pueden ser formuladas así:

sujeto a las siguientes restricciones :

$$\begin{bmatrix} P_k = \sum_{m=1}^n V_k V_m (G_{km} \cos \theta_{km} + \sigma_{km} \sin \theta_{km}) \\ P_k = \sum_{m=1}^n V_k V_m (G_{km} \sin \theta_{km} - \sigma_{km} \cos \theta_{km}) \\ f_1 \leq f_1^n \\ |b_i| \leq |b_i^n| \end{bmatrix} \quad (4.7)$$

Nótese que como las funciones objetivo tienen unidades de medidas muy diferentes, i.e. f_1 se mide en MVar, f_2 y f_3 en el sistema por unidad (*per-unit, pu*), resulta muy difícil en la práctica hacer una combinación lineal de ellos para combinarlos en un solo objetivo. Este inconveniente no se presenta en la optimización multiobjetivo pues todos los objetivos son optimizados simultáneamente.

Para concluir se muestra en la figura 4.1 un ejemplo de una solución al RPC, o distribución de bancos de reactivos, para una red de cuatro barras. El vector de decisión que corresponde al ejemplo es $B = [3, -4, 5, 0]$. Como se observa en el gráfico, este vector indica que la primera barra tiene un banco de capacitores de 3MVar, la segunda barra un reactor de 4 MVar, la tercera un banco de capacitores de 5MVar y la última barra no está compensada.




Figura 4.1: Ejemplo de distribución de bancos Shunt en un EPS

4.3 Métodos de Optimización aplicados a los Sistemas Eléctricos de Potencia

A través de los años, diversos métodos de optimización matemática han sido utilizados para resolver distintos problemas de planificación, operación y control de EPS. Formulaciones matemáticas de problemas de tamaño real se simplifican utilizando ciertas acepciones pero aún con estas simplificaciones resolver problemas relacionados con los EPS de gran escala resulta una tarea extremadamente compleja. Las técnicas aplicadas para la resolución del RPC pueden ser clasificadas en cuatro metodologías según Ng *et al.* [Ng00]: Analítica, Programación Numérica, Heurística e Inteligencia Artificial. Más referencias en [GBF⁺06].

4.3.1 Métodos Analíticos

Los primeros trabajos sobre RPC utilizaban métodos analíticos. Dichos algoritmos eran desechados cuando los recursos computacionales eran insuficientes o muy caros. Los métodos analíticos utilizan el cálculo diferencial e integral para maximizar una función de ahorro con capacitores S , la cual puede ser formulada de la siguiente forma:

$$S = E_a + PP - \sum CC_B \quad (4.8)$$

donde E_a y PP representan la energía ahorrada y la potencia pico disminuida por medio de la ubicación de capacitores respectivamente y CC_B es el costo de la instalación de los capacitores. Varios son los trabajos que han utilizado estos métodos, entre los cuales Neagle y Samson [Nea56], Cook [Coo59], [Coo61], Schmill [Sch65], Chang [Cha69a], [Cha69b] Bae [Bae78], [Dwy92], [Dwy92], [Mar91], [CS], [Civ85], [GC85].

4.3.2 Métodos de Programación Numérica

Los métodos de programación numérica son técnicas iterativas utilizadas para maximizar (o minimizar) una función objetivo con las variables de decisión. El valor de las variables de decisión debe satisfacer además un conjunto de restricciones [GBF⁺06].

Existen una amplia variedad de técnicas de programación matemáticas bien elaboradas y estudiadas como son: programación lineal LP (Lineal Programming) [SB79], [OA90], [HG83]; método de las variaciones locales o método del punto interior IP (*Interior Point method*) [IG98], [VL93], [Gra94], [RJM96], [CM96], [MJ97], [PK92] y [SI94]; programación cuadrática QP (*Quadratic Programming*) [MJ94] y [NJ89], programación no lineal NLP (*NonLinear Programming*) [Ban05], [IS00] y [Tin67]; técnicas de descomposición, programación entera y programación entera mixta [AC00], [DN90], [Geo72], [PM85], [GPM88] y [MJ96]; programación dinámica DP (*Dynamic Programming*) [SY99], [Par90] [Dur68].

4.3.3 Métodos Metaheurísticos

Los métodos conocidos como heurísticas consisten en un conjunto de reglas empíricas desarrolladas por intuición, experiencia y juicios. Estos conjuntos de reglas heurísticas dan como resultado estrategias de búsqueda más rápidas y prácticas que aquellas basadas en la búsqueda exhaustiva y pueden llegar a obtener soluciones, si bien no óptimas globales, muy próximas a las óptimas con un alto nivel de confianza. A finales de los 80 métodos basados en técnicas heurísticas de búsqueda fueron introducidas para reducir las pérdidas de distribución por reconfiguración [SJHS88], [TT90]. Abdel-Salam *et al.* [TASH94], [SJHS88], [TT90] y [Car00].

4.4 Métodos basados en Inteligencia Artificial

A pesar del éxito de los algoritmos descriptos en las secciones previas, una gran cantidad de problemas relativos a los EPS aun permanecen sin poder ser resueltos completamente, en un sentido convencional. Debido a esto muchos investigadores han volcado su atención a las nuevas técnicas basadas en la Inteligencia Artificial y han desarrollado sus aplicaciones en ingeniería de potencia. En particular: Sistemas Expertos (KBS - Knowledge-Based Systems), Templado Simulado (SA - Simulated Annealing), Redes Neuronales (ANN - Artificial Neural Networks), Teoría de Conjuntos Difusos (FST - Fuzzy Set Theory) y Algoritmos Genéticos (GA - Genetic Algorithms.) han sido implementados para resolver diversos problemas relativos a los EPS [GBF⁺06].

4.4.1 Sistemas Expertos

Los ES (Expert System) consisten en una serie de reglas, hechos (conocimientos) y un motor de inferencia para simular el razonamiento lógico para resolver problemas que son tan complejos que requieren la pericia humana para su resolución. Las mayores ventajas de los ES [KW97a] son: a) son consistentes y estables; b) pueden ser fácilmente transformados o reproducidos y c) pueden ser fácilmente documentados, aplicaciones de los fueron presentados en [ZZ89], [BNJ92] y [For91], mas referencias en [GBF⁺06].

4.4.2 Redes Neuronales

Una red neuronal está constituida por neuronas artificiales interconectadas simulando el sistema nervioso del cerebro humano. Una ANN (Artificial Neural Network) típica consiste en un árbol compuesto por niveles: el nivel de entrada, uno o más niveles medios y el nivel de salida. La ANN acepta datos de entrada conocidos y minimiza la diferencia entre los datos de salida generados y los datos de salida conocidos. [VV93], [HH93], [Par91], [SN90], [SM94], [SY97a], [RA96] y [GR96].

4.4.3 Teoría de Conjuntos Difusos

El concepto de FST (Fuzzy Set Theory) fue introducido por Zadeh [ZAD65] en 1965 como una herramienta formal para lidiar con la incertidumbre y el error introducido en

el modelado de sistemas y fue utilizado para resolver problemas relativos a los EPS en 1979 [Ban05]. Las variables difusas son generadas por una función de membresía que asigna grados de membresía a un conjunto dado. Usualmente, los grados de membresía varían desde el cero (no) hasta el uno (miembro) [Zad65], [PS91], [SY97b], [SY98] y [Y.H99].

4.4.4 Templado Simulado

El Templado Simulado es un algoritmo iterativo de optimización que se basa en el proceso de templado. Cuando un material se temple, es calentado hasta que alcanza una alta temperatura y luego es enfriado lentamente de acuerdo a un proceso de enfriamiento predefinido que permite obtener una configuración cristalina que cumple con determinados requisitos. Con elevadas temperaturas, las moléculas de los materiales se ubican en formaciones aleatorias. Cuando el material se enfría, las moléculas se organizan en formaciones que corresponden a estados de mínima energía interna. Algunas aplicaciones de SA a los EPS [GR97] y [RR96], [AU95], [MA98] y [YH97].

4.4.5 Búsqueda Tabú

La búsqueda Tabú (TS - Tabú Search) es un procedimiento de mejora iterativa que empieza con una solución inicial e intenta determinar una mejor solución en el vecindario factible de la solución inicial. La búsqueda tabú, incluye una memoria que almacena los últimos movimientos realizados, y que se usa para no volver a caer en los mismos mínimos locales, a esta memoria se le denomina lista tabú. Pero también tiene un método que permite escapar de los máximos locales, que se denomina nivel de aspiración; consiste en un criterio para aceptar movimientos incluidos en la lista tabú. Publicaciones sobre TS [GL97], [GLTW93], [Glo89] y [Glo90].

4.4.6 Optimización por Colonia de Hormigas (ACO)

Dorigo introdujo este algoritmo de optimización conocido inicialmente como ACS (Ant Colony System) [Dor92]. Estas técnicas toman su inspiración del comportamiento de búsqueda de alimentos de las hormigas reales, para resolver complejos problemas combinatoriales. Entre algunas de las publicaciones que abordan el EPS, programación de generación a corto plazo [LS04], flujo optimo de potencia [BT05]. Específicamente, el RPC ha sido tratado en [LZh03] y en [FGBE05] y [GBF⁺06].

Debido a que el aporte de esta tesis consiste en una aplicación de este tipo de algoritmo al RPC una descripción detallada de la Optimización por Colonia de Hormiga se deja para el próximo capítulo, así como la correspondiente explicación del método propuesto.

4.4.7 Optimización por enjambres de partículas

Otra técnica que está inspirada en las reglas que siguen las manadas de animales, o las bandadas de pájaros es la llamada optimización por enjambres de partículas o PSO

(Particle Swarm Optimization). Fue desarrollada por el Dr. Eberhart y Dr. Kennedy en 1995 [Ebe95]. Esta técnica trata de representar las diferentes soluciones a un problema mediante “individuos” de una manada. Cada individuo tiene unas coordenadas en el espacio del problema, así como un valor de evaluación. Las partículas, tomando diferentes caminos, tratan de dirigirse hacia la mejor partícula del grupo, teniendo también en cuenta el mejor valor obtenido por las partículas en la vecindad de cada una. Algunas aplicaciones de PSO a los EPS pueden ser encontradas en [Esm05] y [DMS05].

4.4.8 Algoritmos Genéticos

Los GA son técnicas inspiradas en la evolución biológica creadas para intentar descubrir una serie de puntos del espacio de búsqueda muy próximos al óptimo. Son algoritmos de optimización de propósito general que se distinguen de las técnicas de optimización tradicionales por el uso del concepto de población genética para guiar el proceso de optimización. En lugar de la búsqueda de punto a punto de las técnicas tradicionales los GA realizan la búsqueda de población a población. EPS fueron abordados en [Boo], [SS94], [WQ95], [Ma95], [LKSC], [DM00], [Bar01a], [Bar01b], [Bar01c] y [GBF⁺06] utilizando las técnicas de GA.

4.5 Técnicas híbridas de Inteligencia Artificial

Los verdaderos problemas de los EPS pueden ser muy complejos para un paradigma en particular, debido a esto muchos investigadores han decidido integrar dos o más técnicas para lidiar con esta complejidad [KW97a]. Algunos de los trabajos que aplicaron las técnicas híbridas a los EPS [GBF⁺06]: [RA97], [SD94], [SY97c], [DA91], [AA00], [KW97b], [Bar01a], [Bar01b] y [Bar01c].

En este capítulo hemos desarrollado la formulación matemática del Problema de Compensación de Potencia Reactiva (RPC), en base a la definición general de un problema multi-objetivo presentada en el capítulo anterior. Finalmente hemos descrito brevemente varios métodos de optimización aplicados al EPS, resaltando de entre los cuales el método de Optimización por Colonia de Hormigas (ACO), el cual será desarrollado de forma extensa en el siguiente capítulo.

Capítulo 5

Optimización basada en colonia de hormigas

A partir de los 90, la comunidad científica comenzó a analizar el comportamiento de insectos en busca de ideas que puedan ser utilizadas como meta-heurísticas. Muchos aspectos de las actividades colectivas de los insectos sociales, como las hormigas, son auto-organizadas (*self-organizing*), lo que significa que un comportamiento grupal complejo emerge de la interacción de individuos que poseen un comportamiento muy simple. El ejemplo de esta situación, en el caso de los insectos, es la búsqueda de alimentos y la construcción de nidos [PMB06].

Los resultados de esta auto-organización son globales (se deben a la colonia) por naturaleza, y se fundamentan en interacciones basadas enteramente en información local. Estas interacciones pueden ser directas (vía contacto físico, visual o químico) o indirectas. El contacto indirecto se caracteriza por un concepto que será explicado más adelante “Estimergia”, que básicamente se refiere a que un individuo realiza una acción basada en las acciones realizadas anteriormente por otros individuos [PMB06].

En la década de los 90 surgió un nuevo método, conocido como optimización por colonia de hormigas (ACO), exitosamente utilizado en la resolución de varios problemas combinatorios mono-objetivo. ACO es una meta-heurística basada en algunos comportamientos de la colonia de hormigas reales [DM99]. Ya en años más recientes se ha dado los primeros pasos en la resolución de problemas multi-objetivo basados en estos conceptos, los cuales también tuvieron gran éxito en varios problemas combinatorios como es el caso del problema del cajero viajante bi-objetivo [GGB04],[PMB06], [LPB08].

En este capítulo se explica el comportamiento de las hormigas reales en la búsqueda de alimentos, luego se presenta el modelo computacional ACO y la teoría denominada meta-heurística ACO, que define una clase particular de algoritmos ACO, además de describir varias implementaciones de este tipo de algoritmos basados en la colonia de hormigas con un enfoque mono-objetivo y multi-objetivo detallando pseudocódigos genéricos para ambos casos [PMB06].

5.1 Colonia de Hormigas

Las hormigas son insectos sociales, cuyo comportamiento está orientado a la supervivencia de la colonia como un todo antes que de un único individuo. Basados en los experimentos realizados por Denenbourg *et al.* [DAGP90] y Goss *et al.* [GADP89] se demostró su capacidad de poder encontrar el camino más corto desde su nido a las fuentes de comida. Este comportamiento se obtiene por medio de una sustancia química llamada feromona, que las hormigas depositan al caminar en busca de alguna fuente de comida, dejando de esta manera rastros de feromonas que las demás hormigas pueden oler [PMB06].

La elección entre diferentes caminos a seguir toma lugar cuando varios caminos se cruzan. Entonces, las hormigas eligen el camino a seguir con una decisión probabilística sesgada por la cantidad de feromona: cuanto más fuerte es el rastro de feromona, mayor es la probabilidad de elegirlo [LPB08].

Puesto que las hormigas depositan feromona en el camino que siguen, este comportamiento lleva a un proceso de auto-refuerzo que concluye con la formación de rastros señalados por una concentración de feromona elevada. Este comportamiento permite además a las hormigas encontrar los caminos más cortos entre su hormiguero y la fuente del alimento [AOC04]. Nótese que las hormigas solo se comunican de manera indirecta, a través de modificaciones del espacio físico que perciben. Esta forma de comunicación se denomina Estimergia Artificial[AOC04],

Como se ilustra en la figura 5.1, este mecanismo permite a las hormigas encontrar el camino más corto. Inicialmente todas las hormigas siguen el camino directo entre el nido y la fuente de alimento. Si algún obstáculo es puesto en ese camino directo, las hormigas eligen aleatoriamente cualquier camino. Al transcurrir el tiempo y mientras que las hormigas están recorriendo los caminos más prometedores, estos van recibiendo una cantidad superior de feromonas. Esto ocurre debido a que las hormigas que siguen los caminos más cortos consiguen encontrar la comida más rápidamente, por lo que comienzan su viaje de retorno antes.

Entonces, en el camino más corto habrá un rastro de feromona ligeramente superior y, por lo tanto, las decisiones de las siguientes hormigas estarán dirigidas en mayor medida a dicho camino. Además, este camino irá recibiendo una proporción mayor de feromona gracias a las hormigas que vuelven por él y no por el camino más largo. Este proceso hace que la probabilidad de que una hormiga escoja el camino más corto aumente progresivamente y que al final, el recorrido de la colonia converja al más corto de todos los caminos posibles.

Esta convergencia se complementa con la acción del entorno natural que provoca que la feromona se evapore transcurrida un cierto tiempo. Así, los caminos menos prometedores pierden progresivamente feromonas porque son visitados cada vez por menos hormigas[AOC04],[LPB08].

En la sección siguiente presentamos una versión simple de un algoritmo ACO, de forma a modelar computacionalmente el comportamiento natural de las hormigas.




Figura 5.1: Comportamiento de las hormigas en la búsqueda de su alimento entre el nido y su fuente de alimentación. (a) Inicialmente todas las hormigas van por un camino más corto, (b) eligen aleatoriamente los caminos alternativos en ausencia de feromonas entre los distintos caminos alternativos, y (c) los altos niveles de concentración de feromonas atraen a las hormigas por el camino más corto. Imagen tomada de [GBF⁺06].

5.2 Modelo computacional simple de las hormigas reales

De manera a explicar el comportamiento natural de las hormigas, se presenta a continuación un algoritmo ACO simple, que utiliza el problema TSP para dicho proposito. El algoritmo se basa en buscar el camino de menor costo entre un par de nodos dado un grafo completamente conexo [DM99],[LPB08],[PMB06].

En ambos casos, tanto las hormigas artificiales como las hormigas naturales buscan encontrar el camino más corto entre un par de nodos del grafo. La longitud de un recorrido o solución se considera como la cantidad de saltos entre nodos realizada por la hormiga. Así, en un contexto mono-objetivo se busca minimizar la longitud del camino que conecta el par de nodos origen y destino. El caso multi-objetivo es descrito más adelante en este capítulo.

A cada arco (i, j) del grafo se asocia una variable $\tau_{i,j}$ denominada rastro artificial de feromonas o rastro de feromonas. Estas variables son consultadas y actualizadas por las hormigas. La cantidad de feromonas es proporcional a la cantidad de hormigas que ya utilizaron dicho arco.

Cada hormiga aplica una regla de decisión paso a paso al construir una solución. En cada nodo se utiliza información local de manera estocástica para decidir el siguiente nodo a visitar. Se utiliza el rastro de feromonas asociado a cada arco de salida del nodo actual en que se encuentra una hormiga.

Formalmente, la regla de decisión de la hormiga k ubicada en el nodo i utiliza los rastros de feromonas $\tau_{i,j}$ para computar la probabilidad de escoger el nodo $j \in J_i$ como el siguiente nodo a visitar, donde J_i es el conjunto de vecinos ubicados a un salto del nodo i . La regla viene dada por la expresión:

$$p_{i,j} = \begin{cases} \frac{\tau_{i,j}}{\sum_{x \in J_i} \tau_{i,x}}, & \text{si } j \in J_i \\ 0, & \text{si } j \notin J_i \end{cases} \quad (5.1)$$

Al construir una solución, las hormigas depositan feromonas en los arcos que utilizan. Entonces, cada hormiga deposita una cantidad $\Delta\tau$ de feromonas al pasar de una ciudad i a otra j . De esta forma, la hormiga actualiza el valor $\tau_{i,j}$ según la expresión:

$$\tau_{i,j} = \tau_{i,j} + \Delta\tau \quad (5.2)$$

Con esta regla, se estimula a las siguientes hormigas a utilizar el arco (i, j) recientemente visitado por la hormiga que realizo la actualización. Para $\Delta\tau$ se puede utilizar un valor constante definido a priori.

Para evitar la convergencia a óptimos locales, se agrega un mecanismo de evaporación de feromonas similar al caso real. Tal evaporación ocasiona una disminución de los rastros de feromonas en forma paulatina, favoreciendo la exploración de arcos distintos durante el proceso de búsqueda. Esta evaporación se realiza en cada iteración del algoritmo disminuyendo el valor de cada $\tau_{i,j}$ [PMB06],[LPB08]:

5. Optimización basada en colonia de hormigas

$$\tau_{i,j} = (1 - \rho) \cdot \tau_{i,j}, \rho \in (0, 1) \quad (5.3)$$

Donde ρ representa el coeficiente de evaporación de feromonas y es definido a priori.

El algoritmo presentado a continuación modela el comportamiento de las hormigas reales en su tarea de búsqueda de alimentos. El pseudocódigo del mismo se presenta en el Algoritmo 1.

Algoritmo 1: Pseudocódigo de un algoritmo ACO Simple.

```
1 Procedure Aco_simple
2   inicializar_parametros();
3   while not condicion_parada() do
4     gen = gen + 1;
5     for ant = 1 to m do /* m es la cantidad de hormigas */
6       construir_solucion(); /* Algoritmo 2 */
7       evaluar_solucion();
8       calcular_mejorSolucion();
9     end
10    mejor_solucion();
11 end
12 End
```

Algoritmo 2: Pseudocódigo Construir Solución ACO Simple.

```
1 Procedure construir_solucion
2   Sol =  $\emptyset$ ;
3   estado_actual=origen;
4   while not estado_actual=destino do
5     siguiente=seleccionar_siguienteEstado() ; /* Ecuación 5.1 */
6     Sol=Sol  $\cup$  siguiente;
7     actualizar_feromonas() ; /* Ecuación 5.2 */
8     estado_actual=siguiente;
9   end
10 End
```

A pesar de su simplicidad (y quizás por este motivo), este modelo posee limitaciones, y puede ser extendido de manera a mejorar su desempeño. Por ejemplo, podemos depositar una cantidad de feromonas proporcional a la evaluación de la calidad de la solución encontrada, favoreciendo así a los arcos que componen “buenas” soluciones. En los problemas reales, generalmente se conoce alguna información heurística particular del problema, que podemos tener en cuenta en nuestro modelo de hormigas artificiales [PMB06].

5.3 Meta-heurística ACO

La teoría de la meta-heurística ACO mencionada en esta sección fue presentada por Dorigo y Di Caro [DM99]. También aparece en el trabajo de Maniezzo et al. [MdL04], [PMB06], [LPB08]. En los trabajos de Dorigo et al. [DM96] y Dorigo y Di Caro [DM99] fueron mencionadas ideas iniciales que luego constituyeron la teoría de la meta-heurística ACO.

Los algoritmos de optimización por colonia de hormigas ACO son agentes computacionales simples que operan de forma concurrente pasando por los distintos estados del problema, llegando a soluciones parciales para luego ir iterativamente buscando las mejores soluciones factibles.

Los algoritmos ACO son esencialmente algoritmos constructivos: en cada iteración del algoritmo, cada hormiga construye una solución al problema recorriendo un grafo de construcción. Cada arista del grafo, que representa los posibles pasos que la hormiga puede dar, tiene asociada dos tipos de información que guían el movimiento de la hormiga [LPB08]:

1. Información heurística, que mide la preferencia heurística de moverse desde el nodo i hasta el nodo j , o sea, de recorrer el enlace (i, j) . Esta información heurística se denota como $\eta_{i,j}$ y es conocida como visibilidad. Las hormigas no modifican esta información durante la ejecución del algoritmo.
2. Información de los rastros de feromona artificiales, que mide la “deseabilidad aprendida” del movimiento de i a j . Imita a la feromona real que depositan las hormigas naturales. Esta información se modifica durante la ejecución del algoritmo dependiendo de las soluciones encontradas por las hormigas. Se denota por $\tau_{i,j}$ y se la conoce como feromona.

El modo de operación básico de un algoritmo ACO es como sigue: dadas m hormigas (artificiales) de la colonia, estas se mueven concurrentemente y de manera asíncrona, a través de los estados adyacentes del problema (que puede representarse en forma de grafo, con pesos).

Este movimiento se realiza siguiendo una regla de transición que está basada en la información local disponible en los componentes o nodos. Esta información local incluye la información heurística y memorística (rastros de feromona) para guiar la búsqueda. Al moverse por el grafo de construcción, las hormigas construyen incrementalmente soluciones. Opcionalmente, las hormigas pueden depositar feromona cada vez que crucen un arco o conexión mientras construyen la solución, esto es conocido como actualización en línea de los rastros de feromona paso a paso. Una vez que cada hormiga ha generado una solución, esta se evalúa y puede actualizar los rastros de feromona de los arcos visitados utilizando un proceso llamado actualización en línea a posteriori. Esta información guiará la búsqueda de las otras hormigas de la colonia en el futuro.

Además, el modo de operación genérico de un algoritmo de ACO incluye la evaporación de los rastros de feromona. La evaporación de feromona la lleva a cabo el entorno

5. Optimización basada en colonia de hormigas

y se usa como un mecanismo que evita el estancamiento en la búsqueda y permite que las hormigas busquen y exploren nuevas regiones del espacio.

Generalmente, en un contexto de minimización la visibilidad $\eta_{i,j}$ en el arco (i, j) se calcula como $\eta_{i,j} = \frac{1}{c_{i,j}}$, donde $c_{i,j}$ representa el costo de utilizar el arco (i, j) de acuerdo a un objetivo particular. Así, los arcos menos costosos y por ende más deseables, poseen un valor más elevado de visibilidad.

Los elementos de la matriz de feromonas normalmente son inicializados a un valor τ_0 definido a priori. La política de transición [DM99] se basa en asignar la probabilidad de ir del estado i al estado j según la ecuación:

$$P_{i,j} = \begin{cases} \frac{\tau_{i,j}^\alpha \cdot \eta_{i,j}^\beta}{\sum_{x \in J_i} \tau_{i,x}^\alpha \cdot \eta_{i,x}^\beta}, & \text{si } j \in J_i \\ 0, & \text{en caso contrario} \end{cases} \quad (5.4)$$

donde J_i representa el vecindario de estados alcanzables desde el estado i y válidos atendiendo las restricciones del problema, α y β son parámetros definidos a priori que reflejan la importancia relativa de las feromonas y la visibilidad respectivamente. El algoritmo ACO simple, mencionado en la sección anterior, puede ser considerado un caso especial en el cual $\beta = 0$, lo que implica que en el algoritmo ACO simple, el movimiento de la hormiga solamente es guiado por la información de feromonas, sin utilizar la visibilidad.

Al completar una solución, la hormiga evalúa la solución y modifica los rastros de feromonas en las componentes de la matriz de feromonas $\tau = \{\tau_{i,x}\}$, de forma a guardar el conocimiento de las áreas ya exploradas. Esta información de feromonas guiará la búsqueda de futuras hormigas. El algoritmo también puede incluir un proceso de evaporación de rastros de feromonas al término de cada iteración. La actualización y evaporación de feromonas se realiza según la ecuación generalizada:

$$\tau_{ij} = (1 - \rho) \cdot \tau_{ij} + \rho \cdot \Delta\tau \quad (5.5)$$

donde ρ representa el coeficiente de evaporación, y $\Delta\tau$, en un contexto de minimización, se calcula como:

$$\Delta\tau = \frac{1}{f_k(x)} \quad (5.6)$$

con $k \in \{1, 2, \dots, b\}$ en el caso de realizar una actualización basada en un solo objetivo. Para el caso de actualización considerando los b objetivos al mismo tiempo [Pin05], se puede utilizar, por ejemplo, la ecuación:

$$\Delta\tau = \sum_{k=1}^b \frac{1}{f_k(x)} \quad (5.7)$$

donde por motivos de normalización los valores f_k son divididos por un valor máximo calculado a priori. Así, la cantidad de feromonas depositada en los arcos componentes de una solución es proporcional a la evaluación de la solución según los objetivos del problema. Puede notarse que la expresión 5.5 agrupa la actualización y evaporación de feromonas mencionadas en el modelo simple de la sección anterior. En el Algoritmo 3 se muestra el pseudocódigo de un algoritmo ACO genérico.

Algoritmo 3: Pseudocódigo de un algoritmo ACO genérico [DM99].

```

1 Procedure Aco
2   inicializar_parametros();
3   while not condicion_parada() do
4     gen=gen+1;
5     for ant = 1 to m do
6       construir_solucion(); /* Algoritmo 4                      */
7       evaluar_solucion();
8       actualizar_feromonas();
9       calcular_mejor_solucion();
10    end
11    mejor_solucion();
12 end
13 End

```

Algoritmo 4: Pseudocódigo Construir Solución de un algoritmo ACO genérico.

```

1 Procedure construir_solucion
2   Sol=∅;
3   while existen_estados_no_visitados() do
4     siguiente=seleccionar_siguiente_estado();
5     Sol=Sol ∪ siguiente;
6     marcar_como_visitado(siguiente);
7     if actualizacion_paso_a_paso() then
8       actualizar_feromonas_paso_a_paso();
9     end
10  end
11  End

```

5.4 Alternativas de diseño multi-objetivo

Las principales alternativas para implementaciones de un algoritmo ACO multi-objetivo se extienden de los algoritmos ACO tradicionales y se refieren principalmente al número de colonias y a la forma de manejar la información de feromonas y las funciones heurísticas [LIn04].

Las combinaciones de estas características son las utilizadas por las implementaciones actuales de los algoritmos ACO multi-objetivos y por este motivo merecen ser

mencionadas. Es importante mencionar que en un contexto multi-objetivo, la hormiga que completó una solución debe actualizar el conjunto Pareto CP si la solución encontrada es no dominada con respecto a las existentes en CP y luego debe eliminar las soluciones dominadas de CP, a diferencia del contexto mono-objetivo, donde simplemente se actualiza una única mejor solución cada vez que se encuentra una solución mejor a la conocida hasta ese momento.

5.4.1 Número de Colonias

La alternativa es contar con múltiples colonias, donde el conjunto de todas las hormigas es dividido en conjuntos disjuntos de menor tamaño, y cada grupo conforma una colonia. Cada colonia se especializa en una región del frente Pareto (por ejemplo, un objetivo particular), y utiliza su propia información de feromonas. En un enfoque cooperativo, pueden intercambiarse soluciones entre colonias de manera que la actualización de feromonas en una colonia sea afectada también por soluciones de otras colonias [PMB06].

5.4.2 Información de feromonas y visibilidad

Existen dos alternativas, la primera utiliza una única tabla de feromonas con la información relacionada a todos los objetivos. La segunda alternativa, utiliza múltiples tablas de feromonas, donde cada tabla posee la información de feromonas con respecto a un objetivo del problema. La regla de transición puede basarse en un solo objetivo, o puede basarse en la agregación de las diferentes tablas de feromonas asignando un peso a cada objetivo. La información heurística o visibilidad del problema posee análogas implementaciones alternativas a la información de feromonas.

Completando nuestra implementación de un algoritmo ACO genérico, lo extendemos de manera a tratar múltiples objetivos, agregando el manejo de un conjunto soluciones Pareto optimas en vez de una única mejor solución. El pseudocódigo se presenta en el Algoritmo 5, y en adelante denominamos MOACO (MultiObjective Ant Colony Optimization) a un algoritmo ACO multiobjetivo [PMB06],[LPB08].

Otros trabajos que presentan varios algoritmos ACO multi-objetivos pueden encontrarse en [GGB04], mientras que en [LLn04] se presentan varios diseños alternativos.

En resumen, partimos del algoritmo ACO simple, y desarrollamos algoritmos ACO con mayores capacidades y menores limitaciones que la versión simple. Agregamos las mejoras mencionadas anteriormente como la actualización basada en la calidad de las soluciones encontradas, permitir establecer restricciones de factibilidad a las soluciones, y la transición de estados está basada tanto en los conocimientos aprendidos previamente (rastros de feromonas) como en información heurística específica del problema. Finalmente extendimos las ecuaciones y los algoritmos de manera a tratar problemas multi-objetivos.

En el presente capítulo estudiamos el método de Optimización basada en Colonia de Hormigas (ACO), el cual está basada en el comportamiento de las hormigas reales en la búsqueda de alimentos. luego se presenta el modelo computacional ACO y la

Algoritmo 5: Pseudocódigo de un algoritmo ACO multi-objetivo.

```
1 Procedure MOACO inicializar_parametros();
2 while not condicion_parada() do
3   gen=gen+1;
4   for ant = 1 to m do
5     construir_solucion();
6     evaluar_solucion();
7     actualizar_feromonas();
8     actualizar_conjunto_pareto();
9   end
10  conjunto_pareto();
11 end
12 End
```

Algoritmo 6: Pseudocódigo Construir Solución de un algoritmo ACO multi-objetivo.

```
1 Procedure construirSolucion
2 Sol= $\emptyset$ ;
3 while existen_estados_no_visitados() do
4   siguiente=seleccionarSiguienteEstado();
5   Sol=Sol  $\cup$  siguiente;
6   marcarComoVisitado(siguiente);
7   if actualizacion_paso_a_paso() then
8     actualizar_feromonas_paso_a_paso();
9   end
10 end
11 End
```

5. Optimización basada en colonia de hormigas

teoría denominada meta-heurística ACO, que define una clase particular de algoritmos ACO, además de describir varias implementaciones de este tipo de algoritmos basados en la colonia de hormigas con un enfoque mono-objetivo y multi-objetivo, detallando pseudocódigos genéricos para ambos casos. Dada la teoría de la meta-heurística ACO, en el siguiente capítulo presentamos una introducción a los algoritmos ACO y MOACO.

Capítulo 6

Algoritmos ACO y MOACO

La Compensación de Potencia Reactiva (RPC - Reactive Power Compensation) en Sistemas de Potencia (EPSs - Electric Power Systems) es usualmente estudiada como un problema de optimización simple con restricciones, donde una función objetivo está constituida por una combinación lineal de varios factores tales como la inversión y las pérdidas en transmisión. Al mismo tiempo, ciertas restricciones limitan otros parámetros tales como confiabilidad y perfil de tensiones.

En capítulos anteriores hemos introducido la teoría de la meta-heurística ACO que modela el comportamiento de las hormigas reales a nivel computacional, además de introducir algunos pseudo-códigos a partir de los cuales podemos derivar diversos algoritmos ACO mono-objetivos y multi-objetivos [PMB06], [LPB08].

Mediante estos algoritmos implementaremos las optimizaciones de las funciones objetivos del problema RPC. Principalmente nos centraremos en los algoritmos multi-objetivos explicando los detalles de cada uno de ellos y la manera de como integrarlos a dicho problema, constituyéndose así en el estado del arte hasta la fecha de MOACO aplicados al problema de RPC.

A continuación presentamos una introducción a los algoritmos ACO mono-objetivos. Posteriormente resumiremos cada uno de los algoritmos MOACO basados en ACO mono-objetivos, resolviendo el problema propuesto en el Capítulo 4, y terminamos el capítulo explicando el concepto genérico de visibilidad y feromonas para los MOACO aplicados al RPC.

Cabe mencionar que este trabajo de tesis utiliza los conceptos y algoritmos propuestos por [PMB06], [LPB08], la descripción proveída a continuación fue basada en el resumen de algoritmos ACO descritos en dichos trabajos, de forma a que el lector posea una referencia de dichos algoritmos.

6.1 Algoritmos ACO mono-objetivos

6.1.1 Ant System (AS)

AS fue propuesto por [DM96] cuyo enfoque es una manera viable de optimización en la búsqueda exitosa de problemas de origen combinatorios. AS ha sido aplicado al problema del cajero viajante como un problema de prueba y ha servido como prototipo de varios algoritmos ACO creados posteriormente.

AS se basa en el algoritmo ACO genérico del Algoritmo 3 presentado en el capítulo anterior. Este algoritmo define n generaciones de m hormigas cada una. Los pasos que sigue el ACO básicamente consiste en que cada hormiga construyen un camino o solución, si todas las hormigas generan las mismas soluciones en un ciclo, se dice que el algoritmo entró en un estado de estancamiento (stagnation behavior), entonces, el AS define el criterio de parada del algoritmo como un número máximo n de ciclos (generaciones) o un estado de estancamiento [PMB06].

La probabilidad p_{ij} de la hormiga k , que se encuentra en el estado i , de pasar al estado j viene dada por la expresión 5.3, tomada del algoritmo ACO genérico. Realiza una actualización de feromonas al finalizar cada ciclo, según la expresión 5.3 tomada también del algoritmo ACO genérico. El valor para $\Delta\tau$ se calcula como:

$$\Delta\tau = \frac{Z}{f(x)} \quad (6.1)$$

donde Z es un parámetro definido a priori. Esta expresión es similar a la expresión genérica 5.6 ponderada por el factor Z mencionado. De esta forma, mediante el parámetro Z se controla la cantidad de feromonas a depositar, actuando como un factor de normalización. Este algoritmo fue uno de los primeros trabajos en la optimización basada en colonia de hormigas, y básicamente es análogo al algoritmo ACO genérico presentado anteriormente. Podemos decir entonces que aporta las ideas básicas para los demás algoritmos de hormigas y su importancia es más bien histórica que práctica.

6.1.2 Rank-based Ant System (ASrank)

Este algoritmo es una extensión del Ant System aplicando el concepto de “ranking” (ordenamiento) [Bul99]. Luego de que las m hormigas generan sus respectivas soluciones, estas se ordenan de acuerdo a la evaluación de sus soluciones. La diferencia con el AS aparece al actualizar las feromonas, donde la cantidad de feromonas se pondera por la posición μ de la hormiga, y solo las l mejores hormigas, denominadas elitistas, son consideradas. De esta manera, se evita que las hormigas con soluciones sub-óptimas incrementen el nivel de feromonas de ciertos estados.

La actualización de feromonas se define según la expresión 5.5. La cantidad de feromonas a depositar se basa en la expresión 6.1 con la restricción de permitir solo a las l mejores hormigas, con las mejores l soluciones de la iteración, actualizar los rastros

de feromonas en los arcos que utilizaron. Esta adaptación se muestra en la siguiente expresión:

$$\Delta\tau = (l - \mu) \cdot \frac{Z}{f(x)} \quad (6.2)$$

Z es el mismo factor de normalización utilizado en el AS. Además, este algoritmo introduce la actualización elitista de feromonas, que se realiza luego de cada iteración(ciclo) del algoritmo, y consiste en incrementar los rastros de feromonas en los arcos correspondientes a la mejor solución encontrada hasta el momento (solución elitista) en una cantidad constante $\Delta\tau'$, definida como:

$$\Delta\tau' = l \cdot \frac{Z}{f(x)} \quad (6.3)$$

Este algoritmo utiliza el concepto de elitismo, en el cual solo las mejores soluciones depositan rastros de feromonas, también se realiza una actualización basada en la mejor solución encontrada hasta el momento. A esta solución la denominaremos en adelante *globalbest* (denotado por *gb*), y a la mejor solución de la iteración la llamaremos *iteration best* (denotado por *ib*). Mediante esta estrategia elitista se busca concentrar la búsqueda en la cercanía de las mejores soluciones encontradas, donde potencialmente se encuentran buenas soluciones [G04].

6.1.3 Max-Min Ant System (MMAS)

Presentamos el MMAS, un algoritmo basado en optimización por colonias de hormigas derivado del AS. Este algoritmo fue propuesto en [ST00]. La probabilidad de transición de estado es la misma del AS expresión genérica 4.3. Utiliza el concepto de elitismo, y permite solo a la mejor solución encontrada en la iteración o hasta el momento, actualizar los rastros de feromonas en sus arcos componentes, utilizando la misma regla que el AS. El uso de esta forma de actualización de feromonas favorece la explotación de buenos caminos encontrados en la búsqueda (concepto conocido como exploitation).

Al utilizar la solución global *gb* para actualizar las feromonas, la búsqueda se concentra rápidamente en esta solución y se limita la exploración de posibles mejores soluciones. Utilizando la solución de la iteración *ib*, considerando que las mejores soluciones por iteración difieren generalmente unas de otras, un gran número de soluciones recibirán feromonas, posibilitando la exploración de varios caminos. Se pueden mezclar las estrategias, utilizando, por ejemplo, *ib* por defecto y *gb* después de un número fijo de iteraciones en la actualización de las feromonas. La estrategia sugerida en [ST00]

es utilizar una estrategia mixta dinámica, que incremente la frecuencia de uso de gb a medida que corren las iteraciones.

Inicialmente se favorece la exploración de distintos caminos, y a medida que avanzan las iteraciones y se van encontrando mejores soluciones, se favorece mas a la mejor solución encontrada hasta el momento, implementando el concepto de exploitation. Para abordar el problema del estancamiento (stagnation behavior) se propuso utilizar límites en los niveles de feromonas que un estado puede tomar, o sea:

$$\tau_{min} \leq \tau_{ij} \leq \tau_{max} \quad (6.4)$$

si $\tau_{min} > \tau_{max}$, entonces $\tau_{ij} = \tau_{max}$, con $\tau_{max} = \frac{\Delta\tau}{1-\rho}$
, y si $\tau_{ij} < \tau_{min}$, entonces $\tau_{ij} = \tau_{min}$, con:

$$\tau_{min} = \frac{\Delta\tau}{2 \cdot m \cdot (1 - \rho)} \quad (6.5)$$

donde $\Delta\tau$ se calcula con la expresión 4.4. De esta manera se impone una cota inferior y otra superior al nivel de feromonas en los arcos. Los valores especificados para τ_{min} y τ_{max} fueron tomados de [ST00]. Como puede notarse, tanto τ_{max} como τ_{min} están en función al $\Delta\tau$ de la mejor solución encontrada hasta el momento, es por eso que estos valores son actualizados cada vez que se encuentra una mejor solución global gb .

Los lectores interesados pueden encontrar, en el trabajo citado, una demostración formal de la existencia de una cota superior implícita para el nivel de feromonas producida por el efecto de evaporación de feromonas [ST00] utiliza esta cota implícita como valor para τ_{max} . En el caso de τ_{min} se realizo un planteamiento similar y empíricamente se demostró un buen comportamiento al utilizar el valor de τ_{min} presentado anteriormente.

Como nivel inicial de feromonas se utiliza $\tau_0 = \tau_{max}$, empíricamente los autores del algoritmo demostraron que esto favorece la exploración inicial y mejora el rendimiento del MMAS. También se menciona el concepto de convergencia del MMAS, el cual define que el MMAS converge, si para cada estado de decisión, uno de los estados alternativos a visitar posee el nivel de feromonas τ_0 , mientras que las demás alternativas poseen un valor τ_{min} .

Una vez que el MMAS converge o está cerca de converger, se busca favorecer la exploración de otros caminos proporcionando mas feromonas en los estados con bajo nivel de feromonas, esta acción se conoce como suavizamiento del nivel de feromonas (*Pheromone Trail Smoothing*), y se calcula según la ecuación:

$$\tau_{ij} = \tau_{ij} + fs \cdot (\tau_{max} - \tau_{ij}) \quad (6.6)$$

donde fs se denomina factor de suavizamiento. De esta forma los estados con inferiores niveles de feromonas recibirán mayor cantidad feromonas mediante el suavizamiento. Este mecanismo permite una gran exploración del espacio de búsqueda. Los autores de este algoritmo demostraron en su trabajo, la eficiencia del MMAS en problemas de optimización mono-objetivo, y a la fecha, esta propuesta está considerada como uno de los mejores algoritmos ACO basados en la teoría de las hormigas.

6.1.4 Ant-Q Algorithm

Ant-Q representa un algoritmo de la familia de algoritmos Q-learning, que se proponen en [GL95], lo cual fue aplicado para el problema del cajero viajante y estuvo inspirado en el trabajo Ant System (AS) [DM96] explicado en la sección anterior.

Las principales diferencias que presenta esta propuesta con respecto a los algoritmos basados en el Ant System son las siguientes: utiliza una regla distinta para escoger el siguiente estado a visitar, denominada regla proporcional pseudo-aleatoria (*pseudo-random proportional rule*). Asumamos que nos encontramos en el estado i , entonces se escoge j como siguiente estado a visitar según:

$$j = \begin{cases} \max_{j \in J_i} \left\{ \tau_{i,j}^\alpha \cdot \eta_{i,j}^\beta \right\}, & \text{si } q \leq q_0 \\ \hat{i}, & \text{en caso contrario} \end{cases} \quad (6.7)$$

donde q es un valor escogido aleatoriamente con probabilidad uniforme en el intervalo $[0, 1]$, y q_0 ($0 \leq q_0 \leq 1$) es un parámetro que indica la probabilidad de utilizar la regla pseudo aleatoria; $\hat{i}$ es una variable aleatoria seleccionada según la distribución de probabilidades establecida en la expresión 5.3.

Además, introduce una regla de actualización de feromonas basada en el AS, pero con una diferencia. Se agrega otro componente a la regla, que se define como:

$$\tau_{ij} = (1 - \rho) \cdot \tau_{ij} + \rho \cdot (\Delta\tau + \gamma \cdot \max_{z \in J_j} \tau_{jz}) \quad (6.8)$$

Donde γ se denomina paso de aprendizaje, y $\max_{z \in J_j} \tau_{jz}$ representa el nivel de feromonas del arco que posea mayor cantidad de feromonas de entre todos los arcos que se originan en j . De esta manera, se busca favorecer a los arcos que pertenecen a caminos altamente visitados, depositando más feromonas mediante el componente explicado.

La cantidad $\Delta\tau$ se calcula según la regla del AS expresión 6.1, y puede definirse de dos maneras, según se utilice la mejor solución encontrada (gb) o la mejor solución

de la iteración (*ib*). Solo la hormiga que encontró esta mejor solución tiene permitido actualizar las feromonas. Los autores del Ant-Q, compararon dos formas de escoger el siguiente estado en la regla pseudoaleatoria y lo denominaron con *heurística* y *sin heurística*, que se refieren a utilizar o no la visibilidad en la regla respectivamente.

Los resultados experimentales de los autores del algoritmo demostraron que la visibilidad es útil al comienzo de las iteraciones. Sin embargo, luego de un número grande de iteraciones presenta resultados similares a utilizar solo las feromonas. Esto puede explicarse considerando que inicialmente las feromonas no poseen ningún significado especial, pero luego de correr varias iteraciones se van aprendiendo buenos valores para las mismas.

6.1.5 Ant Colony System (ACS)

ACS es una modificación del Ant-Q citado anteriormente, propuesto en [DM97]. Utiliza la misma regla proporcional pseudoaleatoria presentada en la sección anterior expresión 6.7.

Las diferencias aparecen al actualizar las feromonas, ACS realiza dos actualizaciones, una global realiza da cada vez que se completa una iteración, y otra local realizada por cada hormiga cada vez que transita de un estado a otro. La primera regla de actualización se conoce como actualización retardada *delayed pheromone update*, mientras que la última se conoce como actualización paso a paso *step by step pheromone update*. Generalmente la regla retardada se realiza en función a la calidad de la solución encontrada y no posee analogías con las hormigas reales (concepto artificial).

Por su parte, la regla paso a paso fue introducida en el modelo simple del capítulo 5, y generalmente deposita una cantidad constante de feromonas, en analogía al comportamiento real de las hormigas.

La actualización global la realiza la hormiga que encontró la mejor solución global (*gb*), y se realiza según la expresión genérica 5.5 y la cantidad a depositar se calcula como en el AS, según la expresión 6.1. La actualización paso a paso se realiza también utilizando la expresión 5.5, pero se deposita $\Delta\tau = \tau_0$, una cantidad constante de feromonas en el correspondiente arco utilizado.

τ_0 representa, además, el valor inicial para las feromonas, y los autores sugieren calcular su valor como:

$$\tau_0 = \frac{1}{n \cdot S} \quad (6.9)$$

donde n es el número de componentes del problema a optimizar y S representa el costo de la mejor solución obtenida ejecutando una iteración de ACS sin feromonas, solo guiado por la visibilidad (equivalente a ejecutar un algoritmo avaro).

6.1.6 Omicron ACO (OA)

OA fue propuesto en [GB04] y está inspirado en el Max-Min Ant System (MMAS) explicado anteriormente. La principal diferencia entre el MMAS y el OA es la manera de actualizar la tabla de feromonas. En OA se mantiene una población Pb con las l mejores soluciones o individuos desde que se inició la búsqueda. El mejor individuo de Pb en cualquier momento, es la solución gb mientras que el peor individuo en Pb se denomina gw (*global worst*). No se mantienen individuos repetidos en Pb . La actualización de feromonas utiliza un parámetro definido a priori O , denominado Omicron por los autores del algoritmo.

Inicialmente se inicializa la matriz de feromonas a 1, esto es $\tau_{ij} = 1, \forall i, j \in 1, 2, \dots, n$. En cada iteración se genera una solución, que reemplaza a gw en Pb , si la nueva solución es mejor que gw . Luego de K iteraciones, se actualiza la matriz de feromonas. Para esto, primero se reinicia la matriz de feromonas al valor inicial 1, luego, se suma una cantidad O/l a cada elemento τ_{ij} cada vez que el arco (i, j) aparece en alguno de los l individuos de Pb . Este proceso se repite cada K iteraciones hasta alcanzar una condición de parada. Se puede notar que $1 \leq \tau_{ij} \leq (1 + O)$, donde $\tau_{ij} = 1$ si el arco (i, j) no es utilizado por ningún individuo en Pb , y $\tau_{ij} = 1 + O$, si el arco (i, j) aparece en todos los individuos de Pb .

El siguiente estado a visitar se calcula según la expresión genérica 5.3, al igual que el MMAS. Resulta interesante mencionar que el OA basa su actualización de feromonas en soluciones elitistas pertenecientes a una población, buscando explorar explícitamente el espacio de soluciones acotado por las mejores l soluciones encontradas hasta el momento. Las soluciones que no forman parte de la población Pb , son olvidadas. No se realiza un proceso de evaporación de feromonas, y al igual que en el MMAS el nivel de feromonas en cada arco posee una cota inferior y otra superior, esta última en función al parámetro O definido a priori.

6.2 Algoritmos MOACO

Podemos describir en este capítulo los distintos algoritmos MOACO existentes. Normalmente estos algoritmos son extensiones de algún algoritmo ACO mono-objetivo. Consecuentemente en esta sección presentaremos estas extensiones en detalle para cada algoritmo MOACO.

En este apartado cabe mencionar que no se aplica el concepto de mejor solución gb , como se mencionaba antes, sino el concepto de un conjunto de soluciones pareto óptimas cuyas definiciones fueron mencionadas en el capítulo 3. Es importante recordar que se tratará de una optimización multi-objetivo, e inclusive, dependiendo de la estrategia, pueden existir varias visibilidades y/o varias tablas de feromonas. Mantenemos en las siguientes secciones el contexto de minimización, sin perder con ello la generalidad.

6.2.1 Multiple Objective Ant Q Algorithm (MOAQ)

Este algoritmo se propuso en el trabajo de Mariano y Morales en [MM99]. La regla de transición de estados y la actualización de feromonas están basadas en el algoritmo Ant-Q, mencionado. Se mantiene una colonia de hormigas para cada objetivo. De esta manera, en un problema con b objetivos tendremos b colonias de hormigas optimizando cada una un objetivo específico.

Cada colonia encuentra soluciones que dependen de las soluciones encontradas por el resto de las colonias, creando un mecanismo de negociación y encontrando soluciones comprometidas con todos los objetivos involucrados. Las soluciones comprometidas son evaluadas en el sentido del Pareto, premiando a las soluciones no dominadas que cumplen con las restricciones del problema y penalizando a las soluciones que no cumplen con algunas de ellas.

Los puntos principales del MOAQ se resume como sigue [MM99]:

- El número de objetivos es el mismo que el número de colonia.
- El número de hormigas es el mismo en cada colonia.
- La solución de una hormiga en una colonia afecta a la solución del correspondiente agente en la otra colonia.
- Cada colonia corre una vez y las premiaciones y penalizaciones se da cuando todas las colonias han alcanzado una solución.

La regla de transición de estados se basa en los valores de la matriz de feromonas τ , y la visibilidad η , para la transición en cada colonia se utiliza una regla denominada regla proporcional pseudo-aleatoria (*pseudo random proportional rule*). Asumamos que nos encontramos en el estado i , entonces se escoge j como siguiente estado a visitar según la expresión 5.3. La actualización de los valores τ_{ij} se realiza basada en la expresión del Ant-Q, expresión 6.8.

La idea del MOAQ es utilizar colonias especializadas en objetivos particulares, y compartir los conocimientos, representados por las soluciones encontradas e inclusive por los rastros de feromonas.

6.2.2 Bicriterion Ant (BIANT)

Este algoritmo fue propuesto por Iredi *et al.* [IS01] para la resolución del TSP con dos objetivos y mantiene dos tablas de feromonas τ y τ' para dos objetivos considerados. La distribución de probabilidades para seleccionar el siguiente estado está dada por:

$$p_{i,j} = \begin{cases} \frac{\tau_{i,j}^{\lambda\alpha} \cdot \tau'_{i,j}^{(1-\lambda)\alpha} \cdot \eta_{i,j}^{\lambda\beta} \cdot \eta'_{i,j}^{(1-\lambda)\beta}}{\sum_{x \in J_i} \left\{ \tau_{i,x}^{\lambda\alpha} \cdot \tau'_{i,x}^{(1-\lambda)\alpha} \cdot \eta_{i,x}^{\lambda\beta} \cdot \eta'_{i,x}^{(1-\lambda)\beta} \right\}}, & \text{si } j \in J_i \\ 0, & \text{en caso contrario} \end{cases} \quad (6.10)$$

Para aplicar este algoritmo al problema del RPC se realizaron varias modificaciones comenzando con la cantidad de objetivos a ser optimizados. Para este problema en particular utilizamos tres funciones objetivos especificados en el capítulo 4. Utilizamos tres matrices de feromonas y tres de visibilidad, una para cada objetivos, dividimos la cantidad de hormigas k entre tres (cantidad de objetivos) y hacemos una combinación lineal de las matrices de feromonas y visibilidad de manera a ajustar la expresión 6.10 a nuestro problema.

De esta manera tenemos τ , τ' y τ'' ; η , η' y η'' como matrices de feromonas y visibilidades. Para la ejecución de la expresión (6.10) la distribución de matrices para dicha expresión es la siguiente:

- La primera $k/3$ hormigas utilizan la matriz τ , τ' y la visibilidad η, η'
- La segunda $k/3$ hormigas utilizan la matriz τ', τ'' y la visibilidad η', η''
- La tercera $k/3$ hormigas utilizan la matriz τ, τ'' y la visibilidad η, η''

Para cada hormiga t dado $t \in \{1, 2, \dots, m\}$, λ_t se calcula a partir de:

$$\lambda_t = \frac{t-1}{r \cdot k' - 1} \quad (6.11)$$

Donde r toma valores de 1 a 3 ($r=1$ o $r=2, r=3$), los valores de $t = 1, \dots, k$ donde k es la cantidad de hormigas y k' es calculado de la siguiente manera, $k' = \frac{k}{3}$, para cada valor de r se genera una combinación lineal entre τ, τ', τ'' y η, η', η'' para luego aplicarlos dentro de la expresión 6.10. De esta manera se espera que las diferentes hormigas realicen búsquedas en distintas regiones del frente pareto.

La actualización y evaporación de feromonas se realiza para cada tabla según la expresión 5.5. Solo las hormigas que encontraron soluciones no dominadas pueden actualizar las tablas de feromonas, y depositan una cantidad $\Delta\tau = \frac{1}{l}$, donde l es el número de hormigas de la iteración que generaron soluciones no dominadas. Estas soluciones no dominadas se mantienen en un conjunto externo, el conjunto pareto del algoritmo.

6.2.3 Bicriterion Multi Colony (BicriterionMC o BIMC)

Este algoritmo extiende el Bicriterion Ant y también se presenta en [IS01], introduciendo la generalización de tener b colonias, cada una con su propia tabla de feromonas y visibilidad. Utiliza una actualización por región para realizar la actualización de feromonas, en donde la secuencia de soluciones en el conjunto de soluciones no dominadas de la iteración se ordena con respecto a uno de los objetivos y se divide en b regiones de igual tamaño. Las hormigas que encontraron soluciones en la i -ésima región

actualizan la colonia i , para $i \in [1, b]$. Este método fuerza de manera explícita a las colonias a buscar en diferentes regiones del frente pareto.

El parámetro λ , mencionado en Bicriterion Ant, se calcula de manera distinta. Cada colonia i mantiene un intervalo de valores para λ que se solapan con los valores para la colonia $i - 1$ e $i + 1$, el intervalo de la colonia i se calcula como: $[\frac{i-1}{b+1}, \frac{i+1}{b+1}]$.

En el trabajo de los autores del algoritmo se propusieron otros valores para λ , pero empíricamente se obtuvo una mejor distribución del frente pareto obtenido utilizando la estrategia mencionada.

6.2.4 Pareto Ant Colony Optimization (PACO)

Este algoritmo se propuso en [DK02], y se basa en la utilización de b tablas de feromonas (τ^b), una para cada objetivo. En cada iteración una hormiga computa una serie de pesos, que en [DK02] fueron seleccionados uniformemente aleatorios, $\delta = (\delta_1, \delta_2, \dots, \delta_b)$, y los utiliza al calcular la regla de transición de estados. Estando en el estado i se selecciona el estado j según:

$$j = \begin{cases} \max_{j \in J_i} \left\{ (\sum_{k=1}^b \delta_k \cdot \tau_{i,j}^k)^\alpha \cdot \eta_{i,j}^\beta \right\}, & \text{si } q \leq q_0 \\ \hat{i}, & \text{en caso contrario} \end{cases} \quad (6.12)$$

Donde $\hat{i}$ es una variable aleatoria seleccionada según la distribución de probabilidades calculada con la ecuación:

$$p_{i,j} = \begin{cases} \frac{(\sum_{k=1}^b \delta_k \cdot \tau_{i,j}^k)^\alpha \cdot \eta_{i,j}^\beta}{\sum_{x \in J_i} \{ (\sum_{k=1}^b \delta_k \cdot \tau_{i,x}^k)^\alpha \cdot \eta_{i,x}^\beta \}}, & \text{si } j \in J_i \\ 0, & \text{en caso contrario} \end{cases} \quad (6.13)$$

Las dos mejores hormigas para cada objetivo actualizan la tabla de feromonas correspondiente a dicho objetivo según la expresión 5.5, realizando una actualización elitista. Cada vez que una hormiga avanza a otro estado, se realiza una actualización local paso a paso de las b tablas de feromonas según la expresión 5.5, considerando un valor constante para $\Delta\tau = \tau_0$, que representa el valor inicial para las feromonas (definido a priori).

Básicamente podemos decir que este algoritmo extiende el ACS para volverlo multi-objetivo, con las adaptaciones de tener una tabla de feromonas por objetivo, y agregarlas de forma ponderada en el cálculo del siguiente estado a visitar.

6.2.5 Multi-Objective Ant Colony System (MOACS)

MOACS, propuesto por Barán y Schaerer en [fHIC03], es una extensión del MACS-VRPTW, este último propuesto en [Gam99]. La principal diferencia con el enfoque

original de MACS-VRPTW es considerar todos los objetivos con la misma importancia [HIC03]. Fue implementado considerando tres objetivos, utiliza una única colonia de hormigas para minimizar los tres objetivos en forma simultánea. Todos los objetivos utilizan la misma matriz de feromonas. Por tanto, el conocimiento de buenas soluciones es igualmente importante para cada función objetivo en el frente Pareto. Utiliza la regla pseudo-aleatoria y se escoge el estado j como siguiente a visitar, estando en el estado i , según:

$$j = \begin{cases} \max_{j \in J_i} \left\{ \tau_{i,j} \cdot [\eta'_{i,j}]^{\lambda\beta} \cdot [\eta''_{i,j}]^{(1-\lambda)\beta} \right\}, & \text{si } q < q_0 \\ \hat{i}, & \text{en caso contrario} \end{cases} \quad (6.14)$$

Donde $\hat{i}$ es una variable aleatoria seleccionada según la distribución de probabilidades calculada con la ecuación:

$$p_{i,j} = \begin{cases} \frac{\tau_{i,j} \cdot [\eta'_{i,j}]^{\lambda\beta} \cdot [\eta''_{i,j}]^{(1-\lambda)\beta}}{\sum_{x \in J_i} \tau_{i,x} \cdot [\eta'_{i,x}]^{\lambda\beta} \cdot [\eta''_{i,x}]^{(1-\lambda)\beta}}, & \text{si } j \in J_i \\ 0, & \text{en caso contrario} \end{cases} \quad (6.15)$$

Cada vez que una hormiga se mueve del estado i , al estado j , realiza la actualización local de feromonas según la expresión 5.5, con $\Delta\tau = \tau_0$, el valor inicial para las feromonas.

En el caso de encontrar una solución no dominada, se actualiza el conjunto Pareto CP y se reinicializa la tabla de feromonas, considerando que la información fue aprendida por medio de soluciones dominadas [HIC03]. Si la solución encontrada es dominada se realiza la actualización de feromonas según la expresión 5.5, depositando una cantidad de feromonas según la expresión multi-objetiva 5.7.

Como el nombre del algoritmo menciona, es una extensión multi-objetiva del ACS. Es interesante notar que el concepto de multi-objetivo se basa en la utilización de varias visibilidades, manteniendo una única tabla de feromonas, que contiene la información aprendida, considerando todos los objetivos al mismo tiempo.

6.2.6 MultiObjective Max-Min Ant System (M-MMAS o M3AS)

Este algoritmo, propuesto en [Pin05], extiende el Max-Min Ant System [ST00] para resolver problemas multi-objetivos. Se utilizó inicialmente para resolver el problema de enrutamiento multicast multi-objetivo. Pinto *et al.* optimizaron cuatro objetivos. Se mantiene una tabla de feromonas τ global que mantiene información de feromonas considerando todos los objetivos a optimizar. Una hormiga estando en el estado i

escoge el siguiente estado a visitar, de acuerdo con la probabilidad p dada según la expresión 6.15 del MOACS.

Las soluciones no dominadas actualizan la tabla de feromonas según la expresión 5.5, y depositan una cantidad de feromonas según la expresión 5.7. Si $\tau_{ij} > \tau_{max}$, entonces $\tau_{ij} = \tau_{max}$, con $\tau_{max} = \frac{\Delta\tau}{(1-\rho)}$, y si $\tau_{ij} < \tau_{min}$, entonces $\tau_{ij} = \tau_{min}$, con $\tau_{min} = \frac{\Delta\tau}{2m \cdot (1-\rho)}$. De esta manera se impone una cota inferior y otra superior al nivel de feromonas en los arcos, al igual que en el MMAS.

6.2.7 COMPETants (COMP)

Propuesto en [DHR03], fue utilizado en problemas bi-objetivos, con dos tablas de feromonas y dos visibilidades. El número de hormigas para cada colonia no es fijo, y se asigna de manera dinámica durante la ejecución del algoritmo. Cada vez que todas las hormigas han construido sus soluciones, las colonias con las mejores soluciones reciben más hormigas para la siguiente iteración. Así, el número de hormigas para cada colonia es adaptado dinámicamente de acuerdo al rendimiento de cada colonia.

La probabilidad de transición de estados utiliza la expresión 5.3. Se mantienen hormigas espías en cada colonia cuyas probabilidades de transición de estados utilizan información de ambas tablas de feromonas según la ecuación:

$$p_{i,j} = \begin{cases} \frac{[0.5 \cdot \tau_{i,j} + 0.5 \cdot \tau'_{i,j}] \cdot \eta_{i,j}^\beta}{\sum_{x \in J_i} [0.5 \cdot \tau_{i,x} + 0.5 \cdot \tau'_{i,x}] \cdot \eta_{i,x}^\beta}, & \text{si } j \in J_i \\ 0, & \text{en caso contrario} \end{cases} \quad (6.16)$$

De esta manera se implementa un enfoque cooperativo entre las colonias. El algoritmo está basado en el ASrank, del cual mantuvo el enfoque de realizar un *ranking* y permitir a las mejores l hormigas de cada objetivo actualizar la correspondiente tabla de feromonas. La cantidad $\Delta\tau$ que deposita cada hormiga se calcula como:

$$\Delta\tau = 1 - \frac{\mu - 1}{l} \quad (6.17)$$

Donde μ es la posición de la hormiga en el ranking de acuerdo al objetivo asignado a la colonia de la hormiga en cuestión.

La adaptación dinámica de las hormigas se realiza en base al costo medio, de acuerdo al objetivo asignado a cada colonia. Luego de una iteración, el número de hormigas de la primera colonia (asignada al primer objetivo) será:

$$\frac{\hat{f}_2}{\hat{f}_2 + \hat{f}_1} \quad (6.18)$$

donde $\hat{f}_1$ representa la evaluación promedio de las soluciones no dominadas de la colonia utilizando la primera función objetivo, y $\hat{\hat{f}}_1$ se define análogamente pero utilizando la segunda función objetivo.

Estos costos medios se calculan promediando el costo de todas las soluciones no dominadas encontradas por cada colonia. El número de hormigas espías de la primera colonia se calcula como:

$$4 \cdot f_1(gb^1) \cdot f_1(gb^2) \quad (6.19)$$

donde gb^1 representa la mejor solución encontrada por la primera colonia y gb^2 , la mejor solución de la segunda colonia. Análogamente a lo realizado con la primera colonia, se puede obtener el número de hormigas y el número de espías para la segunda colonia.

6.2.8 Multiobjective Omicron ACO (MOA)

Este algoritmo fue propuesto en [GBF⁺06] y está basado en el algoritmo OA propuesto en [GB04]. El algoritmo fue implementado considerando dos objetivos inicialmente, para nuestra nueva solución del RPC realizamos la modificación para operar con tres objetivos, utilizando una tabla de feromonas y tres visibilidades, una para cada objetivo del problema.

El algoritmo posee una implementación muy similar al OA. Al igual que el OA, utiliza una población P de soluciones no dominadas que pueden actualizar el nivel de feromonas, generalmente se utiliza el conjunto Pareto como población P. Como probabilidad de transición de estados se utilizó la extensión multiobjetivo del MOACS, expresión 6.15.

La actualización de feromonas se basa en depositar una cantidad constante en todos los arcos que componen todas las soluciones de la población P. La regla se basa en el parámetro O (*Omicron*) al igual que en el OA. De esta manera, se mantiene el nivel de feromonas con una cota inferior y otra superior, como se muestra en la sección dedicada al OA.

En el presente trabajo hemos propuesto una modificación del MOA original [GBF⁺06], introduciendo un objetivo más a ser optimizado e introduciendo una tercera matriz de visibilidad para el tercer objetivo. Esta tercera matriz de visibilidad será explicada con detalles en la siguiente sección junto a las demás matrices de visibilidad.

En su trabajo, los autores del algoritmo resolvieron el problema de la compensación de potencia reactiva en el contexto multi-objetivo, y denominaron a la versión multi-objetiva del OA como omicron eléctrico.

6.2.9 MultiObjective Ant System (MAS)

Este algoritmo fue propuesto en [PMB06] y constituye una extensión sencilla del AS (Ant System) [DM96], para manejar múltiples objetivos. Las modificaciones realizadas se centran en la selección del siguiente estado y la actualización de las feromonas. La

selección estocástica del siguiente estado a visitar utiliza la expresión 6.15, basado en el MOACS. De esta manera, se mantiene una única tabla de feromonas con una visibilidad para cada objetivo a optimizar, y las hormigas se distribuyen en regiones del espacio de búsqueda por medio del valor $\lambda = m$ utilizado.

λ toma valores discretos y distancias uniformes entre 1 y el numero m de hormigas, o sea $\lambda \in \{1, 2, \dots, m\}$. Así se obtiene una distribución en el espacio de soluciones del problema, donde por ejemplo, en el contexto bi-objetivo, la hormiga con $\lambda = 1$ se especializara en el segundo objetivo y un valor $\lambda = m$ significa una especialización hacia el primer objetivo. Claramente los demás valores para λ representan valores intermedios entre estos casos extremos de especialización.

La actualización de feromonas se realiza luego de construir todas las soluciones de la iteración y es realizada por las soluciones no dominadas encontradas en la iteración. La regla de actualización utilizada es la expresión genérica 5.5 con $\Delta\tau$ según la expresión 5.7, de esta manera la actualización queda en función a la evaluación de la solución atendiendo todos los objetivos del problema.

Se agrego un mecanismo de control de convergencia al algoritmo, que consiste en reiniciar la tabla de feromonas si durante K' generaciones, con K' definido a priori, no se encontraron soluciones no dominadas. De esta manera, se favorece la exploración de nuevos caminos. Este mecanismo ayuda a continuar la búsqueda ante situaciones de convergencia a óptimos locales o el problema denominado *stagnation behavior*, mencionado en la implementación del AS, en el cual se terminaba el algoritmo ante esta situación. En la nueva propuesta, se reinicializa la tabla de feromonas de manera a continuar la ejecución.

En el presente capítulo se ha introducido los algoritmos ACO, además se presentó resúmenes de algoritmos MOACO basados en ACO, los cuales resuelven el problema propuesto en el capítulo 4. Finalmente se explica los conceptos genéricos de visibilidad y feromonas para los MOACO aplicados al RPC. Con los estudiados en este capítulo, en el siguiente presentamos la resolución del RPC utilizando la meta-heurística MOACO.

Capítulo 7

MOACOs Aplicados al problema RPC

En capítulos anteriores hemos introducido los algoritmos MOACO y sus distintas técnicas de resolución, además de introducir algunos pseudo-códigos, a partir de los cuales podemos derivar un pseudo-código genérico, al cual denominamos en este trabajo MOACO-RPC.

Utilizando esta definición del MOACO-RPC, implementaremos las optimizaciones de las funciones objetivos del problema RPC. Principalmente nos centraremos en los algoritmos multi-objetivos explicados en el capítulo anterior, las particularidades de cada uno de ellos y la manera en como integrarlos al problema mencionado, constituyéndose así en el estado del arte hasta la fecha de MOACO aplicados al problema RPC.

7.1 Pseudocódigo genérico MOACO del problema RPC

El pseudocódigo MOACO genérico aplicado al problema RPC presentado en el algoritmo 7(MOACO-RPC) utiliza el concepto del MOACO genérico presentado en el algoritmo 5 para generar soluciones potencialmente buenos [GBF⁺06]. Al pseudocódigo tomado del algoritmo 5 se agrega el proceso de LFlow(*Load Flow*) o Flujo de Cargas puesto que, posterior a la construcción de una solución se corre este proceso para luego evaluar la solución.

En este apartado realizamos una modificación a la expresión 5.5 que posteriormente utilizaremos en nuestro pseudocódigo genérico y se plantea de esta manera:

$$P_{ij} = \frac{\tau_{i,j}^{\alpha} \cdot \eta_{i,j}^{\beta}}{\sum_{x \in J_i} \tau_{i,x}^{\alpha} \cdot \eta_{i,x}^{\beta}}, \forall j \in J_i \quad (7.1)$$

La ecuación define la probabilidad P_{ij} de escoger el banco b_j para ser ubicado en la barra i , siendo J_i todos los elementos de compensación aplicable a la barra i . Los

parámetros α y β definen la influencia relativa entre los niveles de feromonas y la visibilidad. Para generar una solución demostrada en el pseudocódigo del algoritmo 8, cada hormiga recorre secuencialmente las barras del sistema eléctrico.

Algoritmo 7: Pseudocódigo genérico del MOACO-RPC

```

1 procedure MOACO – RPC
2   inicializar_parametros();
3   while not condicion_parada() do
4      $gen = gen + 1$ ;
5     for  $ant = 1$  to  $m$  do /*  $m$  es la cantidad de hormigas */
6       construir_solucion(); /* crear nuevo individuo */
7       correr_flujo_de_potencia();
8       evaluar_solucion(); /* según la función( 3.2) */
9       actualizar_feromonas(); /* según expresión( 5.5) */
10      actualizar_conjunto_pareto();
11    end
12 end
13 print_conjunto_pareto(); /* frente de soluciones no dominadas */

```

Algoritmo 8: Pseudocódigo construcción de solución por cada hormiga

```

1 procedure construir_solucion
2   inicializar_parametros();
3   calcular_visibilidad();
4   cargar_poblacion_inicial();
5   while  $i \leq n$  do /*  $n$  = cantidad de barras de sistema */
6      $i = i + 1$ ;
7     while  $j \leq c$  do /*  $c$  = posibles compensaciones */
8        $i = i + 1$ ;
9       siguiente = seleccionar_siguiente_reactivo(); /* según( 7.1)  $b_{ij}$  es
          asignado a  $b_i$  */
10    end
11     $B[i] = bi$ ; /* almacena los reactivos seleccionados para cada barra
        */
12 end
13  $P_{new} = B$ ;
14 print  $P_{new}$ ; /* salida de la hormiga con los reactivos para cada
        barra */

```

El conjunto de soluciones no dominadas encontradas durante el proceso es agrupado en la población P . Cada nueva solución generada es comparada con P , conservándose solamente las no dominadas. Este proceso de generación, evaluación y comparación es repetido iterativamente.

Basados en la probabilidad P_{ij} , un determinado valor b_{ij} es seleccionado y asignado

a b_i . Al final del recorrido, la hormiga genera la n – *tupla* B (vector de decisión).

Una generación es definida como un número K de iteraciones, luego de las cuales se procede a la actualización de la matriz de feromonas, que se describe a continuación:

7.2 Feromonas τ

La matriz de feromonas τ , se encarga de almacenar la información aprendida en las iteraciones previas, u obtenida de la población inicial, para ello consta de un número de filas n , igual al número de barras del sistema y un número de columnas c , igual a la cantidad de niveles de discretización de b_j . De esta manera cada fila de τ tiene asociado una barra del sistema y cada columna un valor de compensación posible, b_j . La primera columna de τ representa el mayor valor del reactor inductivo b_{il}^m permitido y la última columna corresponde al mayor valor de capacitancia b_{ic}^m [GBF⁺06].

Algoritmo 9: Pseudocódigo de actualización de la matriz de feromonas

```

1 procedure actualizar_feromonas_MOACO
2    $\tau = \text{ones}()$ ; /* igualar  $\tau$  a la matriz unitaria */
3   inicializar_parametros();
4   while  $i \leq \text{size}(P, 1)$  do /* recorre cada una de las soluciones */
5      $i = i + 1$ ;
6     while  $j \leq \text{size}(P, 2)$  do /* recorre una solución en particular */
7        $b_{ij} = P(i, j)$ ;
8        $z = b_{ij} = P(i, j)$ ;
9        $\tau_{i,z} = (1 - \rho) \cdot \tau_{i,z} + \rho \cdot \Delta\tau$ ; /* actualiza las columnas de  $\tau$  */
10    end
11 end
```

De esta forma τ asocia a cada posible compensación un valor de deseabilidad, este valor influye directamente en la distribución de probabilidades que otorgará la expresión 7.1. Así, cuanto mayor sea la deseabilidad asociada a un determinado valor de compensación, mayor será la probabilidad de que sea efectivamente elegido.

En la actualización de τ se utilizan todos los individuos de P . El número de individuos en P es denotado por m_h . Para la actualización de la matriz de feromonas la hormiga realiza los siguientes pasos según el pseudocódigo representado en el algoritmo 9.

Ejemplo 7.1: Actualización de la matriz de feromonas. (tomado de [GBF⁺06])

Considerando los siguientes valores:

$n = 3$, osea un sistema eléctrico de 3 barras.

$b_i^m = 2$ esto es; un valor máximo de compensación admisible de 2 MVar,

tomamos $c = 5$ posibles compensaciones (-2 MVar, -1 MVar, 0 MVar, 1 MVar,

2MVA_r)

$m_h = 3$, el conjunto P .

$$\tau = \begin{bmatrix} 1 & 1 & 2 \\ -2 & 1 & -1 \\ 0 & 1 & 0 \end{bmatrix}$$

Primer paso: se iguala τ a una matriz unitaria, de dimensión $m_h \times c$.

$$\tau = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

Segundo paso: se selecciona $P[1] = [1, 1, 2]$.

Tercer paso: $b_{1j} = (1 - \rho) \cdot \tau_{1,j} + \rho \cdot \Delta\tau$. Tomamos como valores de ejemplos $\rho = 0.5$ y $\Delta\tau =$ cantidad de soluciones de entrada. Suponiendo que la cantidad de soluciones de entrada es igual 70, seguimos con el cuanto paso.

Cuarto paso: Se aplica el tercer paso a la matriz τ asociada a b_{1j} .

$$\tau = \begin{bmatrix} 1 & 1 & 1 & 35.5 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

Recorriendo una solución en particular para $b_{2j} = 3$ y $b_{3j} = 2$ obtenemos actualizada la matriz de feromonas para el primer recorrido.

$$\tau = \begin{bmatrix} 1 & 1 & 1 & 35.5 & 1 \\ 1 & 1 & 1 & 35.5 & 1 \\ 1 & 1 & 1 & 1 & 35.5 \end{bmatrix}$$

Recorremos las demás soluciones; en este caso, la segunda y tercera fila. Para la segunda fila de P , $P[2] = [-2, 1, -1]$, obtenemos:

$$\tau = \begin{bmatrix} 35.5 & 1 & 1 & 35.5 & 1 \\ 1 & 1 & 1 & 52.75 & 1 \\ 1 & 35.5 & 1 & 1 & 35.5 \end{bmatrix}$$

Para la tercera fila de P , $P[3] = [0, 1, 0]$, obtenemos:

$$\tau = \begin{bmatrix} 35.5 & 1 & 35.5 & 35.5 & 1 \\ 1 & 1 & 1 & 61.37 & 1 \\ 1 & 35.5 & 35.5 & 1 & 35.5 \end{bmatrix}$$

Tabla 7.1: Matriz de feromonas del ejemplo 7.1

7.3 Visibilidad η

La visibilidad η es una función que intenta guiar a las hormigas en la construcción de buenas soluciones. De manera similar a la matriz de feromonas, la visibilidad asigna valores de deseabilidad a todas las compensaciones factibles para cada barra del sistema, para ella asocia a cada barra i un vector fila $\eta[i]$ con c columnas. Cada columna de $\eta[i]$ está asociada a un valor en MVar de banco de reactivo.

Recordemos que una barra con desviación de tensión positiva, tensión mayor que la deseada (V_i^*), necesitaría una compensación inductiva y una barra con desviación negativa, tensión menor que V_i^* , requeriría compensación capacitiva [DM00],[Miu97],[GBF⁺06].

La visibilidad opera asignando una determinada deseabilidad de ser elegido a cada valor de compensación de reactivos representado en cada fila de η . Para poder explorar eficientemente el espacio de soluciones del problema, la visibilidad no es estática durante una generación, sino que varía dinámicamente en el transcurso de la misma. Para conseguir este efecto dinámico η está compuesta por dos funciones η_1 y η_2 , conforme a la siguiente ecuación:

$$\eta = w_1 \cdot \eta_1[ij] + w_2 \cdot \eta_2[j] + w_3 \cdot \eta_3[ij] \quad (7.2)$$

donde:

$$\begin{cases} w_1 + w_2 \\ w_1 \in [1, 0] \\ w_2 \in [0, 1] \end{cases}$$

w_1 , w_2 y w_3 son valores de ponderación que varían al transcurrir la generación.

La función η_1 y η_3 otorga mayor deseabilidad a las soluciones con mucha compensación y η_2 a las soluciones con poca compensación. Los pasos a seguir para calcular la visibilidad son presentados a continuación:

1. Calcular las tensiones en las barras sin ninguna compensación de reactivos en la red, o con una distribución base de reactivos.
2. Calcular la desviación de tensión en las barras.
3. Asignar valores de deseabilidad crecientes a los distintos valores de compensación de acuerdo a la necesidad de cada barra con la función η_1 .
4. Asignar valores de deseabilidad mayores a los bancos de reactivos de pequeña dimensión a través de la función η_2 .

5. Asignar valores de deseabilidad crecientes a los distintos valores de compensación de acuerdo a la necesidad de cada barra con la función η_3 . Esta función asigna mayores deseabilidades a las barras con mayores desviaciones de tensión.
6. Los valores de $\eta[ij]$ para cada iteración son calculados mediante la fórmula 8.14, donde los valores de ponderación w_1 y w_2 varían de acuerdo al número de iteración de la generación. En base al número identificador de hormiga de la generación, w_1 varía gradualmente de 1 en la primera iteración hasta 0 en la última iteración y w_2 varía de 0 en la primera iteración hasta 1 en la última. Estos valores son los utilizados en la expresión 8.14 para hallar la probabilidad final que guiará a las hormigas para la construcción de buenas soluciones.

Así, con la utilización de la función compuesta η se busca construir buenos individuos con gran cantidad de compensación al principio de una generación e ir disminuyendo la cantidad de compensación al terminar la misma. Con esto se busca una mejor exploración del espacio de búsqueda.

Ejemplo 7.2 : Cálculo de la visibilidad. (*tomado de [GBF⁺06]*)

Considerando mismos valores utilizados en el ejemplo 7.1:

$$\eta = 3$$

$b_i^m = 2$, por lo tanto $c = 5$ posibles compensaciones por barra.

1. Cálculo de tensiones en las barras:

En nuestro ejemplo supongamos que, luego de resolver el flujo de potencia con los datos de la red y de la carga, obtenemos las siguientes tensiones en las barras: $V = [1.1; 0.28; 0.98]$; es decir, la primera barra tiene el 110% de la tensión ideal, la segunda el 82% y la tercera el 98%.

2. Cálculo de desviación de tensión:

En el ejemplo este valor sería $\Delta V = [0.1; -0.18; -0.02]$. Nótese que la primera barra necesita compensación inductiva y las otras dos capacitiva.

3. Asignación de deseabilidad de acuerdo a la función η_1 . ([GBF⁺06] et al)

Esta función favorece la elección de soluciones con gran cantidad de reactivo, siendo el máximo valor asignado proporcional a la desviación de tensión en cada barra, utilizándose un factor de proporcionalidad fa , hallado empíricamente. Los valores asignados por n_1 siguen una progresión aritmética creciente o decreciente de acuerdo a la necesidad de una compensación capacitiva o inductiva. En el ejemplo, suponiendo que elegimos un factor de proporcionalidad $fa = 100$, se obtiene:

Para la barra 1: $\Delta V = 0.1$, por lo tanto el máximo valor de probabilidad, que es asignado al banco de reactores de 2 MVar, se determina de la siguiente manera: $\Delta V \cdot fa + 1 = 0.1 \cdot 100 + 1 = 11$. El valor asignado al capacitor de 2 MVar será de 1. Los demás valores siguen una progresión aritmética de paso = $(fa \cdot \Delta V)/(c - 1) = (100 \cdot 0.1)/(5 - 1) = 2.5$.

Para la barra 2: $\Delta V = -0.18$ por lo tanto el máximo valor de probabilidad, asignado al banco de capacitores de 2MVar, será de: $\Delta V \cdot fa + 1 = 0.18 \cdot 100 + 1 = 19$. El valor asignado al reactor de -2MVar será de 1. Los demás valores siguen una progresión aritmética de paso = $(\Delta V \cdot fa)/(c - 1) = (0.18 \cdot 100)/(5 - 1) = 4.5$.

Para la barra 3: se procede de forma análoga, los valores obtenidos se resumen en la tabla 7.2.

Barra Nro	-2MVar	-1MVar	0MVar	1MVar	2MVar
1	11	8.5	6	3.5	1
2	1	5.5	10	14.5	19
3	1	1.5	2	2.5	3

Tabla 7.2: Asignación de deseabilidad otorgados por la función η_1 para el ejemplo 7.2

Para tener una visión mas clara de la asignación de probabilidades dada por η_1 , una representación gráfica de la misma se presenta a continuación:




Figura 7.1: Visualización gráfica de la asignación de deseabilidad η_1

4. Asignación de deseabilidad mediante la función η_2 . ([GBF⁺06] et al)

Esta función tiene como objetivo guiar a las hormigas para encontrar soluciones con poca compensación. Los valores de deseabilidad asignados por η_2 siguen una progresión aritmética, primero creciente y luego decreciente teniendo su pico en la deseabilidad asociada a la compensación nula. Para un valor de referencia se utiliza el promedio de la desviación de tensión ($\overline{\Delta V}$) en todas las barras y un factor de proporcionalidad fb .

En el ejemplo $\overline{\Delta V} = (0.1 + 0.18 + 0.02)/3 = 0.1$ y para una constante de proporcionalidad $fb = 100$ se obtiene:

La deseabilidad asignada a la compensación nula será de $\overline{\Delta V} \cdot fb + 1 = 0.1 \cdot 100 + 1 = 11$, la deseabilidad asignada a los mayores bancos, tanto capacitivos como inductivos será 1. A continuación se muestran los valores calculados en la tabla 7.3.

-2MVar	-1MVar	0MVar	1MVar	2MVar
1	6	11	6	1

Tabla 7.3: Asignación de deseabilidad hecha por la función η_2 para el ejemplo 7.2

De forma análoga a lo hecho con η_1 a continuación se presenta una visualización gráfica de la asignación de deseabilidad hecha por η_2 .




Figura 7.2: Visualización gráfica de la asignación de deseabilidad de la función η_2

5. Asignación de deseabilidad mediante la función η_3

Esta función al igual que la función η_1 favorece la elección de soluciones con gran cantidad de reactivos, siendo el máximo valor asignado proporcional a la desviación de tensión en cada barra. La diferencia radica principalmente en que el 20% de las barras con mayores desviaciones de tensión doblan su deseabilidad en la matriz η_3 siguiendo una progresión aritmética creciente o decreciente de acuerdo a la necesidad de una compensación capacitiva o inductiva.

Debido a que $n = 3$ y que para nuestro ejemplo de visibilidad η_3 ; el 20% de n , no sería un buen dato para tomarlo como ejemplo, entonces optamos por tomar el mayor valor de ΔV a modo de ejemplo para aplicar las reglas descritas en el pseudocódigo del algoritmo 12.

Dado $\Delta V = [0.1; -0.18; -0.02]$ notamos que la barra 2 es la que precisa mayor cantidad de reactivos puesto que posee una mayor desviación de tensión. Entonces duplicaremos el valor para la barra 2 quedando el vector de la siguiente manera: $\Delta V = [0.1; -0.36; -0.02]$.

Posterior a esto aplicamos el mismo procesamiento que el η_1 . Para la barra 2: $\Delta V = -0.36$ por lo tanto el máximo valor de probabilidad, asignado al banco de

capacitores de 2 MVAr, será de: $\Delta V \cdot fa + 1 = 0.36 \cdot 100 + 1 = 37$. El valor asignado al reactor de -2MVAr será de 1. Los demás valores siguen una progresión aritmética de paso $= (\Delta V \cdot fa)/(c - 1) = (0.36 \cdot 100)/(5 - 1) = 9$. Los valores obtenidos se resumen en la tabla 7.4.

Barra Nro	-2MVAr	-1MVAr	0MVAr	1MVAr	2MVAr
1	11	8.5	6	3.5	1
2	1	10	19	28	37
3	1	1.5	2	2.5	3

Tabla 7.4: Asignación de deseabilidad otorgados por la función η_3 para el ejemplo 7.2

6. Cálculo de η

Para el cálculo de η usaremos las tablas 7.2, 7.3, 7.4 y la fórmula (8.14). Téngase en cuenta que los valores, tanto w_1 y w_3 varían uniformemente en la misma proporción, esto debido a que las visibilidades η_1 y η_3 tienen comportamientos similares pero en diferentes proporciones.

- Así para $w_1 = 1$, $w_2 = 0$ y $w_3 = 1$, que corresponde al inicio de una generación tenemos que: $\eta[ij] = 1 \cdot \eta_1 + 0 \cdot \eta_2 + 1 \cdot \eta_3$.

$$\eta[ij] = 1 \cdot \left[\begin{array}{c|c|c|c|c} 11 & 8.5 & 6 & 3.5 & 1 \\ \hline 1 & 5.5 & 10 & 14.5 & 19 \\ \hline 1 & 1.5 & 2 & 2.5 & 3 \end{array} \right] + 0 \cdot \eta_2 + 1 \cdot \left[\begin{array}{c|c|c|c|c} 11 & 8.5 & 6 & 3.5 & 1 \\ \hline 1 & 10 & 19 & 28 & 37 \\ \hline 1 & 1.5 & 2 & 2.5 & 3 \end{array} \right]$$

$$\eta[ij] = \left[\begin{array}{c|c|c|c|c} 22 & 17 & 12 & 7 & 2 \\ \hline 2 & 18.5 & 29 & 42.5 & 56 \\ \hline 2 & 3 & 4 & 5 & 6 \end{array} \right]$$

Tabla 7.5: Ejemplo de asignación de deseabilidad de la función compuesta η para la primera iteración de una generación

- Para $w_1 = 0.5$, $w_2 = 0.5$ y $w_3 = 0.5$, que corresponde a una iteración intermedia de una generación tenemos que: $\eta[ij] = 0.5 \cdot \eta_1 + 0.5 \cdot \eta_2 + 0.5 \cdot \eta_3$.

$$\eta[ij] = 0.5 \cdot \left[\begin{array}{c|c|c|c|c} 11 & 8.5 & 6 & 3.5 & 1 \\ \hline 1 & 5.5 & 10 & 14.5 & 19 \\ \hline 1 & 1.5 & 2 & 2.5 & 3 \end{array} \right] + 0.5 \cdot [1|6|11|6|1] + 0.5 \cdot \left[\begin{array}{c|c|c|c|c} 11 & 8.5 & 6 & 3.5 & 1 \\ \hline 1 & 10 & 19 & 28 & 37 \\ \hline 1 & 1.5 & 2 & 2.5 & 3 \end{array} \right]$$

- Para la última iteración de una generación, en ese caso $w_1 = 0$, $w_2 = 1$ y $w_3 = 0$, tenemos que: $\eta[ij] = 0 \cdot \eta_1 + 1 \cdot \eta_2 + 0 \cdot \eta_3$.

$$\eta[ij] = \begin{bmatrix} 11.5 & 11.5 & 11.5 & 6.5 & 1.5 \\ 1.5 & 10.7 & 20 & 24.2 & 28.5 \\ 1.5 & 4.5 & 7.5 & 5.5 & 3.5 \end{bmatrix}$$

Tabla 7.6: Ejemplo de asignación de deseabilidad de la función compuesta η para la segunda iteración de una generación

$$\eta[ij] = 0 \cdot \eta_1 + 1 \cdot [1|6|11|6|1] + 0 \cdot \eta_3$$

$$\eta[ij] = \begin{bmatrix} 1 & 6 & 11 & 6 & 1 \\ 1 & 6 & 11 & 6 & 1 \\ 1 & 6 & 11 & 6 & 1 \end{bmatrix}$$

Tabla 7.7: Ejemplo de asignación de deseabilidad de la función compuesta η para la tercera iteración de una generación.

En la figura 7.3 se muestra una representación gráfica de la asignación de deseabilidad hecha por η .




Figura 7.3: Visualización gráfica de la asignación de deseabilidad de la función compuesta η para tres iteraciones distintas: a) la primera de la generación, b) una intermedia y c) la última iteración de la generación.

7.3.1 A continuación se presenta los pseudocódigos de visibilidad η_1 , η_2 y η_3 propuestos.

Los valores de $\eta_1[ij]$ aumentan o disminuyen conforme a una progresión aritmética; esto es, creciente o decreciente de acuerdo a la necesidad de una compensación capacitiva o inductiva. En los pseudocódigos presentados a continuación debemos correr el flujo de potencia con la red sin ninguna compensación de reactivos al iniciar los cálculos

visibilidad.

Algoritmo 10: Pseudocódigo de visibilidad η_1

```

1 procedure calculo_visibilidad_ $\eta_1$ 
2   inicializar( $V$ ); /*  $V$  = tensiones en las barras */
3   inicializar( $\Delta V$ );
4   while  $i \leq n$  do /*  $n$  = cantidad de barras del sistema */
5      $i = i + 1$ ;
6     if  $b_{ij} - 1 > 0$  then /* sobretensión en la barra */
7        $j = 0$ ;
8       while  $j \leq c$  do /*  $c$  = posibles compensaciones */
9          $j = j + 1$ ;
10         $\eta_1[i, j] = 1 + (c - j) \cdot \frac{f_a \cdot \Delta V_i}{c - 1}$ ;
11      end
12    else /* subtensión en la barra */
13       $j = 0$ ;
14      while  $j \leq c$  do
15         $j = j + 1$ ;
16         $\eta_1[i, j] = 1 + (j - 1) \cdot \frac{f_a \cdot \Delta V_i}{c - 1}$ ;
17      end
18    end
19 end

```

Algoritmo 11: Pseudocódigo de visibilidad η_2

```

1 procedure calculo_visibilidad_ $\eta_2$ 
2   inicializar( $\Delta V$ );
3    $\bar{\Delta V} = promedio(\Delta V)$ ;
4   while  $j \leq (c - 1)/2$  do /*  $c$  = cantidad de reactivos */
5      $j = j + 1$ ;
6      $\eta_2[j] = 1 + (j - 1) \cdot \frac{2 \cdot f_b \cdot \bar{\Delta V}_i}{c - 1}$ ;
7   end
8    $j = [(c - 1)/2] + 1$ ;
9   while  $j \geq (c - 1)/2$  do
10     $j = j - 1$ ;
11     $\eta_2[j] = 1 + (j - 1) \cdot \frac{2 \cdot f_b \cdot \bar{\Delta V}_i}{c - 1}$ ;
12 end

```

Algoritmo 12: Pseudocódigo de visibilidad η_3

```

1 procedure calculo_visibilidad_ $\eta_3$ 
2   inicializar( $V$ );
3   inicializar( $\Delta V$ );
4   [ $\Delta V_2, I$ ]=sort(abs( $\Delta V$ ), 'descend');
5   ni=round( $n/5$ );
6   for  $ind = 1$  to  $ni$  do
7      $\Delta V(I(ind)) = \Delta V(I(ind)) * 2$ ;
8   end
9   while  $i \leq n$  do /*  $n$ =cantidad de barras del sistema */
10     $i = i + 1$ ;
11    if  $V_i - 1 > 0$  then
12       $j = 0$ ;
13      while  $j \leq c$  do /*  $c$  = posibles compensaciones */
14         $j = j + 1$ ;
15         $\eta_1[i, j] = 1 + (c - j) \cdot \frac{f_a \cdot \Delta V_i}{c-1}$ ;
16      end
17    else
18       $j = 0$ ;
19      while  $j \leq c$  do /*  $c$  = posibles compensaciones */
20         $j = j + 1$ ;
21         $\eta_1[i, j] = 1 + (j - 1) \cdot \frac{f_a \cdot \Delta V_i}{c-1}$ ;
22      end
23    end
24 end

```

Ejemplo 7.3 Creación de una solución.

Se explicará paso a paso la creación de dos soluciones, la primera y la última de una generación. Para este ejemplo se utilizarán los resultados de los ejemplos 7.1 y 7.2. Suponiendo α y β unitarios; los valores obtenidos para la matriz de feromonas y visibilidad son tomados de la tabla 7.1 y 7.5 para la primera generación. Se procede a hallar la distribución de probabilidades según la expresión (7.1) para la primera generación.

- **Cálculo de** $P_{ij} = \frac{\tau_{i,j}^\alpha \cdot \eta_{i,j}^\beta}{\sum_{x \in J_i} \tau_{i,x}^\alpha \cdot \eta_{i,x}^\beta}, \forall j \in J_i$.

$$\tau_{i,j}^\alpha \cdot \eta_{i,j}^\beta = \left[\begin{array}{c|c|c|c|c} 35.5 & 1 & 35.5 & 35.5 & 1 \\ \hline 1 & 1 & 1 & 61.37 & 1 \\ \hline 1 & 35.5 & 35.5 & 1 & 35.5 \end{array} \right]^{\alpha=1} \cdot \left[\begin{array}{c|c|c|c|c} 22 & 17 & 12 & 7 & 2 \\ \hline 2 & 18.5 & 29 & 42.5 & 56 \\ \hline 2 & 3 & 4 & 5 & 6 \end{array} \right]^{\beta=1}$$

Puede observarse que en la primera y tercera barra, la máxima compensación inductiva y capacitiva respectivamente, tienen asociadas la mayor probabilidad

$$\tau_{i,j}^{\alpha} \cdot \eta_{i,j}^{\beta} = \left[\begin{array}{c|c|c|c|c} 781 & 17 & 426 & 248.5 & 2 \\ \hline 2 & 18.5 & 29 & 2608.22 & 56 \\ \hline 1 & 106.5 & 142 & 5 & 213 \end{array} \right]$$

$$\sum_{x \in J_i} \tau_{i,x}^{\alpha} \cdot \eta_{i,j}^{\beta} = \left[\begin{array}{c} 1474.5 \\ 2713.72 \\ 467.5 \end{array} \right]$$

$$P_{ij} = \left[\begin{array}{c|c|c|c|c} 0.53 & 0.018 & 0.29 & 0.169 & 0.001 \\ \hline 0.0007 & 0.0068 & 0.01 & 0.96 & 0.02 \\ \hline 0.002 & 0.227 & 0.303 & 0.01 & 0.455 \end{array} \right]$$

Tabla 7.8: Asignación de probabilidades Pr_{ij} , para la iteración inicial del ejemplo 7.3

de ser seleccionadas. En la segunda barra si bien la probabilidad asociada al banco de 1 MVar es muy elevada aún existe una probabilidad mayor al 6% de elegir otro banco, esto evita que el algoritmo se estanque prematuramente.

Nuevamente se utiliza un método probabilístico para elegir la compensación en cada barra de acuerdo a las probabilidades halladas, obteniéndose de este la solución $B = [-2, 1, 2]$.

Aquí se puede observar como el algoritmo busca soluciones con poca compensación al principio de la generación, así, la primera solución generada utiliza solo 1 banco, y mayor compensación al final de la generación como se nota en la solución hallada al final que necesita en total 5 MVar de compensación. Además, en todos los casos la probabilidad de ubicar un capacitor de 1 MVar en la segunda barra era la mayor debido a que todas las soluciones de Poe asignan dicha compensación a la segunda barra del sistema.

Para la iteración final de una generación utilizamos las tablas 7.1 de feromonas y la 7.7 como visibilidad:

$$\tau_{i,j}^{\alpha} \cdot \eta_{i,j}^{\beta} = \left[\begin{array}{c|c|c|c|c} 35.5 & 1 & 35.5 & 35.5 & 1 \\ \hline 1 & 1 & 1 & 61.37 & 1 \\ \hline 1 & 35.5 & 35.5 & 1 & 35.5 \end{array} \right]^{\alpha=1} \cdot \left[\begin{array}{c|c|c|c|c} 1 & 6 & 11 & 6 & 1 \\ \hline 1 & 6 & 11 & 6 & 1 \\ \hline 1 & 6 & 11 & 6 & 1 \end{array} \right]^{\beta=1}$$

$$\tau_{i,j}^{\alpha} \cdot \eta_{i,j}^{\beta} = \left[\begin{array}{c|c|c|c|c} 35.5 & 6 & 390.5 & 213 & 1 \\ \hline 1 & 6 & 11 & 368.22 & 1 \\ \hline 1 & 213 & 390.5 & 6 & 35.5 \end{array} \right]$$

$$\sum_{x \in J_i} \tau_{i,x}^{\alpha} \cdot \eta_{i,j}^{\beta} = \left[\begin{array}{c} 646 \\ 387.22 \\ 646 \end{array} \right]$$

$$P_{ij} = \left[\begin{array}{c|c|c|c|c} 0.05 & 0.009 & 0.6 & 0.33 & 0.001 \\ \hline 0.002 & 0.015 & 0.028 & 0.95 & 0.002 \\ \hline 0.001 & 0.33 & 0.6 & 0.009 & 0.05 \end{array} \right]$$

Tabla 7.9: Asignación de probabilidades Pr_{ij} , para la iteración final del ejemplo 7.3

Nótese que en la primera y tercera barras la compensación nula es la que tiene mayor probabilidad de ser electa, no ocurre lo mismo con la segunda barra debido al alto nivel de feromona asociado al banco de 1 MVar.

Ahora, que se ha hallado la distribución de probabilidades mediante la expresión (7.1) se utiliza un método de selección probabilístico para elegir la compensación en cada barra. De este proceso resulta la solución: $B = [0, 1, 0]$.

Utilizando las definiciones de los capítulos anteriores, en este capítulo hemos estudiado los algoritmos MOACO integrados al problema RPC. Además hemos presentado la visibilidad utilizada, como así también cada particularidades de los algoritmos para la resolución del problema.

Capítulo 8

Estudios Experimentales, Testing y Análisis de Resultados

En este capítulo se presenta los resultados de los experimentos realizados con los algoritmos MOACO aplicados al problemas del RPC, también presentamos la implementación computacional de los mismos describiendo como fueron diseñadas las pruebas para validar el presente trabajo, mostrando tanto el sistema eléctrico en que fueron probados los algoritmos como las métricas utilizadas para la comparación de los algoritmos.

Primeramente definiremos los objetivos experimentales, luego se explican las configuraciones del entorno computacional sobre el cual se ejecutan los algoritmos y se menciona la instancia para cada algoritmo MOACO, así como también las configuraciones de los parámetros utilizados por los mismos. Posterior a esto analizamos las métricas especializadas en el contexto multi-objetivo y se diseña el experimento utilizando métodos estadísticos como prueba de hipótesis.

Finalmente presentamos el análisis de los resultados experimentales obtenidos, de manera a poder obtener conclusiones empíricas acerca de los algoritmos comparados y asegurar que los mismos puedan ser reproducibles.

8.1 Definir los objetivos experimentales.

Para realizar comparaciones objetivas de meta-heurísticas, el diseño debe asegurar la reproductibilidad de los resultados obtenidos [Val02]. El objetivo de los experimentos y de este capítulo es comparar el desempeño de los algoritmos MOACO entre sí, de modo a resolver de la mejor manera el problema de compensación de potencia reactiva en el sistema de potencia de pruebas IEEE de 118 barras (ver figura 8.1). El sistema de prueba será planteado como problema de tres objetivos a ser optimizados simultáneamente, posteriormente en la sección 8.2, se presentarán y analizarán los resultados en base a métricas de amplia utilización por la comunidad científica.




Figura 8.1: Sistema eléctrico de potencia estandarizado IEEE de 118 barras.

8.1.1 Problema de referencia.

Según Christie [Chr00] el Sistema de Potencia de Prueba IEEE de 118 barras representa una porción del Sistema Eléctrico de los Estados Unidos de Norteamérica (Medio oeste). Los datos fueron recopilados de una copia del Sistema de Potencia de Prueba AEP (*American Electric Power*) de 118 barras y fueron habilitados para la industria eléctrica como un caso estandarizado de estudio [GBF⁺06].

8.2 Entorno computacional

Los algoritmos fueron diseñados e implementados en su totalidad en el lenguaje de programación MATLAB 7.8 sobre el sistema operativo WINDOWS 7 de 64 bits. Se utilizó un computador personal con procesador AMD Sempron de 2.7 GHz y memoria RAM de 4GB.

Los algoritmos MOACO considerados fueron: Biant, BIMC, COMP, MOACS, M3AS, MOAQ, MOA, PACO, MAS, presentados en el capítulo 6. Para facilitar la comparación, los parámetros utilizados para los algoritmos MOACO presentados en la tabla 8.1, fueron considerados como similares a los presentados en [PMB06].

A la hora de realizar la experimentación hemos tomado las configuraciones con las que se obtienen los mejores resultados para cada algoritmo MOACO del trabajo de Pacielo [PMB06] y Lezcano [LPB08] con la salvedad de que la cantidad de hormigas fue fijada en 100. En lo que sigue, los parámetros específicos de un algoritmo están representados entre paréntesis con el nombre del algoritmo al cual pertenecen.

Parámetros	Valor
Números de hormigas	100
α	1
β	2
$\gamma(MOAQ)$	0.3
ρ	0.1
$\lambda(MOAQ)$	0.8
τ_0	1
$\tau_{max}(MOAQ)$	0.9
$O(MOA)$	10
$K(MOA)$	100
$K'(MAS)$	500
q_0	0.5

Tabla 8.1: Parámetros de configuración de los algoritmos.

8.3 Métricas de desempeño

Para el análisis del desempeño de los algoritmos se utilizaron métricas de evaluación de desempeño. Estas métricas poseen un enfoque diferente de comparaciones al tratarse de un problema de optimización multi-objetivo, donde la definición de calidad es más compleja que los problemas de optimización mono-objetivos. Algunas de estas métricas fueron tomadas de Zitzler et al. [Zit00] y se resumen básicamente de la siguiente manera:

- M_1 : Calcula la mínima distancia del frente Pareto calculado con la distancia del frente Pareto verdadero u óptimo (P_{true}).
- M_2 : Compara las distribuciones de los frentes Pareto calculados.
- M_3 : Calcula la máxima extensión entre las soluciones extremas del frente Pareto calculado.
- M_4 : Calcula el porcentaje de soluciones generadas que no pertenecen al frente Pareto verdadero.
- M_5 : Calcula la cantidad de soluciones aportadas al frente Pareto óptimo P_{true} .
- M_6 : Calcula cuan uniformemente separadas están las soluciones a lo largo del frente Pareto.
- M_7 : Calcula convergencia y divergencia de un frente Pareto calculado.

A continuación presentamos de manera detalladas cada una de las métricas. Cabe recalcar que las definiciones de métricas M_1 , M_2 , M_3 , M_4 , M_5 , M_6 fueron tomadas de [LPB08] y M_7 fue tomada de [EA07].

8.3.1 Distancia al frente Pareto óptimo M_1

La métrica de Distancia o Aproximación M_1 calcula el promedio de distancias entre cada punto de un Frente Pareto FP calculado por un algoritmo y el punto más cercano correspondiente al Frente Pareto Óptimo o Frente Verdadero (P_{true}) [Zit00]. Esta métrica evalúa que tan lejos, en promedio, FP se encuentra de P_{true} . Lógicamente, cuando menor es la distancia, mejor es el desempeño del algoritmo. Dicha métrica es matemáticamente definida en la siguiente ecuación:

$$M_1(FP) = \frac{1}{|FP|} \sum_{p \in FP} \min \{d(p, q) | q \in P_{true}\} \quad (8.1)$$

8.3.2 Distribución del frente Pareto M_2

La Distribucion definida por M_2 , se utiliza para calcular el número promedio de soluciones de un Frente Pareto FP que cumplen con la condición de distancia mayor a σ , definido a priori [Zit00]. Mientras mayor sea el valor de M_2 , el algoritmo genera soluciones mejor distribuidas. La métrica de distribución se calcula como:

$$M_2(FP) = \frac{1}{|FP| - 1} \sum_{p \in FP} q \in FP | d(p, q) > \sigma | FP | > 1 \quad to \quad (8.3)$$

8.3.3 Extensión del frente Pareto M_3

La Extensión (M_3) basicamente indica la distancia entre las soluciones extremas de un frente Pareto FP calculado por un algoritmo [Zit00]. Cuanto mayor es la extension, mejor es la capacidad explorativa del algoritmo. La formulación matemática de la métrica de extensión es presentada a continuación:

$$M_3(FP) = \sqrt{\sum_{i=1}^k \max(|p_i - q_i|) | p, q \in FP} \quad (8.4)$$

8.3.4 Error al frente Pareto óptimo M_4

El Error (M_4) calcula el porcentaje de soluciones del Frente Pareto FP generado por un algoritmo que no corresponde al Frente Pareto Óptimo $Ptrue$. Dicha métrica se calcula de la siguiente manera:

$$M_4 = \frac{\sum_{i=1}^{|FP|} e_i}{|FP|} \quad (8.5)$$

La métrica de Error fue tomada de Veldhuizen [Van99] y se refiere al porcentaje de soluciones generadas que no pertenecen al frente Pareto. Si $M_4(FP) = 0$, todas las soluciones del frente Pareto FP generado por un algoritmo se encuentran en el Frente Pareto óptimo $Ptrue$; pero cuando $M_4(FP) = 1$, indica que ninguna de las soluciones en FP se encuentran en $Ptrue$. Un valor bajo de M_4 es deseable.

8.3.5 Soluciones aportadas al frente Pareto óptimo

El ONVGR (*Overall Non-dominated Vector Generation Ratio*, M_5) indica el porcentaje de soluciones aportadas al frente Pareto Óptimo $Ptrue$ [ZE99]. La métrica ONVGR es calculada según:

$$M_5 = \frac{|FP|}{|Ptrue|} \quad (8.6)$$

Cuando $M_5(FP) = 1$, el frente Pareto FP generado por un algoritmo genera un número de soluciones aportadas al frente Pareto óptimo $Ptrue$. Por el contrario, $M_5(FP) = 0$ indica que ninguna de las soluciones de FP se encuentran en $Ptrue$. Un valor más alto idealmente indica calidad de las soluciones aportadas.

8.3.6 Espaciamiento (*Spacing*) M_6

La métrica spacing evalúa la distribución de puntos no dominados en el frente Pareto calculado por el algoritmo. Esta métrica fué tomada de la definición original de Schott [Sch95] y reproducida en los textos de referencia Coello et al. [CR], Deb [Deb01] y [Nes10].

$$M_6 = \sqrt{\frac{1}{|FP| - 1} \cdot \sum_{i=1}^q (\bar{d} - d_i)^2} \quad (8.7)$$

donde:

$|FP|$ =Cardinalidad del frente Pareto FP calculado por un algoritmo.

En la ecuación 8.7, el termino d_i mide la distancia en el espacio de las funciones objetivo entre la solución i -ésima y su vecino mas próximo, la solución j -ésima, en el frente Pareto calculado por el algoritmo:

$$d_i = \min_j \left(\left| f_1^i(x) - f_1^j(x) \right| + \left| f_2^i(x) - f_2^j(x) \right| + \dots + \left| f_M^i(x) - f_M^j(x) \right| \right), i = 1, \dots, |FP|$$

El valor $\bar{d}$ corresponde al promedio de los d_i . Un valor ideal de cero en esta métrica indicaría que todos los puntos obtenidos en el frente Pareto calculado por el algoritmo están igualmente espaciados.

8.3.7 Hiper-Volumen M_7

La métrica hiper-volumen [ZT98] es un indicador combinado de convergencia y diversidad que calcula el volumen, en el espacio de objetivos, cubierto por los miembros de un conjunto de soluciones no dominadas para problemas en los que todos los objetivos deben ser minimizados. Esta métrica se define de la siguiente manera:

Para un problema de minimizacion en tres objetivos, dado un frente de Pareto calculado FP y un punto de referencia R que representa el mayor valor que puede tomar cada funcion objetivo (o un valor mayor que el de cualquier solucion encontrada), se define el hiper-volumen como:

$$HV = volumen \left(\bigcup_{i=1}^{|FP|} v_i \right) \quad (8.8)$$

En donde v_i representa el volumen del paralelepipedo formado entre el punto de referencia R y el i -ésimo elemento del frente pareto FP [Gon11].

Los algoritmos que alcanzan mayores valores para HV son mejores. Es necesario normalizar las soluciones no dominadas puesto que HV depende del escalado de los valores de la función objetivo. La normalización realizada en los frentes está basada en calcular los valores máximos y mínimos que se encuentran en todos los frentes resultantes de todos los algoritmos para entonces mapear todos los valores al intervalo $[0,1]$ [EA07].

8.4 Diseño Experimental

Analizamos dos enfoques al momento del diseño y ejecución del experimento. Por un lado se presenta el estudio global de las métricas según las corridas realizadas por los algoritmos MOACO y se emitirán resultados en base a las figuras presentadas por cada métrica.

El segundo enfoque, del diseño experimental, hace relación a los estudios estadísticos con el fin de aportar conclusiones factibles de rendimiento de los algoritmos MOACO-RPC, dichos resultados serán analizados en forma conjunta con las métricas y sus representaciones gráficas, de manera a definir cuáles algoritmos presentan mejores desempeños para el problema en cuestión.

Para llevar a cabo el enfoque estadístico, utilizamos la teoría de pruebas de hipótesis de manera a comparar estadísticamente la eficacia de los algoritmos MOACO. Se utiliza el método de prueba de hipótesis para pequeñas muestras (t -test) o (t -student), donde utilizamos muestras de la métrica: HV descritas en la sección 8.3. Recordemos que esta métrica calcula la convergencia y diversidad de un frente dado. Por consiguiente, hemos optado por esta métrica, por una cuestión de generalidad.

8.5 Estudio Global de las métricas de desempeño para los algoritmos MOACO-RPC

Para el estudio global de métricas evaluamos todas la representaciones gráficas de cada una de las métricas aplicadas a los algoritmos MOACO-RPC que resuelven el problema en cuestión. Los resultados de las métricas se encuentran normalizados, de modo que el peor valor corresponde a cero y el mejor valor corresponde a uno.

Para que las métricas puedan realizar las comparaciones de las salidas de los algoritmos, primeramente se ejecutan dichos algoritmos cierta cantidad de iteraciones de manera a obtener resultados refinados y mejor seleccionados. Estos algoritmos son ejecutados una cantidad igual de tiempo medidos en minutos. Para este caso se ejecutaron un total de 480 minutos, que equivalen a 8 horas por corridas. Cada corrida

8. Estudios Experimentales, Testing y Análisis de Resultados

de 8 horas genera 16 salidas (ver apéndice A) en intervalos de tiempos de 30 minutos. En total se realizaron 10 corridas por cada algoritmo, y como se tiene 9 algoritmos, se computaron un total de 43.200 minutos de ejecución.

Análisis de Resultados Experimentales de las Métricas.

A continuación se presentan los resultados de evaluaciones de las métricas aplicadas a los frentes Pareto generados por los algoritmos antes descritos para el problema MOACO-RPC.

Para cada una de las figuras, el eje de la abscisa posee un total de 16 posibles valores, divididos en intervalos de 30 minutos, en el rango de 30 hasta 480 minutos. Por otro lado, el eje de la ordenada representa cada valor evaluado por las métricas representando el promedio de cada una de las métricas para las 10 corridas de cada uno de los algoritmos propuestos.

8.5.1 Análisis de Resultados de la Métrica M_1

Se puede apreciar en la figura 8.2 que los algoritmos BIAnt y M3AS representan los mejores rendimientos para la métrica M_1 , teniendo mejores aproximaciones al frente Pareto verdadero. Los valores obtenidos para representar la figura 8.2 se detallan en la tabla 1 del apéndice A.




Figura 8.2: Estudio de la métrica de Distancia al frente M_1 .

8.5.2 Análisis de Resultados de la Métrica M_2

Se puede apreciar que la curva del algoritmo MOACS es la que presenta mejor distribución del frente por obtener mayores valores a las demás curvas. Los valores obtenidos para representar la figura 8.3 se detallan en la tabla 2 del apéndice A.




Figura 8.3: Estudio de la métrica Distribución del frente Pareto M_2 .

8.5.3 Análisis de Resultados de la Métrica M_3

La figura 8.4 muestra la representación M_3 de los algoritmos estudiados, y cuáles de estas posee mejor extensión M_3 de cada frente manejado por dicha métrica. La tabla 3 del apéndice A representa los valores de la figura 8.4. La misma demuestra que los algoritmos MOACS y PACO, seguido del BIAN, obtienen mejores extensiones de sus frentes paretos respecto a los demás algoritmos.

8.5.4 Análisis de resultado de la métrica Error M_4

Se puede observar en la figura 8.5 que los algoritmos BIAN y BIMC son los que poseen menores errores y por ende mejores soluciones para esta métrica. Los valores de la figura 8.5 se detallan en la tabla 4 del apéndice A.

8.5.5 Análisis de resultado de la métrica ONVGR M_5

La figura 8.6 presenta un ejemplo de la evaluación de dos frentes Pareto, todo esto, considerando las soluciones aportadas al frente Pareto óptimo por los algoritmos MOACO estudiados. Cuanto mayor se aproxime el valor a la unidad, mejor será el rendimiento del algoritmo, puesto que presentará mejor semejanza al P_{true} . Los algoritmos MAS,

8. Estudios Experimentales, Testing y Análisis de Resultados




Figura 8.4: Estudio de la métrica Extensión del frente Pareto M_3 .




Figura 8.5: Estudio de la métrica Error al frente Pareto P_{true} M_4 .

COMPET y M3AS presentan mejores resultados bajo esta métrica. Los valores obtenidos para representar la figura 8.6 se detallan en la tabla 6 del apéndice A.




Figura 8.6: Estudio de la métrica ONVGR M_5 .

8.5.6 Análisis de resultado de la métrica de Spacing M_6

A medida que los valores de la métrica para cada uno de los algoritmos vayan aproximándose a cero, mejor será el rendimiento del algoritmo bajo esta métrica. Los algoritmos BIAN y BIMC se aproximan a cero y obtienen mejores resultados para la métrica Spacing. Los valores obtenidos para representar la figura 8.7 se detallan en la tabla 5 del apéndice A.

8.6 Análisis Estadísticos

8.6.1 Diseño del experimento utilizando prueba de hipótesis

La experiencia respecto al rendimiento de algún índice de un procedimiento dado, o la exigencia del cumplimiento de alguna norma nos lleva a realizar proposiciones sobre el valor de algún parámetro estadístico.

Muchos problemas de ingeniería requieren decisiones respecto a la veracidad de los parámetros de dos proposiciones o sentencias analizadas. Estas proposiciones se deben contrastar con la realidad (mediante el muestreo de datos) para tomar una decisión entre aceptar o rechazar dicha proposición. Estas proposiciones se denominan Hipótesis y el procedimiento para decidir si se aceptan o se rechazan se denomina Prueba de Hipótesis [Mon11].

Una prueba, o test, de hipótesis es una herramienta de análisis de datos que puede, en general formar parte de un experimento comparativo más completo. Este es uno de los aspectos más útiles de la inferencia estadística, ya que muchos tipos de problemas de tomas de decisiones, pruebas o experimentos en el mundo de la ingeniería, se pueden




Figura 8.7: Estudio de la métrica Spacing M_6 .

formular como problemas de prueba de hipótesis. Dicha prueba es una proposición sobre los parámetros de una población o sobre la distribución de probabilidad de una variable aleatoria.

Los procedimientos de prueba de hipótesis dependen del empleo de la información contenida en la muestra aleatoria de la población de interés. Si la información es consistente con la hipótesis, se concluye que ésta es verdadera; sin embargo si esta información es inconsistente con la hipótesis, se concluye que es falsa. Debe hacerse hincapié en que la verdad o falsedad de una hipótesis en particular, nunca puede conocerse con certidumbre, a menos que pueda examinarse a toda la población. Usualmente esto es imposible en muchas situaciones prácticas. Por lo tanto, es necesario desarrollar un procedimiento de prueba de hipótesis teniendo en cuenta la probabilidad de llegar a una conclusión equivocada [Gri08].

La hipótesis nula, representada por H_0 , es la afirmación sobre una o más características de poblaciones que al inicio se supone cierta. La hipótesis alternativa, representada por H_1 , se establece como el opuesto de la hipótesis nula y representa la conclusión que se apoya si la hipótesis nula se rechaza. Ésta generalmente es la hipótesis a investigar.

La hipótesis nula se rechaza en favor de la hipótesis alternativa, sólo si la evidencia muestral sugiere que H_0 es falsa. Si la muestra no contradice decididamente a H_0 , se continúa creyendo en la validez de la hipótesis nula. Entonces, las dos conclusiones posibles de un análisis por prueba de hipótesis son las representadas en la tabla 8.2 [Ros09]:

La prueba de hipótesis puede inducir a cometer dos tipos de conclusiones erróneas, Por ejemplo, podemos rechazar la hipótesis nula H_0 y por lo tanto optamos a favor

de la hipótesis alternativa, cuando en realidad H_0 es efectivamente verdadera. Este tipo de error es conocido como error del Tipo I. De la misma manera puede ocurrir que rechacemos la hipótesis alternativa H_1 , optando así a favor de la hipótesis nula, cuando en realidad esta es falsa. Este tipo de error es conocido como error del Tipo II [Mas03],[MGPB11].

Decisión/Condición real	H_0 Verdadera	H_0 Falsa
Rechazar H_0	Error Tipo I	ok
Aceptar H_0	ok	Error Tipo II

Tabla 8.2: Tabla de Errores de Tipo I y Tipo II.

Puesto que nuestra decisión está basada en variables aleatorias, se pueden asociar probabilidades a los tipos de error I y II. Así, la probabilidad de cometer el error de tipo I es representado por la letra griega α . Al error de tipo I se lo conoce también con el nombre de nivel de significancia o $\alpha - error$. De la misma forma, la probabilidad de cometer el error de tipo II es β , también conocido como $\beta - error$ [Mon11],[MGPB11].

Otro concepto importante a tener en cuenta es la potencia de la prueba de hipótesis. La potencia es igual a $1 - \beta$ y puede ser interpretada como la probabilidad de rechazar correctamente una hipótesis nula falsa [Mon11]

8.6.2 Procedimiento general para la prueba de Hipótesis

Examinar los datos muestrales:

1. Identificar el parámetro de interés.
2. Establecer la Hipótesis Nula: H_0 .
3. Especificar una Hipótesis alternativa adecuada: H_1 .
4. Seleccionar un nivel de significancia: α .
5. Establecer un estadístico de prueba adecuado.
6. Establecer una región de rechazo.
7. Calcular todas las cantidades muestrales necesarias para el estadístico.
8. Decidir si debe o no rechazarse H_0 .

8.6.3 Selección de métricas para aplicar la prueba de hipótesis

En la sección 8.3 se presentaron las métricas que evalúan nuestras soluciones Pareto óptimas. De esta métrica será utilizada solo la métrica HV para evaluar la eficacia de los algoritmos MOACO propuestos a través del análisis estadístico.

A la hora de medir la calidad de los algoritmos multiobjetivos se suelen tener en cuenta dos aspectos: Minimizar la distancia del frente Pareto obtenido por el algoritmo

al frente Pareto verdadero y maximizar la extensión de soluciones sobre el frente de forma que la distribución sea lo más uniforme posible [EA07].

Para el cálculo de HV es necesario definir los puntos de referencia máximo y mínimo. De forma experimental, se determinó que es suficiente con los puntos $(\pm 6, 1, 1)$ como máximo, los cuales representan las peores evaluaciones de cada objetivo, y $(0, 0, 0)$ como mínimo, para los tres objetivos: sumatoria de compensación de potencia reactiva, promedio de desviación de tensión y máxima desviación de tensión. De este modo, se envuelven todos los frentes obtenidos.

El modo de proceder a la hora de realizar el estudio estadístico es el mostrado en la figura 8.8. Para ello, el primer paso consiste en determinar si los datos procedentes de las 10 corridas siguen una distribución normal. Para ello utilizamos el test de Shapiro-Wilk [Mas03] para muestras pequeñas ≤ 50 . El cual estudiamos a continuación.




Figura 8.8: Modo de proceder a la hora de seleccionar el test estadístico adecuado a la naturaleza de las muestras.

8.6.4 Análisis Estadísticos de los Datos

8.6.4.1 Test de Normalidad (Test de Shapiro-Wilk)

Cuando se analizan datos medidos por una variable cuantitativa continua, las pruebas estadísticas de estimación y contraste frecuentemente empleadas, se basan en suponer que se ha obtenido una muestra aleatoria de una distribución de probabilidad de tipo normal o de Gauss. Sin embargo, en muchas ocasiones esta suposición no resulta válida, y en otras la sospecha de que no sea adecuada no resulta fácil de comprobar, por tratarse de muestras pequeñas. Shapiro y Wilk propusieron una prueba estadística para verificar que la distribución normal describe bien a un conjunto de datos $T(i)$, don el tamaño de la muestra q sea ≤ 50 . Para aplicar el test de Shapiro – Wilk seguimos los siguientes pasos [Mas03] :

1. Tomamos la muestra $T(i)$ y ordenamos las observaciones de menor a mayor, sea $x_{(i)}$ el conjunto ordenado de datos, quedando de la siguiente manera la inequación:

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(q)} \quad (8.9)$$

2. Calcula la media $\bar{x}$ y la varianza muestral, σ^2 .

$$\sigma^2 = \sum_{i=1}^q (x_{(i)} - \bar{x})^2 \quad (8.10)$$

3. Utilizando los valores a_i de la tabla 1 del apéndice B, calcular:

$$g = \sum_{i=1}^q a_i \cdot x_{(i)} \quad (8.11)$$

donde, q es el tamaño de la muestra.

4. Computar la estadística de Shapiro-Wilk.

$$W = g^2 / \sigma^2 \quad (8.12)$$

5. Se rechaza la suposición de normalidad si W es menor que el valor en la tabla 4 del apéndice B.

El sistema de hipótesis de interés es:

H_0 : La población está distribuida normalmente.

H_1 : La población no está distribuida normalmente.

Se rechazará la hipótesis nula de normalidad si el estadístico W es menor que el valor crítico p proporcionado por la tabla 4 para el tamaño muestral y el nivel de significancia dado.

Según la tabla 8.3, vemos que todos los algoritmos, en todas sus instancias, obtiene un p superior a 0.842 (valor crítico) con un nivel de significancia de 0.05, por lo que hay una fuerte evidencia en los datos a favor de la hipótesis nula. Es decir, podemos asumir que los datos proceden de un modelo normal.

8.6.4.2 Prueba de Homogeneidad de Varianza (Test de Levene)

Uno de los supuestos que más se requieren en aplicaciones estadísticas populares, tales como, el análisis de varianzas, el análisis de regresión, etc., es el de la homogeneidad de varianzas. Este supuesto es crucial para garantizar la calidad de los procedimientos estadísticos utilizados tanto en prueba de hipótesis como en la construcción de intervalos de confianza [JCC06].

Existen muchas pruebas para verificar si el supuesto de homogeneidad es plausible o no, pero, dada la complejidad del problema, no es posible realizar estudios comparativos entre ellas que sean exhaustivos, ni de su comportamiento para muestras pequeñas, ya que muchas de ellas son de carácter asintótico. En este trabajo estudiamos el nivel

Algoritmos	W Shapiro-Wilk HV	Normalidad
PACO	8.011203599	SI
BIANT	8.17141317	SI
COMPET	8.17141317	SI
M3AS	8.389178488	SI
MAS	8.499443527	SI
MOAQ	8.323539142	SI
BIMC	8.283002784	SI
O3Obj	8.45292005	SI
MOACS	8.164359292	SI

Tabla 8.3: Shapiro-Wilk para la métrica HV

real de significancia, el cual es la verdadera probabilidad de rechazar la hipótesis nula cuando es cierta y que en pruebas no exactas es diferente de nivel nominal, o teórico, de significancia determinado por el usuario, usualmente a nivel de 5% u otros valores pequeños [JCC06].

Notación

La notación utilizada en el presente artículo será la siguiente:

d = Número de muestras

n_i = Tamaño de la i -ésima muestra

σ_i^2 = Varianza estimada para la i -ésima población.

$N = n_1 + n_2 + \dots + n_d$

s^2 = Varianza total estimada

La hipótesis que se quiere probar es:

H_0 : $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_d^2$

H_1 : $\sigma_i^2 = \sigma_j^2$ para por lo menos un par (i, j)

El estadístico de prueba de Levene se define como:

$$W = \frac{(N - d) \sum_{i=1}^d n_i (\bar{Z}_i - \bar{Z})^2}{(d - 1) \sum_{i=1}^d \sum_{j=1}^{n_i} (Z_{ij} - \bar{Z}_i)^2} \quad (8.13)$$

Donde Z_{ij} puede tener una de las siguientes tres definiciones:

1. $Z_{ij} = |x_{ij} - \bar{x}_i|$ donde, $\bar{x}_i$ es la media del i -ésimo subgrupo.
2. $Z_{ij} = |x_{ij} - \tilde{x}_i|$ donde, $\tilde{x}_i$ es la mediana del i -ésimo subgrupo.
3. $Z_{ij} = |x_{ij} - x'_i|$ donde, x'_i es la media recortada al 10% del i -ésimo subgrupo.

$\bar{Z} \dots$ es la media global de Z_{ij} y $\bar{Z}_i$ es la media del i -ésimo subgrupo de los Z_{ij} .

La prueba de Levene rechaza la hipótesis de que las varianzas son iguales con un nivel de significancia α , si $W > F_{\alpha, d-1, N-d}$, donde, $F_{\alpha, d-1, N-d}$ es el valor crítico superior de la distribución F con $d - 1$ grados de libertad en el numerador y $N - d$ grados de libertad en el denominador a un nivel de significancia α .

El sistema de hipótesis de interés es:

$H_0 : W < F_{critico}$ Acepta la hipótesis de varianzas iguales.

$H_1 : W > F_{critico}$ Rechaza la hipótesis de varianzas iguales.

Se rechazará la hipótesis nula de homogeneidad de varianzas si el estadístico W calculado mediante el presente test es mayor al valor crítico tomado de la tabla XX del Apéndice XX a un nivel de significancia de 0,05. Este valor crítico tomado de la distribución F es igual a $F_{critico} = 1,554$.

De acuerdo a los valores obtenidos de $W = 0,82$ para la métrica M_1 y $W = 1,38$ para la métrica HV , notamos que son menores a $F_{critico}$, por ende se rechaza la hipótesis alternativa que contradice la hipótesis nula. Con esto concluimos que las varianzas son iguales para todas las muestras.

La prueba de Levene ofrece una alternativa más robusta que el procedimiento de Bartlett, ya que es poco sensible a la desviación de la normalidad. Eso significa que será menos probable que rechace una verdadera hipótesis de igualdad de varianzas solo porque las distribuciones de las poblaciones muestreadas no son normales.

8.6.4.3 Prueba de T-test respecto a las medias cuando se muestran distribuciones normales.

En la prueba de hipótesis, se analiza estadísticamente el desempeño de los algoritmos MOACO implementados, utilizando dos métricas de evaluación. Con este test se determinan cual, o cuáles algoritmos son aceptados válidos dentro de un margen de aceptación bajo dicho test. El test consiste en el test de eficacia, el cual mide la calidad de las soluciones encontradas por los algoritmos con respecto al frente Pareto P_{true} del problema. Con este test se consigue verificar si la calidad de las soluciones obtenidas es menor a 0.05, utilizando como parámetro de valoración las métricas M_1 y HV .

Las declaraciones, “Calidad de las soluciones obtenidas” son verificadas en términos de Hipótesis Nula (que es la proposición que se quiere poner a prueba) y una Hipótesis Alternativa, la cual se aceptará si se rechaza la hipótesis nula [Don09], [VOA01], [BW08], [Gri08], [MD02], [LR04]:

Hipótesis para la Métrica M_1 .

considérese la hipótesis nula:

$$H_0 : \mu = 0.055$$

contra la alternativa:

$$H_1 : \mu > 0.055$$

Hipótesis para la Métrica HV. considérese la hipótesis nula:

$$H_0 : \mu = 0.655$$

contra la alternativa:

$$H_1 : \mu > -0.655$$

Tanto el test de la métrica M_1 como para la métrica HV, fueron hechos tomando 5% como los errores de Tipo I (alpha) y Tipo II (Beta). Siguiendo con los pasos descritos en la sección 8.4.2.1, tomamos las muestras obtenidas de las métricas M_1 y HV como hemos mencionado anteriormente.

La ecuación del test para establecer si la estadística está dentro de la sección crítica, se definen con la siguiente ecuación:

$$\tau_v = \frac{\bar{x} - \mu}{\frac{\sigma}{\sqrt{N}}} \quad (8.14)$$

donde $\bar{x}$ es el promedio de cada muestra, μ es valor que desea alcanzar, en nuestro caso, tenemos 0,05 para M_1 y 0,65 para la métrica HV(para cada una de las hipótesis), σ es la desviación estándar y N es el tamaño de la muestra.

A un nivel de significancia de 0.05, con 9 grados de libertad (tamaño de la muestra menos 1, esto es: 10 - 1) el valor crítico $t_c = 1.833$, para el análisis de estimación de la media poblacional utilizando el t-test de una cola. El valor crítico es calculado utilizando la tabla 6 del apéndice B.

8.6.4.4 Análisis de prueba de hipótesis.

Una vez obtenido las muestras a través de la métrica de aproximación M_1 y la de Hiper-volumen HV, para cada uno de los algoritmos MOACO implementados, se genera la tabla 8.4 y 8.5. Las mismas contienen las medias y desviaciones estándares para las dos métricas respectivamente. La columna $t_{0.95}$ contiene el valor del test evaluando la ecuación 8.14, y tomando como parámetros los valores de las medias y desviación estándares calculada para cada algoritmo.

La última columna H_0 afirma la eficacia del algoritmo. Esto indica si se rechaza o no la afirmación de la hipótesis nula. El punto crítico $t_c = 1.833$ es calculado utilizando la tabla 6 del apéndice B.

Para el análisis de la tabla 8.4, si $t_{0.95}$ es menor a $-t_c$ se rechaza H_0 , de lo contrario se acepta. A continuación detallamos la tabla para la métrica HV.

Para la Métrica HV.

8. Estudios Experimentales, Testing y Análisis de Resultados

Algoritmos	$\bar{x}_\sigma$	$t_{0.95}$	H_0
MOAQ	$0,1382546442 \pm 0,012523573$	$-11,03759125$	NO
PACO	$0,04845676 \pm 0,013115624$	$-12,7678542$	NO
OE3Obj	$0,025182929 \pm 0,006934304$	$-37,40117765$	NO
COMPET	$0,0326031 \pm 0,00762607$	$-13,55347546$	NO
BIANT	$0,061013767 \pm 0,00762607$	$-13,55347546$	NO
BIMC	$0,00735491 \pm 0,011046403$	$-10,17231754$	NO
M3AS	$0,022147958 \pm 0,010055224$	$-17,50572864$	NO
MOACS	$0,041859098 \pm 0,010754782$	$-19,79918482$	NO
MAS	$0,048512191 \pm 0,01594913$	$-1,356708298$	SI

Tabla 8.4: T-test para la métrica HV de los algoritmos MOACO.

Así también para el análisis de la tabla 8.5, si $t_{0.95}$ es mayor a t_c se rechaza H_0 , de lo contrario se acepta. A continuación detallamos la tabla para la métrica M_1 .

Para la Métrica M_1 .

Algoritmos	$\bar{x}_\sigma$	$t_{0.95}$	H_0
MOAQ	$0,138254644 \pm 0,003508624$	$20,53828809$	NO
PACO	$0,04845676 \pm 0,009096177$	$13,42197273$	NO
OE3Obj	$0,025182929 \pm 0,013413144$	$2,028090288$	NO
COMPET	$0,0326031 \pm 0,008354223$	$3,48955287$	NO
BIANT	$0,061013767 \pm 0,00995617$	$-0,055982185$	SI
BIMC	$0,00735491 \pm 0,013413144$	$2,028090288$	NO
M3AS	$0,022147958 \pm 0,012202708$	$2,928082297$	NO
MOACS	$0,041859098 \pm 0,011870078$	$4,036375719$	NO
MAS	$0,048512191 \pm 0,014832155$	$5,456395849$	NO

Tabla 8.5: T-test para la métrica M_1 de los algoritmos MOACO.

En la tabla 8.4 se puede apreciar que el algoritmo MAS fue aceptado, debido a que la hipótesis nula, cumple las restricciones de la hipótesis nula. Teniendo en cuenta la métrica del hipervolumen, este algoritmo obtuvo buenos resultados de dispersión y cobertura.

En la tabla 8.5 podemos corroborar que el algoritmo BIANTE obtuvo mejores soluciones, esto significa que la distancia de sus frentes es muy ajustada a P_{true} , lo cual lo convierte en buenas opciones para resolver el problema RPC.

8.6.4.5 Discusión.

En resumen, con las métricas de evaluación aplicadas sobre los distintos algoritmos MOACO, se puede notar que los algoritmos MAS y BIANTE han tenido desempeños muy buenos, fundamentalmente demostraron que son capaces de obtener soluciones muy próximas las consideradas óptimas, recordemos que estas soluciones consideradas óptimas fueron tomadas de la unión de las mejores soluciones de todos los algoritmos utilizados en esta tesis, de hecho varias soluciones encontradas por estos algoritmos forman parte de la solución óptima, lo cual queda demostrada con las métricas M_1 , M_4 , M_5 y M_6 . Sin embargo, a la hora de obtener mejor distribución y extensión de las soluciones en el espacio de solución, los algoritmos MOACS y PACO han demostrado mejores desempeños en este aspecto, los cuales obtuvieron las mejores evaluaciones de las métricas M_2 y M_3 respectivamente.

A efecto de realizar otro tipo de análisis, a parte del análisis del tiempo de los algoritmos, hemos realizado un análisis estadístico sobre la métrica de desempeño HV , la cual encontramos más adecuada por tratarse de una métrica que mide, al mismo tiempo, la convergencia y diversidad de las soluciones encontradas por los algoritmos. Este análisis estadístico consiste en la aplicación del test, denominado prueba de T-student, previa comprobación de la naturaleza de los datos obtenidos por la métrica, la distribución normal comprobada con el test de Shapiro-Wilk y la homogeneidad de varianzas comprobada con el test de Levene. con el T-student se trata de encontrar los algoritmos con mejores desempeños, medidos con la métrica HV . El resultado del análisis arroja nuevamente que los algoritmos BIANTE y MAS son los de mejores desempeños, o expresado en término estadístico, estos algoritmos poseen las mejores probabilidades de encontrar soluciones muy próxima a las soluciones óptimas.

En base a los análisis realizados, concluimos que los algoritmos BIANTE y MAS encontraron soluciones muy promisorias, por tanto, los recomendados por esta tesis para la resolución del problema de ingeniería eléctrica: Compensación de Potencia Reactiva (Reactive Power System, *RPC*).

Capítulo 9

Conclusiones y Trabajos Futuros

En el presente trabajo presentamos, un estudio comparativo del problema de compensación de potencia reactiva, con la metaheurística MOACO, implementados por vez primera con los tres objetivos: sumatoria de compensación de potencia reactiva, promedio de desviación de tensión, máxima desviación de tensión. Cabe también mencionar que a parte de las distintas métricas convencionales, se ha utilizado la métrica del Hipervolumen HV , la cual mide la aproximación y extensión de un conjunto Pareto. También en este trabajo se realizó un estudio estadístico, con el fin de aportar otro tipo de evaluación del rendimientos de los algoritmos MOACO aplicado al RPC.

Por otro lado, se ha extendido el concepto de visibilidad tratado en el trabajo de Gardel y Barán [GBF⁺06], de modo a guiar por buenos caminos la búsqueda de soluciones para cada objetivo, con esto se pretende una mayor exploración del espacio de soluciones. Además, se debe mencionar también la especialización introducida en el cálculo del siguiente nodo a visitar, durante la construcción de una solución, de tal manera a adaptar los nueve algoritmos MOACO utilizados en esta tesis, al problema en cuestión. Todo esto, constituye los principales aportes de la presente tesis.

El sistema eléctrico en estudio fue el de la IEEE de 118 barras, cuyos datos son tomados de un archivo plano, por parte del sistema que ejecuta los algoritmos MOACO, lo cual facilita que también se pudiera utilizar el sistema eléctrico Paraguay, o cualquier otro sistema eléctrico de potencia, realizando cambios mínimos en el archivo de configuración. De este modo presentamos un conjunto de algoritmos independiente al sistema en estudio y altamente escalable para la solución de problemas similares.

En el presente trabajo fueron conducidos análisis estadísticos basados en un esquema bien definido, para primeramente comprobar la naturaleza de la población, basado en el Test de Shapiro Wilk, el siguiente paso fue el test de Levene, el comparativo final está basado en t-test, mediante el cual se comprueba la eficacia de los algoritmos MOACO, En base a los análisis de resultados realizados, análisis del tiempo y análisis estadístico, podemos concluir que los algoritmos BIAnt y MAS obtuvieron soluciones muy promisorias al problema de optimización de potencia reactiva. Por lo tanto, son los algoritmos que recomendamos para la resolución del problema *RPC* u otro similar de ingeniería eléctrica. también destacamos, que los algoritmos MOACS y PACO han

demostrado buen performance de distribución y extensión dentro del espacio de solución, por lo que, tal vez con alguna modificación de sus parámetros o con pequeños variantes pueden llegar a ser buenos candidatos en la resolución del problema *RPC*.

Como trabajo futuro podría considerarse fijar valores diferentes para la máxima compensación capacitiva e inductiva, para todas las barras, teniendo en cuenta que para el presente trabajo se ha considerado el mismo valor absoluto para ambos tipos de compensación.

Además, se puede incorporar y probar más funciones objetivos a los algoritmos desarrollados en esta tesis, tal como la minimización de la pérdida de potencia, etc. Otra consideración puede basarse en limitar las posibles compensaciones admisibles para las barras a equipos de compensación disponibles comercialmente.

Finalmente, un interesante trabajo futuro es considerar un mecanismo de activación/desactivación de los elementos de compensación en las diferentes barras, basado en su nivel de carga en diferentes franjas horarias, es decir, compensación dinámica.

Apéndice A

Datos de las Métricas M1,M2,M3,M4,M5 y M6.

Tabla 1: Datos de la métrica M_1 .

T(min)/Algoritmos	BIANT	COMPET	M3AS	MAS	MOACS	MOAQ	BIMC	OE3Obj	PACO
0	0,9426	0,9341	0,9428	0,9215	0,9236	0,9147	0,9384	0,9231	0,9113
30	0,9428	0,9376	0,9431	0,9216	0,9253	0,9147	0,9403	0,9246	0,9115
60	0,9429	0,9382	0,9431	0,9216	0,9257	0,9151	0,9403	0,9247	0,9124
90	0,9449	0,9385	0,9431	0,9221	0,9262	0,9156	0,9405	0,9249	0,9131
120	0,9453	0,9385	0,9432	0,9222	0,9263	0,9156	0,9408	0,9257	0,9139
150	0,9458	0,9386	0,9432	0,9226	0,9264	0,9165	0,9409	0,9259	0,9142
180	0,9462	0,9387	0,9433	0,9227	0,9265	0,9175	0,9413	0,9263	0,9144
210	0,9471	0,9391	0,9435	0,9227	0,9271	0,9176	0,9414	0,9269	0,9145
240	0,9471	0,9393	0,9435	0,9229	0,9271	0,9176	0,9415	0,9275	0,9149
270	0,9471	0,9394	0,9439	0,9232	0,9272	0,9181	0,9415	0,9276	0,9151
300	0,9472	0,9395	0,9439	0,9238	0,9273	0,9185	0,9418	0,9279	0,9154
330	0,9474	0,9399	0,9439	0,9241	0,9273	0,9196	0,9419	0,9281	0,9174
360	0,9475	0,9399	0,9442	0,9243	0,9273	0,9196	0,9421	0,9284	0,9177
390	0,9477	0,9402	0,9447	0,9244	0,9273	0,9197	0,9423	0,9299	0,9191
420	0,9501	0,9407	0,9451	0,9251	0,9279	0,9201	0,9423	0,9331	0,9193
450	0,9502	0,9407	0,9461	0,9261	0,9287	0,9201	0,9429	0,9338	0,9211
480	0,9552	0,9447	0,9473	0,9271	0,9287	0,9235	0,9444	0,9358	0,9241

Tabla 2: Datos de la métrica M_2 .

T(min)/Algoritmos	BIANT	COMPET	M3AS	MAS	MOACS	MOAQ	BIMC	OE3Obj	PACO
0	0.2175	0.2143	0.2482	0.2280	0.2841	0.4551	0.2463	0.2261	0.2164
30	0.2769	0.2982	0.3369	0.3136	0.3092	0.4796	0.2933	0.4159	0.4241
60	0.2850	0.2995	0.3389	0.3380	0.3188	0.4811	0.2951	0.4180	0.4290
90	0.3013	0.3022	0.3436	0.3682	0.4174	0.4831	0.2971	0.4461	0.4534
120	0,3226	0,3025	0,3475	0,3897	0,4876	0,4858	0,3039	0,4612	0,4943
150	0,3428	0,3039	0,3511	0,4117	0,5507	0,4890	0,3071	0,4664	0,5185
180	0,3651	0,3041	0,3548	0,4339	0,6013	0,5005	0,3080	0,4668	0,5457
210	0,3883	0,3063	0,3608	0,4572	0,6173	0,5048	0,3093	0,4672	0,5686
240	0,4134	0,3068	0,3650	0,4761	0,6235	0,5096	0,3097	0,4675	0,5725
270	0,4362	0,3068	0,3689	0,4958	0,6421	0,5148	0,3098	0,4849	0,5893
300	0,4576	0,3070	0,3731	0,5131	0,6757	0,5205	0,3120	0,4851	0,6183
330	0,4852	0,3072	0,3777	0,5328	0,7293	0,5265	0,3129	0,5010	0,6343
360	0,5035	0,3086	0,3858	0,5580	0,7398	0,5329	0,3154	0,5203	0,6631
390	0,5219	0,3138	0,3912	0,5800	0,7480	0,5395	0,3160	0,5277	0,6717
420	0,5411	0,3148	0,3987	0,6125	0,7586	0,5465	0,3166	0,5280	0,6842
450	0,5572	0,3195	0,4100	0,6355	0,7943	0,5537	0,3167	0,5367	0,7127
480	0,5726	0,3207	0,4189	0,6502	0,7988	0,5611	0,3177	0,5485	0,7389

Tabla 3: Datos de la métrica M_3 .

T(min)/Algoritmos	BIANT	COMPET	M3AS	MAS	MOACS	MOAQ	BIMC	OE3Obj	PACO
0	0,0229	0,0166	0,0175	0,0653	0,0333	0,0625	0,0615	0,0647	0,0332
30	0,1665	0,1290	0,1351	0,1429	0,2441	0,1231	0,1206	0,1391	0,2449
60	0,2680	0,2116	0,2142	0,2087	0,3869	0,1546	0,1571	0,1811	0,3881
90	0,3382	0,2670	0,2703	0,2612	0,4885	0,1730	0,1749	0,2017	0,4903
120	0,3926	0,3225	0,3146	0,2930	0,5672	0,1861	0,1866	0,2151	0,5692
150	0,4371	0,3591	0,3527	0,3220	0,6314	0,1962	0,1957	0,2258	0,6346
180	0,4924	0,3975	0,3843	0,3496	0,6759	0,2045	0,2034	0,2347	0,6892
210	0,4960	0,4004	0,3872	0,3660	0,6909	0,2115	0,2099	0,2422	0,7089
240	0,4996	0,4035	0,3908	0,3815	0,6959	0,2176	0,2156	0,2487	0,7282
270	0,5031	0,4070	0,3937	0,3965	0,7009	0,2229	0,2206	0,2545	0,7460
300	0,5066	0,4098	0,3975	0,4110	0,7057	0,2277	0,2252	0,2598	0,7545
330	0,5469	0,4125	0,4026	0,4253	0,7105	0,2321	0,2293	0,2646	0,7631
360	0,5505	0,4152	0,4055	0,4390	0,7155	0,2363	0,2330	0,2689	0,7681
390	0,5545	0,4186	0,4081	0,4525	0,7201	0,2399	0,2365	0,2730	0,7725
420	0,5580	0,4212	0,4123	0,4658	0,7249	0,2433	0,2397	0,2768	0,7765
450	0,5807	0,4240	0,4150	0,4737	0,7305	0,2464	0,2429	0,2803	0,7793
480	0,6107	0,4299	0,4175	0,4972	0,7351	0,2497	0,2457	0,2836	0,7813

Tabla 4: Datos de la métrica Error M_4 .

T(seg)/Algoritmos	BIANT	COMPET	M3AS	MAS	MOACS	MOAQ	BIMC	OE3Obj	PACO
0	0,0450	0,0338	0,0317	0,0445	0,0173	0,0256	0,0493	0,0199	0,0255
30	0,1154	0,0677	0,0620	0,1283	0,0504	0,0499	0,0969	0,0393	0,0516
60	0,1810	0,0883	0,0813	0,1975	0,0758	0,0627	0,1280	0,0523	0,0689
90	0,2163	0,0985	0,0907	0,2237	0,0837	0,0702	0,1426	0,0582	0,0783
120	0,2749	0,1054	0,0968	0,2772	0,1025	0,0755	0,1558	0,0633	0,0855
150	0,3067	0,1106	0,1018	0,2848	0,1054	0,0796	0,1639	0,0688	0,0924
180	0,3353	0,1149	0,1059	0,2922	0,1083	0,0830	0,1703	0,0741	0,0997
210	0,3520	0,1189	0,1103	0,2979	0,1105	0,0858	0,1774	0,0765	0,1098
240	0,3672	0,1222	0,1139	0,2989	0,1109	0,0883	0,1828	0,0803	0,1157
270	0,3853	0,1255	0,1170	0,3035	0,1125	0,0905	0,1877	0,0831	0,1206
300	0,3996	0,1283	0,1196	0,3068	0,1139	0,0924	0,1921	0,0851	0,1294
330	0,4149	0,1312	0,1219	0,3178	0,1181	0,0944	0,1983	0,0866	0,1402
360	0,4283	0,1337	0,1243	0,3322	0,1220	0,0960	0,2019	0,0882	0,1505
390	0,4435	0,1369	0,1280	0,3433	0,1266	0,0974	0,2079	0,0942	0,1692
420	0,4613	0,1389	0,1306	0,3540	0,1306	0,0988	0,2161	0,0997	0,1812
450	0,4720	0,1410	0,1330	0,3644	0,1330	0,1001	0,2188	0,1047	0,1865
480	0,4885	0,1690	0,1397	0,4003	0,1601	0,1019	0,2233	0,1757	0,3562

Tabla 5: Datos de la métrica ONVGR M_5 .

T(seg)/Algoritmos	BIANT	COMPET	M3AS	MAS	MOACS	MOAQ	BIMC	OE3Obj	PACO
0	0,0265	0,0075	0,0085	0,0285	0,0329	0,0027	0,0049	0,0118	0,0090
30	0,0549	0,0272	0,0263	0,0562	0,0352	0,0052	0,0095	0,0203	0,0183
60	0,0803	0,0328	0,0313	0,1038	0,0510	0,0068	0,0125	0,0242	0,0245
90	0,1218	0,0354	0,0339	0,1469	0,0655	0,0076	0,0180	0,0264	0,0296
120	0,1896	0,0380	0,0364	0,1867	0,0790	0,0081	0,0233	0,0283	0,0333
150	0,2434	0,0418	0,0401	0,2219	0,0916	0,0085	0,0283	0,0314	0,0381
180	0,2883	0,0451	0,0433	0,2540	0,1043	0,0088	0,0331	0,0345	0,0418
210	0,2905	0,0483	0,0464	0,2822	0,1160	0,0091	0,0337	0,0377	0,0612
240	0,2917	0,0515	0,0496	0,3095	0,1270	0,0093	0,0347	0,0401	0,0644
270	0,2959	0,0547	0,0528	0,3339	0,1372	0,0095	0,0372	0,0430	0,0723
300	0,3013	0,0580	0,0559	0,3562	0,1472	0,0097	0,0383	0,0457	0,0767
330	0,3038	0,0611	0,0589	0,3774	0,1565	0,0099	0,0399	0,0482	0,0929
360	0,3064	0,0643	0,0619	0,3874	0,1655	0,0101	0,0405	0,0507	0,0998
390	0,3105	0,0674	0,0650	0,3999	0,1700	0,0102	0,0412	0,0531	0,1034
420	0,3121	0,0706	0,0684	0,4053	0,1747	0,0104	0,0416	0,0569	0,1089
450	0,3118	0,0737	0,0715	0,4107	0,1793	0,0105	0,0420	0,0606	0,1103
480	0,3223	0,0768	0,0745	0,4181	0,1834	0,0105	0,0420	0,0606	0,1103
480	0,3223	0,0768	0,0745	0,4181	0,1834	0,2721	0,0549	0,0642	0,2241

Tabla 6: Datos de la métrica Spacing M_6 .

T(min)/Algoritmos	BIANT	COMPET	M3AS	MAS	MOACS	MOAQ	BIMC	OE3Obj	PACO
0	0,9481	0,9438	0,9295	0,9088	0,9026	0,9247	0,9598	0,9239	0,9518
30	0,9541	0,9557	0,9506	0,9504	0,9038	0,9423	0,9598	0,9319	0,9518
60	0,9587	0,9569	0,9506	0,9504	0,9038	0,9423	0,9696	0,9328	0,9533
90	0,9619	0,9569	0,9531	0,9565	0,9038	0,9431	0,9702	0,9329	0,9533
120	0,9689	0,9578	0,9531	0,9601	0,9078	0,9431	0,9702	0,9329	0,9567
150	0,9721	0,9578	0,9531	0,9601	0,9078	0,9431	0,9706	0,9339	0,9567
180	0,9731	0,9583	0,9540	0,9618	0,9106	0,9451	0,9706	0,9382	0,9570
210	0,9731	0,9584	0,9540	0,9618	0,9106	0,9461	0,9714	0,9382	0,9570
240	0,9752	0,9584	0,9548	0,9626	0,9143	0,9471	0,9714	0,9397	0,9572
270	0,9752	0,9586	0,9548	0,9692	0,9147	0,9481	0,9733	0,9397	0,9572
300	0,9754	0,9586	0,9553	0,9692	0,9147	0,9483	0,9733	0,9419	0,9588
330	0,9754	0,9589	0,9583	0,9716	0,9168	0,9484	0,9739	0,9420	0,9589
360	0,9754	0,9589	0,9583	0,9716	0,9168	0,9485	0,9739	0,9439	0,9589
390	0,9774	0,9602	0,9585	0,9736	0,9175	0,9485	0,9746	0,9439	0,9591
420	0,9833	0,9602	0,9585	0,9736	0,9175	0,9485	0,9746	0,9447	0,9591
450	0,9833	0,9630	0,9588	0,9761	0,9179	0,9487	0,9786	0,9447	0,9608
480	0,9958	0,9630	0,9588	0,9761	0,9179	0,9488	0,9959	0,9645	0,9735

Apéndice B

Tablas de Distribuciones Estadísticas.

TABLA 1 Coeficientes Utilizados en el Test de Normalidad Shapiro-Wilk

i	a_{n-i+1}													
	$n=3$	4	5	6	7	8	9	10	11	12	13	14		
1	0.7071	0.6872	0.6646	0.6431	0.6233	0.6052	0.5888	0.5739	0.5601	0.5475	0.5359	0.5251		
2		0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291	0.3315	0.3325	0.3325	0.3318		
3				0.0875	0.1401	0.1743	0.1976	0.2141	0.2280	0.2347	0.2412	0.2460		
4						0.0561	0.0947	0.1249	0.1429	0.1566	0.1666	0.1707		
5								0.0399	0.0695	0.0922	0.1099	0.1240		
6										0.0305	0.0539	0.0727		
7												0.0240		
	$n=15$	16	17	18	19	20	21	22	23	24	25	26		
1	0.5150	0.5056	0.4968	0.4886	0.4808	0.4734	0.4663	0.4590	0.4532	0.4493	0.4450	0.4407		
2	0.3306	0.3290	0.3273	0.3253	0.3232	0.3211	0.3185	0.3156	0.3126	0.3098	0.3069	0.3043		
3	0.2495	0.2521	0.2540	0.2553	0.2561	0.2566	0.2578	0.2571	0.2563	0.2554	0.2543	0.2533		
4	0.1878	0.1959	0.1988	0.2027	0.2059	0.2085	0.2119	0.2131	0.2139	0.2145	0.2148	0.2151		
5	0.1353	0.1447	0.1524	0.1587	0.1641	0.1686	0.1736	0.1764	0.1787	0.1807	0.1822	0.1836		
6	0.0880	0.1005	0.1109	0.1197	0.1271	0.1334	0.1399	0.1443	0.1480	0.1512	0.1539	0.1563		
7	0.0443	0.0593	0.0725	0.0837	0.0932	0.1013	0.1092	0.1150	0.1201	0.1245	0.1283	0.1316		
8		0.0196	0.0359	0.0496	0.0612	0.0711	0.0804	0.0878	0.0941	0.0997	0.1046	0.1089		
9				0.0163	0.0303	0.0422	0.0530	0.0618	0.0696	0.0764	0.0823	0.0876		
10						0.0140	0.0263	0.0368	0.0459	0.0539	0.0610	0.0672		
11								0.0122	0.0228	0.0321	0.0405	0.0476		
12										0.0107	0.0200	0.0284		
13												0.0094		

Figura 1: Test de Normalidad “Test de Shapiro-Wilk”(1)

TABLA 1 Coeficientes Utilizados en el Test de Normalidad Shapiro-Wilk

n	27	28	29	30	31	32	33	34	35	36	37	38
1	0.4366	0.4328	0.4291	0.4254	0.4220	0.4188	0.4156	0.4127	0.4096	0.4068	0.4040	0.4015
2	0.3018	0.2992	0.2968	0.2944	0.2921	0.2898	0.2876	0.2854	0.2834	0.2813	0.2794	0.2774
3	0.2522	0.2510	0.2499	0.2487	0.2475	0.2463	0.2451	0.2439	0.2427	0.2415	0.2403	0.2391
4	0.2152	0.2151	0.2150	0.2148	0.2145	0.2141	0.2137	0.2132	0.2127	0.2121	0.2116	0.2110
5	0.1848	0.1857	0.1864	0.1870	0.1874	0.1878	0.1880	0.1882	0.1883	0.1883	0.1883	0.1881
6	0.1584	0.1601	0.1616	0.1630	0.1641	0.1651	0.1660	0.1667	0.1673	0.1678	0.1683	0.1686
7	0.1346	0.1372	0.1395	0.1415	0.1433	0.1449	0.1463	0.1475	0.1487	0.1496	0.1505	0.1513
8	0.1128	0.1162	0.1192	0.1219	0.1243	0.1265	0.1284	0.1301	0.1317	0.1331	0.1344	0.1356
9	0.0923	0.0965	0.1002	0.1036	0.1066	0.1093	0.1118	0.1140	0.1160	0.1179	0.1196	0.1211
10	0.0728	0.0778	0.0822	0.0862	0.0899	0.0931	0.0961	0.0988	0.1013	0.1036	0.1056	0.1075
11	0.0540	0.0598	0.0650	0.0697	0.0739	0.0777	0.0812	0.0844	0.0873	0.0900	0.0924	0.0947
12	0.0358	0.0424	0.0483	0.0537	0.0585	0.0629	0.0669	0.0706	0.0739	0.0770	0.0798	0.0824
13	0.0178	0.0253	0.0320	0.0381	0.0435	0.0485	0.0530	0.0572	0.0610	0.0645	0.0677	0.0706
14		0.0084	0.0159	0.0227	0.0289	0.0344	0.0395	0.0441	0.0484	0.0523	0.0559	0.0592
15				0.0076	0.0144	0.0206	0.0262	0.0314	0.0361	0.0404	0.0444	0.0481
16						0.0068	0.0131	0.0187	0.0239	0.0287	0.0331	0.0372
17								0.0062	0.0119	0.0172	0.0220	0.0264
18										0.0157	0.0210	0.0258
19												0.0063

Figura 2: Test de Normalidad “Test de Shapiro-Wilk” (2)

TABLA 1 Coeficientes Utilizados en el Test de Normalidad Shapiro-Wilk

n	39	40	41	42	43	44	45	46	47	48	49	50
1	0.3989	0.3964	0.3940	0.3917	0.3894	0.3872	0.3850	0.3830	0.3808	0.3789	0.3770	0.3751
2	0.2755	0.2737	0.2719	0.2701	0.2684	0.2667	0.2651	0.2635	0.2620	0.2604	0.2589	0.2574
3	0.2380	0.2368	0.2357	0.2345	0.2334	0.2323	0.2313	0.2302	0.2291	0.2281	0.2271	0.2260
4	0.2104	0.2098	0.2091	0.2085	0.2078	0.2072	0.2065	0.2058	0.2052	0.2045	0.2038	0.2032
5	0.1880	0.1878	0.1876	0.1874	0.1871	0.1868	0.1865	0.1862	0.1859	0.1855	0.1851	0.1847
6	0.1689	0.1691	0.1693	0.1694	0.1695	0.1695	0.1695	0.1695	0.1695	0.1693	0.1692	0.1691
7	0.1520	0.1526	0.1531	0.1535	0.1539	0.1542	0.1545	0.1548	0.1550	0.1551	0.1553	0.1554
8	0.1366	0.1376	0.1384	0.1392	0.1398	0.1406	0.1410	0.1415	0.1420	0.1423	0.1427	0.1430
9	0.1225	0.1237	0.1249	0.1259	0.1269	0.1278	0.1286	0.1293	0.1300	0.1306	0.1312	0.1317
10	0.1092	0.1108	0.1123	0.1136	0.1149	0.1160	0.1170	0.1180	0.1189	0.1197	0.1205	0.1212
11	0.0967	0.0986	0.1004	0.1020	0.1035	0.1049	0.1062	0.1073	0.1085	0.1095	0.1105	0.1113
12	0.0848	0.0870	0.0891	0.0909	0.0927	0.0943	0.0959	0.0972	0.0986	0.0998	0.1010	0.1020
13	0.0733	0.0759	0.0782	0.0804	0.0824	0.0842	0.0860	0.0876	0.0892	0.0906	0.0919	0.0932
14	0.0622	0.0651	0.0677	0.0701	0.0724	0.0745	0.0765	0.0783	0.0801	0.0817	0.0832	0.0846
15	0.0515	0.0546	0.0575	0.0602	0.0628	0.0651	0.0673	0.0694	0.0713	0.0731	0.0748	0.0764
16	0.0409	0.0444	0.0476	0.0506	0.0534	0.0560	0.0584	0.0607	0.0628	0.0648	0.0667	0.0685
17	0.0305	0.0343	0.0379	0.0411	0.0442	0.0471	0.0497	0.0522	0.0546	0.0568	0.0588	0.0608
18	0.0203	0.0244	0.0283	0.0318	0.0352	0.0383	0.0412	0.0439	0.0465	0.0489	0.0511	0.0532
19	0.0101	0.0146	0.0188	0.0227	0.0263	0.0296	0.0328	0.0357	0.0385	0.0411	0.0436	0.0459
20		0.0049	0.0094	0.0136	0.0175	0.0211	0.0245	0.0277	0.0307	0.0335	0.0361	0.0386
21				0.0045	0.0087	0.0126	0.0163	0.0197	0.0229	0.0259	0.0288	0.0314
22						0.0042	0.0081	0.0118	0.0153	0.0185	0.0215	0.0244
23								0.0039	0.0076	0.0111	0.0143	0.0174
24										0.0037	0.0071	0.0104
25												0.0085

* $a_k = -a_{n-k+1}$ for $i = 1, 2, \dots, k$ where $k = n/2$ if n is even and $k = (n-1)/2$ if n is odd.
Source: Shapiro, S. S. and Wilk, M. B. (1965). "An Analysis of Variance Test for Normality (Complete Samples)," *Biometrika*, **52**, 591-611. Copyright Biometrika Trustees. Reprinted with permission.

Figura 3: Test de Normalidad "Test de Shapiro-Wilk" (3)

TABLE 2 Critical Values for the Shapiro–Wilk Test for Normality

n	$\alpha = 1\%$	Critical Value			
		2%	5%	10%	50%
3	0.753	0.756	0.767	0.789	0.959
4	0.687	0.707	0.748	0.792	0.935
5	0.686	0.715	0.762	0.806	0.927
6	0.713	0.743	0.788	0.826	0.927
7	0.730	0.760	0.803	0.838	0.928
8	0.749	0.778	0.818	0.851	0.932
9	0.764	0.791	0.829	0.859	0.935
10	0.781	0.806	0.842	0.869	0.938
11	0.792	0.817	0.850	0.876	0.940
12	0.805	0.828	0.859	0.883	0.943
13	0.814	0.837	0.866	0.889	0.945
14	0.825	0.846	0.874	0.895	0.947
15	0.835	0.855	0.881	0.901	0.950
16	0.844	0.863	0.887	0.906	0.952
17	0.851	0.869	0.892	0.910	0.954
18	0.858	0.874	0.897	0.914	0.956
19	0.863	0.879	0.901	0.917	0.957
20	0.868	0.884	0.905	0.920	0.959
21	0.873	0.888	0.908	0.923	0.960
22	0.878	0.892	0.911	0.926	0.961
23	0.881	0.895	0.914	0.928	0.962
24	0.884	0.898	0.916	0.930	0.963
25	0.888	0.901	0.918	0.931	0.964

Figura 4: Test de Normalidad “Test de Shapiro-Wilk”(4)

TABLE 2 Critical Values for the Shapiro–Wilk Test for Normality

n	$\alpha = 1\%$	Critical Value			
		2%	5%	10%	50%
26	0.891	0.904	0.920	0.933	0.965
27	0.894	0.906	0.923	0.935	0.965
28	0.896	0.908	0.924	0.936	0.966
29	0.898	0.910	0.926	0.937	0.966
30	0.900	0.912	0.927	0.939	0.967
31	0.902	0.914	0.929	0.940	0.967
32	0.904	0.915	0.930	0.941	0.968
33	0.906	0.917	0.931	0.942	0.968
34	0.908	0.919	0.933	0.943	0.969
35	0.910	0.920	0.934	0.944	0.969
36	0.912	0.922	0.935	0.945	0.970
37	0.914	0.924	0.936	0.946	0.970
38	0.916	0.925	0.938	0.947	0.971
39	0.917	0.927	0.939	0.948	0.971
40	0.919	0.928	0.940	0.949	0.972
41	0.920	0.929	0.941	0.950	0.972
42	0.922	0.930	0.942	0.951	0.972
43	0.923	0.932	0.943	0.951	0.973
44	0.924	0.933	0.944	0.952	0.973
45	0.926	0.934	0.945	0.953	0.973
46	0.927	0.935	0.945	0.953	0.974
47	0.928	0.928	0.946	0.954	0.974
48	0.929	0.937	0.947	0.954	0.974
49	0.929	0.937	0.947	0.955	0.974
50	0.930	0.938	0.947	0.955	0.974

Source: Adapted from Shapiro, S. S. and Wilk, M. B. (1965), "An Analysis of Variance Test for Normality (Complete Samples)," *Biometrika*, **52**, 591–611. Copyright Biometrika Trustees. Reprinted with permission.

Figura 5: Test de Normalidad “Test de Shapiro-Wilk”(5)

Tabla 3 Probabilities Under the t -Distribution Curve									
1-Tail	0.2000	0.1500	0.1000	0.0500	0.0250	0.0100	0.0050	0.0010	0.0005
2-Tail	0.4000	0.3000	0.2000	0.1000	0.0500	0.0200	0.0100	0.00200	0.0010
Conf Lev.	0.6000	0.7000	0.8000	0.9000	0.9500	0.9800	0.9900	0.9980	0.9990
df									
1	1.376	1.963	3.078	6.314	12.706	31.821	63.657	318.31	696.62
2	1.061	1.386	1.886	2.920	4.303	6.965	9.925	22.327	31.599
3	0.978	1.250	1.638	2.353	3.182	4.541	5.841	10.215	12.924
4	0.941	1.190	1.533	2.132	2.776	3.747	4.604	7.173	8.610
5	0.920	1.156	1.476	2.015	2.571	3.365	4.032	5.893	6.869
6	0.906	1.134	1.440	1.943	2.447	3.143	3.707	5.208	5.959
7	0.896	1.119	1.415	1.895	2.365	2.998	3.499	4.785	5.408
8	0.889	1.108	1.397	1.860	2.306	2.896	3.355	4.501	5.041
9	0.883	1.100	1.383	1.833	2.262	2.821	3.250	4.297	4.781
10	0.879	1.093	1.372	1.812	2.228	2.764	3.169	4.144	4.587
11	0.876	1.088	1.363	1.796	2.201	2.718	3.106	4.025	4.437
12	0.873	1.083	1.356	1.782	2.179	2.681	3.055	3.930	4.318
13	0.870	1.079	1.350	1.771	2.160	2.650	3.012	3.852	4.221
14	0.868	1.076	1.345	1.761	2.145	2.624	2.977	3.787	4.140
15	0.866	1.074	1.341	1.753	2.131	2.602	2.947	3.733	4.073
16	0.865	1.071	1.337	1.746	2.120	2.583	2.921	3.686	4.015
17	0.863	1.069	1.333	1.740	2.110	2.567	2.898	3.646	3.965
18	0.862	1.067	1.330	1.734	2.101	2.552	2.878	3.610	3.922
19	0.861	1.066	1.328	1.729	2.093	2.539	2.861	3.579	3.883
20	0.860	1.064	1.325	1.725	2.086	2.528	2.845	3.552	3.850
21	0.859	1.063	1.323	1.721	2.080	2.518	2.831	3.527	3.819
22	0.858	1.061	1.321	1.717	2.074	2.508	2.819	3.505	3.792
23	0.858	1.060	1.319	1.714	2.069	2.500	2.807	3.485	3.768
24	0.857	1.059	1.318	1.711	2.064	2.492	2.797	3.467	3.745
25	0.856	1.058	1.316	1.708	2.060	2.485	2.787	3.450	3.725
26	0.856	1.058	1.315	1.706	2.056	2.479	2.779	3.435	3.707
27	0.855	1.057	1.314	1.703	2.052	2.473	2.771	3.421	3.690
28	0.855	1.056	1.313	1.701	2.048	2.467	2.763	3.408	3.674
29	0.854	1.055	1.311	1.699	2.045	2.462	2.756	3.396	3.659
30	0.854	1.055	1.310	1.697	2.042	2.457	2.750	3.385	3.646

Figura 6: Prueba de T-Test con respecto a las medias cuando se muestran distribuciones normales

Referencias

- [AA00] D. A. Linkens A. Afzalin. Training of neuro fuzzy power system stabilizer using genetic algorithms. *Int. Journal of Electrical Power and Energy Systems*, 22(2):93–102, 2000. [31](#)
- [ABB05] Support ABB. Power capacitors, 2005. ABB Capacitors AB, SECAP A05.en, 5nd edition. [23](#), [24](#)
- [AC00] N. Alguacil and A. Conejo. *Multi-Period Optimal Power Flow using Benders Decomposition*,. in *IEEE Trans. Power Systems*, pages 15(1):196–201. 2000. [28](#)
- [AOC04] S. Alonso and F. Herrera O. Cerdón, I. Fernández de Viana. La metaheurística de optimización basada en colonias de hormigas: Modelos y nuevos enfoques. Technical report, Servicio de Publicaciones de la Universidad de Málaga, 2004. Optimizacion Inteligente: Técnicas de Inteligencia Computacional para Optimización. [33](#)
- [Arr83] Arnold C.P. Harker B. J. Arrillaga, J. *Computer Modelling of Electrical Power Systems*. Editorial John Wiley Sons , Reino Unido, 1983. [7](#), [8](#), [11](#)
- [AU95] Pahalawaththa N.C. Annakkage U.D., Numnonda T. *Unit Commitment by Parallel Simulated Annealing*, volume 142(6), pages 595–600. 1995. IEE Proceedings- Generation Transmission and Distribution. [30](#)
- [Bae78] Y. Bae. *Analytical Method of Capacitors Allocations on Distribution Primary Feeders*, volume vol. 97, no. 11, pages 1232–1238. 1978. in *IEEE Trans. on Power Apparatus and Systems*. [28](#)
- [Ban05] R. Bansal. A bibliographical survey of evolutionary computation applications in power systems (1994-2003). *En Int. Journal of Power and Energy Systems*, 25(3), 2005. [28](#), [30](#)
- [Bar01a] Vallejos J. Ramos R. Barán, B. Multi-objective optimization in reactive power compensation. *En Proc. Jornadas Internacionales de Tecnología-(JIT-CITA'2001)*, 2001. [31](#)

- [Bar01b] Vallejos J. Ramos R. Fernández U. Barán, B. Multi-objective reactive power compensation. *En Proc. IEEE 2001 Transmission and Distribution Conference and Exposition*, 2001. [31](#)
- [Bar01c] Vallejos J. Ramos R. Fernández U. Barán, B. Reactive power compensation using a multi-objective evolutionary algorithm. *En Proc. IEEE 2001 Porto Power Tech*, 2001. [31](#)
- [BNJ92] Cauley G. Lauby M.-Maratukulam D. J. Balu N. J., Adapa R. A. *Review of Expert Systems Planning And Operations*, volume 80(5), pages 727–731. 1992. in *IEEE Trans. on Power Apparatus and Systems*, Proceedings of IEEE. [29](#)
- [Boo] Chiang H. Boone, G. *Optimal Capacitor Placement in Distribution Systems by Genetic Algorithm*. [31](#)
- [BT05] SLIMANI L. BOUKTIR T. Optimal power flow of the algerian electrical network using an ant colony optimization method. *En Leonardo Journal of Sciences de Amici Publishing House editores*, 2005. [30](#)
- [Bul99] Hartl R. Strauss C. Bullnheimer, B. *A new rank based version of the Ant System. A computational study*, *Central European Journal for operations Research and Economics*, 7:1, 25-38. 1999. [44](#)
- [Bun82] Miller R. Wheeler J. Bunch, J. *Distribution System Integrated Voltage and Reactive Power Control*, in *IEEE Trans. on Power Apparatus and Systems*, volume vol 101, no. 2, pages 284–289. 1982. [23](#)
- [BW08] S. Boslaugh and P. Watters. *Statistics in a Nutshell: A Desktop Quick Reference In a Nutshell*. 2008. .ISBN: 9780596510497, editorial O'Reilly. [87](#)
- [Car00] El-Keib A. Carlisle, J. *A Graph Search Algorithm for Optimal Placement of Fixed and Switched Capacitors on Radial Distribution Systems*, in *IEEE Trans. on Power Delivery*, volume vol. 15,no.1, pages 423–428. 2000. [29](#)
- [Cha69a] N. Chang. *Generalized Equations on Loss Reduction with Shunt Capacitors*, in *IEEE Trans. on Power Apparatus and Systems*, volume 91, pages 1574–1577. 1969. [28](#)
- [Cha69b] N. Chang. *Locating Shunt Capacitors on Primary Feeders for Voltage Control and Loss Reduction*, in *IEEE Trans. on Power Apparatus and Systems*, volume 88, pages 1574–1577. October 1969. [28](#)
- [Chr00] R. Christie. Power systems test case archive. *Electrical Engineering Dept., University of Washington*, 2000. [73](#)

- [Civ85] S. Grainger J. Civanlar. *Volt/VAR Control on Distribution Systems with Lateral Branches Using Shunt Capacitors and Voltage Regulators, Part III: The numerical results*, . in *IEEE Trans. on Power Apparatus and Systems*, volume 104, pages 3291–3297. November 1985. [28](#)
- [CM96] Awobamise B. Tong S. Rahimi A.F. Christoforidis M., Aganagic M. *Long Term/Mid-Term Resource Optimization of a Hydro-Dominant Power System using Interior Point Methods*. *IEEE Trans. Power Systems*, volume 11, pages 287–294. 1996. [28](#)
- [Coe99] C. Coello. *A comprehensive Survey of Evolutionary-based Multiobjective Optimization Techniques*, . in *Knowledge and Information Systems: An International Journal*, volume 1, pages 269–308. 1999. [1](#), [2](#), [16](#)
- [Coo59] R. Cook. *Analysis of Capacitor Application as Affected by Load Cycle*, . in *AIEE Trans.*, volume 78, pages 950–957. 1959. [28](#)
- [Coo61] R. Cook. *Optimizing the Application of Shunt Capacitors for Reactive-volt-ampere Control and Loss Reduction*, . in *AIEE Trans.*, volume 80, pages 430–444. August 1961. [28](#)
- [CR] C. Coello and C.M. Romero. *Evolutionary Algorithms and Multiple Objective Optimization*, En M. Ehrgott y X. Gandibleux (Eds.), *Multiple Criteria Optimization: State of the Art Annotated Bibliographic Surveys*. [2](#), [76](#)
- [CS] Grainger J. Civanlar S. *Volt/VAR Control on Distribution Systems with Lateral Branches Using Shunt Capacitors and Voltage Regulators, Part II: The solution method*, . in *IEEE Trans. on Power Apparatus and Systems*. [28](#)
- [DA91] Zhao R. David A.K. *An Expert Systems With Fuzzy Sets for Optimal Long Range Operation Planning*. *IEEE Trans. Power Systems*, volume 6, pages 59–65. 1991. [31](#)
- [DAGP90] J. Denenbourg, S. Aron, S. Goss, and J. Pasteels. The self-organizing exploratory pattern of the argentine ant. *Journal of Insect Behavior*, 1990. [2](#), [33](#)
- [Deb99a] K. Deb. Evolutionary algorithms for multi-criterion optimization in engineering design. Technical report, 1999. [1](#), [16](#)
- [Deb99b] K. Deb. Evolutionary algorithms for multi-criterion optimization in engineering design. In *Proceedings of Evolutionary Algorithms in Engineering and Computer Science EUROGEN99*, 1999. [21](#)
- [Deb01] K. Deb. Multi-objective optimization using evolutionary algorithms. Technical report, 2001. [76](#)

- [DHR03] K. Doerner, R. Hartl, and M. Reimann. *Are COMPETants more competent for problem solving? the case of a multiple objective transportation problem*, *Central European Journal of Operations Research*, pages 11:2,115–141. 2003. [2](#), [54](#)
- [DK02] Hartl R. Strauss C. Doerner K., Gutjahr W., editor. *Pareto Ant Colony Optimization: A Metaheuristic Approach to Multiobjective Portfolio Selection*, 2002. [2](#), [52](#)
- [DM96] Colomi A. Dorigo M., Maniezzo V. The ant system: Optimization by a colony of co-operating agents. *IEEE Trans. Systems. Man and Cybernetics*, 26:29–41, 1996. [37](#), [44](#), [47](#), [55](#)
- [DM97] Gambardella L. Dorigo M. Ant colony system: A cooperative learning approach to the traveling salesman problem. 1997. [48](#)
- [DM99] Di Caro G. Dorigo M. *The Ant Colony Optimization Meta-Heuristic*. 1999. [xvii](#), [2](#), [32](#), [35](#), [37](#), [38](#), [39](#)
- [DM00] Marannino P. Montagna M. Delfanti M., Granelli G.P. *Optimal Capacitor Placement using Deterministic and Genetic Algorithms.*, *IEEE Trans. on Energy Conversion.*, volume 15(3), pages 1041–1046. 2000. [31](#), [61](#)
- [DMS05] Devaraj Dr. D. Durairaj Mr. S., Kannan Dr. P.S. Multi-objective var dispatch using particle swarm optimization. *International Journal of Emerging Electric Power Systems*, No. 1, Article 1082, 4, 2005. [31](#)
- [DN90] Shahidehpour S.M. Deeb N. *Linear Reactive Power Optimization in a Large Power Network Using the Decomposition Approach.*, *IEEE Trans. Power Systems*, volume 5, pages 428 –438. 1990. [28](#)
- [Don04] Fabregat R. y Marzo J. Donoso, Y. Multi-objective optimization algorithm for multicast routing with traffic engineering. *IEEE 3rd International Conference on Networking (ICN2004)*, Guadalupe Caribe Francés, 2004. [21](#)
- [Don09] R. Donnelly. *The Humongous Book of Statistics Problems: Translated for People Who Don't Speak Math*. 2009. . ISBN: 1592578659, editorial Alpha. [87](#)
- [Dor92] M. Dorigo. *Multigrid Methods for Highly Oscillatory Problems, Optimization, learning and natural algorithms, disertación de Ph.D. Dipartimento di Electronica, Politecnico di Milano, Italia*. PhD thesis, Weizmann Institute of Science, Rehovot, Israel, 1992. [30](#)
- [DS03] M. Dorigo and T. Stutzle. *The Ant Colony Optimization Metaheuristic: Algorithms, Applications, and Advances*. En F. Glover y G. Kochenberger

- (Eds.), *Handbook of Metaheuristics*, tomo 57 de *International Series in Operations Research and Management Science*. Kluwer Academic Publishers. 2003. [2](#)
- [Dur68] H. Duran. *Optimum Number, Location, and Size of Shunt Capacitors in Radial Distribution Feeders, A dynamic programming approach*, . In *IEEE Trans. on Power Apparatus and Systems*, volume 87, pages 1769–1774. 1968. [28](#)
- [Dwy92] A. Dwyer. *The Use of Shunt Capacitors Applied for Line Loss Savings*, . in *Proc. 1992 CEA Conference*. April 1992. [28](#)
- [EA07] F. Luna A.J. Nebro P. Bouvry E. Alba, B. Dorronsoro. A cellular multi-objective genetic algorithm for optimal broadcasting strategy in metropolitan manets. *Computer Communications*, 2007. [74](#), [77](#), [84](#)
- [Ebe95] Kennedy J. Eberhart, R. C. *A new optimizer using particle swarm theory. Proceedings of the Sixth International Symposium on Micromachine and Human Science, Nagoya, Japan.*, pages 39–43. 1995. [31](#)
- [Esm05] Lambert-Torres G. Zambroni de Souza A.C Esmin, A.A.A. *A Hybrid Particle Swarm Optimization applied to Loss Power Minimization*, en *IEEE Transaction on Power System*, volume 20, pages 859–866. 2005. [31](#)
- [Fal98] D. Falcao. Análise de redes elétricas, rio de janeiro. Technical report, 1998. [4](#), [12](#)
- [FGBE05] U. Fernández, P. Gardel, B. Barán, and H. Estigarribia. *Aplicación del ómicron ACO al problema de Compensación de Potencia Reactiva en un contexto Multiobjetivo*. 2005. [30](#)
- [fIIC03] Proc. Twenty first IASTED International Conference, editor. *A multiobjective Ant Colony System for Vehicle Routing Problems with Time Windows*, 2003. [2](#), [52](#), [53](#)
- [For91] CIGRE Task Force. *Survey on Expert System in Alarm Handling, Electra*, volume 139, pages 133–151. 1991. [29](#)
- [G04] O. Gómez. ómicron aco, conferencia latinoamericana en informática (clei-04). 2004. [45](#)
- [GADP89] S. Goss, S. Aron, S. Denenbourg, and J. Pasteels. Self-organized shortcuts in the argentine ant. *Naturwissenschaften*, 1989. [2](#), [33](#)
- [Gam99] Taillard E. Agazzi G. Gambardella, L. *MACS-VRPTW: A Multiple Ant Colony System for Vehicle Routing Problems with Time Windows*, In D. Corne, M. Dorigo, F. Glover (Eds.), *New Ideas in Optimization*, McGraw-Hill, pages 73–76. 1999. [2](#), [52](#)

- [GB04] O. Gómez and B. Barán. ómicron aco, proceedings of clei-2004. latin-american conference on informatics (clei). arequipa. Perú. 2004. [49](#), [55](#)
- [GBF⁺06] P. Gardel, B. Barán, U. Fernandez, H. Estigarribia, and S. Duarte. *Multi-objective Reactive Power Compensation with an Ant Colony Optimization Algorithm*. 2006. [ix](#), [2](#), [4](#), [8](#), [10](#), [14](#), [23](#), [28](#), [29](#), [30](#), [31](#), [34](#), [55](#), [57](#), [59](#), [61](#), [62](#), [63](#), [73](#), [90](#)
- [GC85] J. Grainger and S. Civanlar. Volt/var control on distribution systems with lateral branches using shunt capacitors and voltage regulators, part i: The overall problem. . in *IEEE Trans. on Power Apparatus and Systems*, 104:3278–3283, 1985. [28](#)
- [Geo72] A.M. Geoffrion. *Generalized Benders Decomposition*, *Journal Of Optimization Theory Applications.*, volume 10, pages 237–261. 1972. [28](#)
- [GGB04] P. Gardel, O. Gómez, and B. Barán. *Análisis del Omicron ACO con optimización local*. 2004. [32](#), [40](#)
- [GL95] Dorigo M. Gambardella L., editor. *Ant-Q: A reinforcement Learning approach to the traveling salesman problem*. Morgan Kaufmann, 1995. [47](#)
- [GL97] F. Glover and M. Laguna. *Tabu Search*. Kluwer Academic Publishers, Boston, USA. 1997. [30](#)
- [Glo89] F. Glover. *Tabu Search - Part 1*. *ORSA Journal on Computing.*, volume 1, pages 190– 206. 1989. [30](#)
- [Glo90] F. Glover. *Tabu Search - Part 1*. *ORSA Journal on Computing.*, volume 2, pages 4–32. 1990. [30](#)
- [GLTW93] F. Glover, M. Laguna, E. Tallard, and D. De Werra. *Tabu Search*. Science Publishers, Basel, Switzerland,. 1993. [30](#)
- [Gon11] A.M. González. Optimización de intervenciones para el desplazamiento de poblaciones. *Universidad Carlos III de Madrid*, 1:37–40, 2011. [77](#)
- [GPM88] S. Granville, M.V.F. Pereira, and A. Monticelli. *An Integrated Methodology for VAR Source Planning*. *IEEE Trans. Power Systems*, volume 3(2), pages 549–557. 1988. [28](#)
- [GR96] Z. Gu and D. Rizy. *Neural Networks for Combined Control of Capacitor Banks and Voltage Regulators in Distribution Systems*. in *IEEE Trans. on Power Delivery*, volume 11, pages 1921–1928. 1996. [29](#)
- [GR97] Monticelli A. Romero R. Gallego R.A., Alves A.B. *Parallel Simulated Annealing Applied to Long Term Transmission Network Expansion Planning*. *IEEE Trans. Power Systems*, volume 12, pages 181–188. 1997. [30](#)

- [Gra94] S. Granville. *Optimal Reactive Dispatch Through Interior Point Methods*. *IEEE Trans. Power Systems*, volume 9(1), pages 136–144. 1994. [28](#)
- [Gri08] D. Griffiths. *Head First Statistics*. Editorial O'Reilly, 2008. [82](#), [87](#)
- [HG83] G.T. Hegdt and W.M. Grady. *Optimal Var Siting Using Linear Load Flow Formulation*. *IEEE Trans. Power Apparatus and Systems*, PAS-102(5), pages 1214–1222. 1983. [28](#)
- [HH93] D. Highly and T. Hilmes. *Load Forecasting by ANN*. *IEEE Computer Applications in Power*, pages 6(3)10–15. 1993. [29](#)
- [Hor97] J. Horn. *The nature of niching: genetic algorithms and the evolution of optimal, cooperative population*. PhD thesis, PhD thesis. University of Illinois at Urbana-Champaign, Urbana, Illinois., 1997. [19](#), [21](#)
- [IG98] Clements K.A. Bagchi A. Davis P.W. Irrisari G.D., Kimball L.M. *Economic Dispatch with Network and Ramping Constraints via Interior Point Methods*. *IEEE Trans. Power Systems*, volume 13(1), pages 236–242. 1998. [28](#)
- [IS00] M. Irving and Y. Song. *Optimization Methods for Electric Power Systems, Part 1, Mathematical Optimization Methods*. *IEE Power Engineering Journal*, volume 14(5), pages 245–254. 2000. [28](#)
- [IS01] Middendorf M. Iredi S., Merkle D., editor. *Bi-Criterion Optimization with Multi Colony Ant Algorithms*, 2001. [2](#), [50](#), [51](#)
- [JCC06] Lucinia Rojas Juan Carlos Correa, René Iral. *Estudio de Potencia de Pruebas de Homogeneidad de Varianza*, volume 29, pages 57–76. 2006. *Revista Colombiana de Estadística*, Universidad Nacional de Colombia. [85](#), [86](#)
- [Kun93] P. Kundur. *Power Systems Stability and Control*. , Neava York: Mc Graw-Hill. 1993. [2](#), [23](#), [24](#)
- [KW97a] R. Aggarwal K. Wardwick, A. Ekwue. Artificial intelligence techniques in power systems. Technical report, IEEE, 1997. [29](#), [31](#)
- [KW97b] S.Y. Wong. K.P. Wong. Hybrid genetic/simulated annealing to short term multiple fuel-constrained generation scheduling. Technical report, IEEE, 1997. [31](#)
- [Lan02] R. Landa. Algoritmos culturales aplicados a optimización con restricciones y optimización multiobjetivo. Master's thesis, Tesis de Maestría, Centro de Investigación y Estudios Avanzados, Instituto Politécnica Nacional. México, 2002. [22](#)

- [LIn04] Paquete L. Stutzle T. Lopez-Ibañez, M. *On the design of ACO for the Biobjective Quadratic Assignment Problem*, In: Dorigo, et al. (Eds.): *Proc. of the Fourth International Workshop on Ant Colony Optimization (ANTS 2004)*, *Lecture Notes in Computer Science*, Springer Verlag. 2004. [39](#), [40](#)
- [LKSC] G. Levitin, A. Kalyuzny, A. Shenkman, and M. Chertkov. *Optimal Capacitor Allocation in Distribution Systems Using a Genetic Algorithm and a Fast Energy Loss Computatation Technique*, . in *IEEE Trans. on Power Delivery*, pages 15(2)623–328. [31](#)
- [LPB08] C. Lezcano, D. Pinto, and B. Barán. *Team Algorithms Based on Ant Colony Optimization A New Multi-Objective Optimization Approach*, *PPSN X 2008, Dortmund, Germany*. 2008. [16](#), [32](#), [33](#), [35](#), [37](#), [40](#), [43](#), [73](#), [74](#)
- [LR04] R. Levin and D. Rubin. *Estadística para Administradores*. 2004. . ISBN: 9702604974, editorial Prentice Hall. [87](#)
- [LS04] Zhou Jiaqi Xu Guoyu Libao Shi, Hao Jin. Short-term generation scheduling with reliability constrains using ant colony optimization algorithm. *En WCICA, Fifth World Congress on Intelligent Control and Automation Hangzhou, China*, 2004. [30](#)
- [LZh03] Yun-He Hou Xin-Yin Xiong Lin Zhao-hua, Li-Juan Lu. Generalized ant colony optimization algorithm for reactive power optimization in power systems. *En Journal of N.C.E.P.*, 2003. [30](#)
- [Ma95] Lai L. Ma, J. Application to optimal reactive power dispatch including voltage-dependent load models. in *IEEE*, 1995. [31](#)
- [MA98] Selim S.Z. Mentaway A.H., Abdel-Magid Y.L. *A Simulated Annealing Algorithm for Unit Commitment*. *IEEE Trans. Power Systems*, volume 13(1), pages 197–204. 1998. [30](#)
- [Mar91] T. Marx. *The Why and How of Power Capacitor Switching*. Fischer Pierce. 1991. [28](#)
- [Mas03] Richard F. Hess-James L Mason, Robert L. Gunst. *Statistical Design and Analysis of Experiments With Applications to Engineering and Science*, volume Second Edition. 2003. [83](#), [84](#)
- [MD02] Runger G Montgomery D. *Applied Statistics and Probability for Engineers*. Editorial Wiley, third edition edition, 2002. [87](#)
- [MdL04] V. Maniezzo and L. Gambardella F. de Luigi. *Ant Colony Optimization*. In: Onwubolu, G. C., and B. V. Babu (Eds.): *New Optimization Techniques in Engineering*, Springer-Verlag, Berlin Heidelberg, pages 101–117. 2004. [37](#)

- [MGPB11] D. Méndez, P. Gardel, D. Pinto, and B. Barán. *Ubicación de Llaves Telecomandadas en Sistema de Distribución Eléctrica. Una Comparación de Algoritmos Evolutivos y Enjambre de Partículas en un Ambiente Multiobjetivo*. 2011. Tesis de Grado ,Facultad Politécnica U.N.A. [83](#)
- [Miu97] Chiang H. y Darling G. Miu, K. *Capacitor Placement, Replacement and Control in Large-scale Distribution Systems by GA-based Twostage Algorithm*, volume 12, pages 1160–1166. August 1997. .in IEEE Trans. on Power Systems. [61](#)
- [MJ94] Ogbuoriri E.C. y Adapa R. Momoh J.A., Guo S.X. *The Quadratic Interior Point Method Solving Power System Optimization Problems*. *IEEE Trans. Power Systems.*, pages 9(3):1327–1336. 1994. [28](#)
- [MJ96] Jimenez N.R. Thoden F.P. Gonzalez J. Madina J., Conejo A.J. *A LP Based Decomposition Approach to Solve The Medium Term Hydrothermal Coordination Problem*. *Proc. 12th Power System Computation Conf., Dredson, Germany*, pages 1397–1405. 1996. [28](#)
- [MJ97] Granville S. Mello J.C.O., Melo A.C.G. *Simultaneous Capability Assessment by Combining Interior Point Method and Monte Carlo Simulation*. *IEEE Trans. Power Systems*, volume 12(2), pages 736–742. 1997. [28](#)
- [MM99] C. Mariano and E. Morales. *A Multiple Objective Ant-Q Algorithm for the Design of Water Distribution Irrigation Networks*, *Technical Report HC-9904, Instituto Mexicano de Tecnología del Agua*. 1999. [2](#), [50](#)
- [Mon11] D. Montgomery. *Applied Statistics and Probability for Engineers*. Editorial Wiley, fifth edition edition, 2011. [81](#), [83](#)
- [Nea56] Samson D. Neagle, N. *Loss Reduction from Capacitors Installed on Primary Feeders*, in *AIEE Trans.*, volume 75, pages 950–959. 1956. [28](#)
- [Nes10] S. Nesmachnow. *Una Versión Paralela del Algoritmo Evolutivo para Optimización Multiobjetivo NSGA-II y su Aplicación al Diseo de Redes de Comunicaciones Confiables*. 2010. Centro de Clculo, Instituto de Computacin, Facultad de Ingeniera. Universidad de la Repblica del Uruguay. [76](#)
- [Ng00] Salama M. Chikhani A. Ng, H. *Classification of Capacitors Allocation Techniques*, .in *IEEE Trans. on Power Delivery*, volume 15, pages 387–392. 2000. [28](#)
- [NJ89] Srivastava S.C. Nanda J., Kothari D.P. *A New Optimal Power Dispatch Algorithm using Fletcher’s QP Method*. *IEE Proceedings, Generation Transmission and Distribution*, volume 136(3), pages 153–161. 1989. [28](#)

- [OA90] M. Prais B. Scott O. Alsac, J. Bright. Further developments in lp based optimal power flow. *IEEE Transactions on Power Systems*, 5(3):697–711, 1990. [28](#)
- [Par90] J. Parten. *A Simplified Modified Dynamic Programming Algorithm for Sizing Location and Feeder Reinforcements*. *IEEE Trans. Power Delivery*, volume 5(1), pages 277–283. 1990. [28](#)
- [Par91] D. Park. *Electric Load Forecasting Using an Artificial Neural Network*. *IEEE Trans. Power Systems*, volume 6(2), pages 442–449. 1991. [29](#)
- [Pin05] Barán B. Pinto, D., editor. *Multiobjective Multicast Routing Problem with a new Ant Colony Optimization approach*, 2005. [2](#), [38](#), [53](#)
- [PK92] Vannelli A. Pannambalam K., Quintana V.H. *A Fast Algorithm for Power System Optimization using Interior Point Method*. *IEEE Trans. Power Systems*, volume 7(2), pages 892–899. 1992. [28](#)
- [PM85] Cunha S.H.F. Oliveira C.G. Pereira M.V.F, Pinto L.M.V.G. *Decomposition Approach to Automated Generation/Transmission Expansion Planning*. *IEEE Trans. Power Apparatus and Systems*, volume (11), pages 3074–3083. 1985. [28](#)
- [PMB06] J. Paciello, H. Martínez, and B. Barán. Team algorithms for ant colony based multi-objective problems. *ASAI 2006, Mendoza, Argentina.*, 2006. [16](#), [32](#), [33](#), [35](#), [36](#), [37](#), [40](#), [43](#), [44](#), [55](#), [73](#)
- [PS91] Mandal D.P. Pal S.K. *Fuzzy Logic and Approximate Reasoning: An Overview*. *Journal of Institution of Electronics and Telecommunication Engineers*, pages 548–559. 1991. [30](#)
- [RA96] Goswami S.K. Roy A.D. *Development of Artificial Neural Networks for Solving Capacitor Control Problem in Distribution Network*. *Proc. 9th National Power Systems Conference, IIT Kanpur (India)*, pages 413–416. 1996. [29](#)
- [RA97] Y. H. Song R. Aggarwal. Fuzzy logic and neural networks in generation and distribution. *Power Technology International, Spring Issue*, 11(3):129–134, 1997. [31](#)
- [RJM96] Quintana V.H. Ramos J.L. M., Exposito A.G. Reactive power optimization by quadratic interior point method. *Implementation Issues. Proc. 12th Power System Computation Conf., Dredson, Alemania*, 1996. [28](#)
- [Rob60] P. Ward Robert. *Introduction to Electrical Engineering, , Third Editions; Englewood Cliffs, N. J., Prentince-Hall, Inc.* McGraw Hill, 1960. [1](#)

- [Ros09] Sheldon M. Ross. *Introduction to Probability and Statistics for Engineers and Scientists*. Elsevier Academic Press, fourth edition edition, 2009. [82](#)
- [RR96] Monticelli A. Romero R., Gallego R.A. *Transmission System Expansion Planning by Simulated Annealing*. *IEEE Trans. Power Systems*, volume 11(1), pages 364–369. 1996. [30](#)
- [Sah76] Gonzalez T. Sahni, S. P-complete aproximation problems. *Journal of the ACM*, 23, 555-565, 1976. [1](#)
- [SB79] Marinho J.L. Scott B. *Linear Programming for Power System Network Security Applications*. *IEEE Trans. Power Apparatus and Systems*, volume PAS-98, pages 837–845. 1979. [28](#)
- [SC95] Atlasovich J. Schaerer C. *Tesis de grado para optar al titulo de Ingeniero Electromecánico, Facultad de Ingeniería, Universidad Nacional de Asunción - Paraguay*. 1995. [7](#), [8](#), [11](#), [12](#)
- [Sch65] J. Schmill. *Optimum Size and Location of Shunt Capacitors on Distribution Feeders*, . in *IEEE Trans. on Power Apparatus and Systems*, volume 84, pages 825–832. 1965. [28](#)
- [Sch95] J. Schott. *Fault Tolerant Design Using Single and Multicriteria Genetic Algorithm Optimization*. 1995. Master’s thesis, Department of Aeronautics and Astronautics, Massachusetts Institute of Technology, Cambridge, Massachusetts. [76](#)
- [SD94] Chang C. Srinivasan D., Liew A. *Forecasting Daily Load Curve using a Hybrid Fuzzy-Neural Approach*. *IEE Proceedings- Generation Transmission and Distribution*, volume 141(6), pages 561–567. 1994. [31](#)
- [SI94] V.R. Sherkat and Y. Ikura. *Experience With Interior Point Optimization Software for a Fuel Planning Application*. *IEEE Trans. Power Systems*, volume 9(2), pages 833–840. 1994. [28](#)
- [SJHS88] Civanlar S., Grainger J., Yin H., and Lee S. *Distribution Feeder Reconfiguration for Loss Reduction*, . in *IEEE Trans. on Power Delivery*, volume 3, pages 1217–1223. 1988. [29](#)
- [SM94] Macqeen J.F. Ekwue A.O. Short M.J., Hui C.K. Application of artificial neural network for ngc voltage collapse monitoring. *CIGRE Symposium, Paris, Paper 28 205*, 1994. [29](#)
- [SN90] Tan O.T. Santoso N.I. *Neural-Net Based Real-Time Control of Capacitors Installed on Distribution Systems*. *IEEE Trans. Power Delivery*, volume 5(1), pages 266–272. 1990. [29](#)

- [SS94] Pahwa A. Sundhararajan S. *Optimal Selection of Capacitors for Radial Distribution Systems Using a Genetic Algorithm*, . in *IEEE Trans. on Power Systems*, volume 9, pages 1499–1507. 1994. [31](#)
- [ST00] Hoos H. Stutzle T. Max-min ant system. *Future Generation Computer Systems*, 2000. [45](#), [46](#), [53](#)
- [Ste86] R. Steuer. Multiple criteria optimization: theory, computation, and application. new york. 1986. [20](#)
- [Ste88] W. Stevenson. *Análisis de Sistemas de Potencia, Cuerna Vaca*. Graw-Hill/Interamericana de México S.A. de C.V., 1988. [8](#), [10](#), [12](#)
- [SY97a] Johns A.T. Song Y.H. *Applications of Fuzzy Logic in Power Systems. I. General Introduction to Fuzzy Logic*. *IEE Power Engineering Journal*, volume 11(5), pages 219–222. 1997. [29](#)
- [SY97b] Johns A.T. Song Y.H., Wan H.B. *Kohonen Neural Network Based Approach to Voltage Weak Buses Areas Identification*. *IEE Proceedings- Generation Transmission Distribution*, volume 144(3), pages 340–344. 1997. [30](#)
- [SY97c] Wang P.Y. Johns A.T. Song Y.H., Wang G.S. *Environmental/Economic Dispatch using Fuzzy Controlled Genetic Algorithms*. *Proc IEE - Generation Transmission Distribution*, volume 144(4), pages 377–382. 1997. [31](#)
- [SY98] Johns A.T. Song Y.H. *Applications of Fuzzy Logic in Power Systems. II. Comparison and Integration with Expert Systems Neural Networks and Genetic Algorithms*. *IEE Power Engineering Journal*, volume 12(4), pages 185–190. 1998. [30](#)
- [SY99] Johns A.T. Song Y.H. *Applications of Fuzzy Logic in Power Systems. III. Example Applications*. *IEE Power Engineering Journal*, volume 13(2), pages 97–103. 1999. [28](#)
- [TASH94] A. Chikhani T. Abdel-Salam and R. Hackam. *A New Technique for Loss Reduction Using Compensating Capacitors Applied to Distribution Systems with Varying Load Condition*. 1994. *IEEE Trans. On Power Delivery*. [29](#)
- [Tin67] C.S. Tinney, W.F. y Hart. *Power Flow Solution by Newtons Method*. *IEEE Trans. Power Apparatus and Systems*, pages PAS-86(11):1449–1460. 1967. [28](#)
- [TT90] Lubkeman D. Taylor T. *Implementation of Heuristics Search Strategies for Distribution Feeder Reconfiguration*, in *IEEE Trans. On Power Delivery*, volume 5, pages 239–246. 1990. [29](#)

- [Val02] J. Vallejos. *Compensación de Potencia Reactiva en Sistemas Eléctricos de Potencia utilizando Inteligencia Artificial*, volume Tesis de grado para optar al título de Ingeniero Electromecánico, Facultad de Ingeniería, Universidad Nacional de Asunción - Paraguay. 2002. [4](#), [6](#), [7](#), [13](#), [71](#)
- [Van] D. VanVeldhuizen. *Multiobjective Evolutionary Algorithms: Classifications, Analyses, and New Innovations*. PhD thesis, Graduate School of Engineering, Air Force Institute of Technology, Wright-Patterson AFB, Ohio. [16](#)
- [Van97] D. VanVeldhuizen. *Multi-objective Evolutionary Algorithms: Classifications, Analysis, and Innovations*. PhD thesis, Ph. D. thesis, Department of Electrical and Computer Engineering, Graduate School of Engineering, USAF Institute of Technology, Wright-Patterson AFB, Ohio, 1997. [1](#)
- [Van99] D. VanVeldhuizen. *Multiobjective Evolutionary Algorithms: Classifications, Analyses, and New Innovations*. PhD thesis, PhD thesis, Department of Electrical and Computer Engineering, Graduate School of Engineering, Air Force Institute of Technology, Wright-Patterson AFB, Ohio., 1999. [75](#)
- [VL93] Vannelli V. Vargas L.S., Quintana V.H. *A Tutorial Description of an Interior Point Method and its Applications to Security Constrained Economic Dispatch*. *IEEE Trans. Power Systems*, volume 8(3), pages 1315–1324. 1993. [28](#)
- [VOA01] D. Voelker, P. Orton, and S. Adams. *Statistics (Cliffs Quick Review)*. 2001. ISBN: 0764563882, editorial Cliffs Notes. [87](#)
- [VV93] Rao N.D. Vankayala V.S.S. *Artificial Neural Networks and Their Applications to Power Systems - A Bibliographical Survey*. *Electric Power Systems Research*, volume 28(1), pages 67–79. 1993. [29](#)
- [WQ95] Ma J. Wu Q. Power system optimal reactive power dispatch using evolutionary programming. Technical report, IEEE, 1995. [31](#)
- [YH97] Huang C.L. Yang H.T., Yang P.C. A parallel algorithm approach to solving the unit commitment problem. Technical report, IEEE, 1997. [30](#)
- [Y.H99] Song Y.H. *Modern Optimization Techniques in Power Systems*. Kluwer Academic Publishers, London, UK. 1999. [30](#)
- [Zad65] L.A. Zadeh, editor. *Fuzzy Sets*, 1965. [30](#)
- [ZE99] Thiele L. Zitzler E. Multiobjective evolutionary algorithms: A comparative case study and the strength pareto approach. Technical report, IEEE, 1999. [16](#), [75](#)
- [Zit00] Deb K. Thiele L. Zitzler, E. Comparison of multiobjective evolutionary algorithms. empirical result, evolutionary computation. Technical report, 2000. [74](#), [75](#)

- [ZT98] Eckart Zitzler and Lothar Thiele. Multiobjective optimization using evolutionary algorithms - a comparative study. *Lecture Notes in Computer Science*, 1998. [76](#)
- [ZZ89] Hope G.S. y Malik O.P Zhang Z.Z. Expert systems in electric power systems - a bibliographic survey. Technical report, IEEE, 1989. [29](#)